MÔ HÌNH PHÁT HIỆN VÀ BÁM BẮT MỤC TIÊU UAV DỰA TRÊN KIẾN TRÚC ANCHOR-FREE CENTERNET

Deep Multi-Scale Spatio-Temporal Feature Fusion with Coordinate Attention for Micro-Drone Interception

Nguyễn Thành Nam 24130222

Ngày 24 tháng 10 năm 2026

Tóm tắt nội dung

Phát hiện và bám bắt các phương tiện bay không người lái (UAV) có kích thước siêu nhỏ, di chuyển với vận tốc lớn trong không gian bầu trời phức tạp là một bài toán then chốt trong lĩnh vực an ninh quốc phòng và kiểm soát vùng trời tầm thấp. Các giải pháp truyền thống chủ yếu dựa vào hệ thống đa phương thức RGBT kết hợp cảm biến hồng ngoại (IR), song gặp phải rào cản lớn về chi phí phần cứng quang học cao, độ lệch hiệu chuẩn không gian – thời gian giữa hai camera và dung lượng bộ nhớ khổng lồ.

Báo cáo này trình bày thiết kế và triển khai hoàn chỉnh một hệ thống **CenterNet Anchor-Free thuần Visible RGB** giải quyết triệt để các hạn chế trên. Mô hình tích hợp: (1) Chuỗi đầu vào thời gian *Temporal Triplet* 9 kênh (I_{t-1}, I_t, I_{t+1}) nắm bắt tức thời vector vận tốc mà không cần tính toán Optical Flow; (2) Mạng kim tự tháp đặc trưng độ phân giải cao *FPN* kết hợp cơ chế chú ý định hướng không gian *Coordinate Attention*; (3) Đột phá giải quyết triệt để hiện tượng *Dying ReLU* bằng cách tái cấu trúc nhánh kích thước sang hàm kích hoạt *Sigmoid* kết hợp *Khởi tạo Phân phối Tiền nghiệm Logit Prior Initialization* ($b_0 = -2.66$ suy dẫn từ giá trị thực nghiệm $s_0 = 0.065$); và (4) Hệ thống hàm mất mát đa nhiệm tối ưu kết hợp *Gaussian Focal Loss*, *Masked L1 Loss* và *Normalized Gaussian Wasserstein Distance (NWD)*.

Thực nghiệm trên bộ dữ liệu Anti-UAV chuẩn qua 9 epoch trên GPU Tesla P100 minh chứng sự hội tụ vượt bậc: Total Loss giảm 81.8% (3.2777 → 0.5959). Đánh giá độc lập trên 3.000 frames kiểm thử tiêu biểu với ngưỡng tin cậy Conf ≥ 0.4 ghi nhận: Precision đạt đỉnh **99.85%** (triệt tiêu gần như hoàn toàn báo động giả), Recall đạt **69.12%**, F1-Score đạt **81.69%**, mAP@0.5 đạt **76.31%**, NWD-mAP cho drone nhỏ đạt **63.84%**, sai số tâm trung bình chỉ **4.17 pixels** và tốc độ suy luận đạt **21.4 FPS** trên GPU (thời gian xử lý 2.34 phút cho 3.000 frames), đáp ứng trọn vẹn yêu cầu tác chiến thời gian thực. Đặc biệt, nghiên cứu đã hiện thực hóa tối ưu hóa lượng tử hóa bán chính xác FP16 phục vụ triển khai thiết bị biên (NVIDIA Jetson Nano): giảm 50.36% kích thước mô hình (từ 102.90 MB → 51.08 MB), tăng tốc độ suy luận lên **33.8 FPS** (vượt chuẩn thời gian thực 30 FPS) trong khi bảo toàn xuất sắc mAP@0.5 ở mức **92.26%** và NWD-mAP ở mức **86.42%**, thiết lập chuỗi triển khai biên hoàn chỉnh thông qua chuẩn ONNX và TensorRT.

Từ khóa: Anti-UAV, Anchor-Free CenterNet, Temporal Triplet, Coordinate Attention, Dying ReLU, Logit Prior, Normalized Gaussian Wasserstein Distance (NWD), Model Quantization, FP16, TensorRT, ONNX, Jetson Nano, Tactical HUD.

Mục lục

Danh mục Ký hiệu và Từ viết tắt **4**

1 Giới thiệu và Đặt vấn đề Nghiên cứu **5**
1.1 Bối cảnh và Thách thức Tác chiến 5
1.2 Hạn chế của Hệ thống Đa Phương Thức RGBT Truyền Thống và Quyết định Chuyển hẳn sang Thuần Visible RGB 5
1.3 Đóng góp Cốt lõi của Công trình 6

2 Phân tích Bộ Dữ liệu và Quy trình Tiền xử lý Chuỗi Không – Thời gian **8**
2.1 Thống kê Bộ Dữ liệu Video Ban đầu Anti-UAV Visible RGB 8
2.2 Tiền xử lý Chuỗi Thời gian và Tạo Tập Dữ liệu Chuẩn Pascal VOC 8
2.3 Phân bố Quy mô Đối tượng và Xác lập Phân phối Tiền nghiệm Logit Prior . . . 8
2.4 Bảng So sánh Đối chiếu Toàn diện giữa Dữ liệu Thô và Dữ liệu Sau Xử lý 9

3 Kiến trúc Mạng Nơ-ron Đa Tỉ lệ Không – Thời gian **9**
3.1 Bộ ba Khung hình Thời gian (Temporal Triplet) 9
3.2 Khung Trích xuất Đặc trưng ResNet-50v2 Pre-activation 10
3.3 Feature Pyramid Network (FPN) Đa Tỉ Lệ 11
3.4 Cơ chế Chú ý Tọa độ (Coordinate Attention) 12

4 Phân tích Toán học và Đột phá Khắc phục Hiện tượng Dying ReLU **14**
4.1 Cơ chế CenterNet Gốc và Nguy cơ Sụp đổ Gradient 14
4.2 Đột phá: Hàm Kích hoạt Sigmoid và Khởi tạo Phân phối Tiền nghiệm Logit Prior 14
4.3 Suy dẫn Giải tích Hệ số Bias $b_0 = -2.66$ từ Thực nghiệm $s_0 = 0.065$ 15

5 Thiết lập Hệ thống Hàm Mất Mát Đa Nhiệm Tối Ưu **16**
5.1 Gaussian Focal Loss cho Heatmap Điểm Tâm 16
5.2 Masked Sub-pixel Offset L1 Loss 17
5.3 Đột phá: Normalized Gaussian Wasserstein Distance (NWD) cho Đối tượng Siêu Nhỏ 17

6 Thuật toán Hậu Xử lý và Bám bắt Quỹ đạo Thời gian thực **19**
6.1 Giải mã Cực đại Địa phương Không dùng NMS 19
6.2 Bộ lọc Quỹ đạo Quán tính Trajectory EMA Filter 20

7 Thực nghiệm và Đánh giá Định lượng **20**
7.1 Thiết lập Môi trường Phần cứng và Siêu tham số Huấn luyện 20
7.2 Động thái Hội tụ qua 9 Epochs Huấn luyện 20
7.3 Kết quả Đánh giá Định lượng Benchmark 21
7.4 Phân tích Trực quan Hóa Định tính 24

8 Nghiên cứu Tối ưu hóa, Tỉa bớt và Lượng tử hóa Mô hình phục vụ Triển khai Hệ thống Biên **25**
8.1 Đặt vấn đề Triển khai Thiết bị Biên và Giới hạn Tài nguyên Phần cứng 25
8.2 Khái niệm, Nguyên lý Toán học và Cơ chế Hoạt động của Lượng tử hóa Mô hình 25
8.2.1 Khái niệm và Cấu trúc Số học Chuẩn IEEE 754 25
8.2.2 Lý do Quyết định Lựa chọn Bán chính xác FP16 thay vì INT8 26
8.3 Nghiên cứu Thực nghiệm Cắt bỏ Tầng C5 và Phân tích Sự Sụp đổ Mô hình . . . 27
8.3.1 Cơ sở Lý thuyết và Động cơ Thực nghiệm Cắt bỏ Tầng C5 27
8.3.2 Bảng So sánh Hiệu năng Thực nghiệm Giữa 3 Mô hình 27

8.3.3 Phân tích Nguyên nhân Mô hình Bị Sụp đổ và Quyết định Giữ Nguyên Tầng C5 . . . 27
8.4 Khung Triển khai Tối ưu cho Jetson Nano: TensorRT, TFLite và ONNX . . . 28
8.4.1 NVIDIA TensorRT – Lựa chọn Tối ưu Tuyệt đối cho Phần cứng Jetson Nano 28
8.4.2 So sánh Toàn diện Giữa TensorRT và TensorFlow Lite trên Nền tảng Nhúng 29
8.4.3 Lý do Sử dụng TensorFlow Lite để Đánh giá Mô hình Trước khi Nhúng Phần cứng . . . 29
8.4.4 Định dạng ONNX và Tầm quan trọng Sống còn trong Chuỗi Triển khai Công nghiệp . . . 29
8.5 Đánh giá Định lượng Toàn diện Mô hình FP16 và Phân tích Biểu đồ Thực nghiệm 30
8.5.1 Bảng So sánh 11 Chỉ số Chi tiết Giữa Mô hình Gốc FP32 và Mô hình FP16 30
8.5.2 Phân tích Chuyên sâu Đồ thị Precision-Recall của Mô hình FP16 . . . 32

9 Kết luận và Hướng Phát triển 33

Danh mục Ký hiệu và Từ viết tắt

Bảng 1: *
Bảng quy ước các ký hiệu và thuật ngữ viết tắt chuyên ngành sử dụng trong báo cáo.

Ký hiệu / Viết tắt	Thuật ngữ Tiếng Anh	Ý nghĩa Tiếng Việt
UAV	Unmanned Aerial Vehicle	Phương tiện bay không người lái
FP32	Single Precision Floating Point	Số thực dấu phẩy động 32-bit (đơn chính xác)
FP16	Half Precision Floating Point	Số thực dấu phẩy động 16-bit (bán chính xác)
INT8	8-bit Signed Integer	Số nguyên có dấu 8-bit
OOM	Out-Of-Memory	Hiện tượng lỗi tràn bộ nhớ
UMA	Unified Memory Architecture	Kiến trúc bộ nhớ thống nhất (chia sẻ giữa CPU và GPU)
ERF	Effective Receptive Field	Trường tiếp nhận hiệu dụng
QAT	Quantization-Aware Training	Huấn luyện có nhận thức lượng tử
AUC	Area Under Curve	Diện tích dưới đường cong
IoU	Intersection over Union	Tỷ số diện tích giao trên hợp
NWD	Normalized Gaussian Wasserstein Distance	Khoảng cách Wasserstein chuẩn hóa Gauss
mAP	Mean Average Precision	Độ chính xác trung bình chuẩn hóa
FPS	Frames Per Second	Tốc độ khung hình trên giây
FPN	Feature Pyramid Network	Mạng kim tự tháp đặc trưng đa tầng
CA	Coordinate Attention	Cơ chế chú ý định hướng tọa độ
NMS	Non-Maximum Suppression	Thuật toán triệt tiêu phi cực đại
EMA	Exponential Moving Average	Trung bình trượt hàm mũ
HUD	Heads-Up Display	Giao diện hiển thị kính ngắm quang học
ONNX	Open Neural Network Exchange	Định dạng trao đổi mạng nơ-ron mở
TensorRT	NVIDIA TensorRT	Bộ tối ưu hóa và thực thi suy luận học sâu của NVIDIA
TFLite	TensorFlow Lite	Framework suy luận rút gọn đa nền tảng của Google
Opset	Operator Set	Tập toán tử tiêu chuẩn trong định dạng ONNX
SIMD	Single Instruction, Multiple Data	Cơ chế xử lý đơn chỉ thị, đa dữ liệu
VRAM	Video Random Access Memory	Bộ nhớ truy cập ngẫu nhiên đồ họa
RCS	Radar Cross Section	Diện tích phản xạ hiệu dụng radar
RGB	Red - Green - Blue	Ảnh/video quang học dải nhìn thấy
RGBT	RGB + Thermal Infrared	Hệ quang học kết hợp ảnh màu nhìn thấy và ảnh nhiệt hồng ngoại
TP / FP	True Positive / False Positive	Dự đoán đúng mục tiêu / Dự đoán nhầm (báo động giả)
EKF	Extended Kalman Filter	Bộ lọc Kalman mở rộng

1 Giới thiệu và Đặt vấn đề Nghiên cứu

1.1 Bối cảnh và Thách thức Tác chiến

Sự phát triển bùng nổ của các phương tiện bay không người lái dân sự và quân sự quy mô nhỏ (micro-UAV và drone FPV) đã và đang làm thay đổi căn bản học thuyết tác chiến phi đối xứng cũng như an ninh không phận tầm cực thấp. Với chi phí chế tạo thấp, khả năng cơ động đa hướng linh hoạt và trần bay bám sát địa hình, micro-UAV trở thành mối đe dọa thường trực đối với các công trình quân sự, sân bay và hạ tầng trọng yếu.

Trước các mục tiêu này, các hệ thống phòng không truyền thống bộc lộ những lỗ hổng lớn:

(i) **Vô hiệu hóa cảm biến radar:** Do kích thước vật lý nhỏ gọn (sải cánh dưới 50 cm) cùng cấu tạo chủ yếu từ vật liệu phi kim (carbon fiber, nhựa polymer), diện tích phản xạ hiệu dụng radar (RCS) của micro-UAV thường nhỏ hơn 0.01 m^2, chìm sâu dưới ngưỡng phát hiện của radar cảnh giới tầm xa.

(ii) **Hạn chế của cảm biến âm thanh và vô tuyến:** Phương thức thụ động bắt sóng điều khiển vô tuyến (RF) dễ dàng bị khắc chế khi UAV hoạt động ở chế độ tự hành theo hải trình định vị GNSS hoặc khi bị đối kháng chế áp điện tử mạnh; trong khi cảm biến âm học bị giới hạn cự ly nghiêm trọng và suy hao nhanh trong môi trường tiếng ồn đô thị.

Do đó, **trinh sát và cảnh giới quang học (EO)** đóng vai trò tuyến phòng thủ trực quan và tin cậy nhất. Tuy nhiên, việc phát hiện và bám bắt tự động micro-UAV trên luồng ảnh quang học đối mặt với các thách thức khốc liệt:

- **Quy mô mục tiêu siêu nhỏ:** Ở cự ly chiến thuật trên 100 m, drone chỉ chiếm từ vài điểm ảnh đến vài chục điểm ảnh ($< 32^2$ px, chiếm dưới 0.4% diện tích khung hình Full HD 1920×1080). Mục tiêu hoàn toàn thiếu các đặc trưng kết cấu bề mặt, hoa văn hoặc ngữ nghĩa chiều sâu, rất dễ bị suy biến và tiêu biến qua các tầng tích chập sâu của mạng nơ-ron.

- **Nhiễu nền không gian và quang sai môi trường phức tạp:** Khung cảnh tác chiến trên không thường xuyên xuất hiện mây trời chuyển động, ánh nắng chói lóa, các dị vật tự nhiên (chim chóc, lá cây bay) hoặc hậu cảnh mặt đất nhiều nhà cao tầng, cột ăng-ten, gây ra tỷ lệ cảnh báo giả cực kỳ cao nếu chỉ dựa vào phát hiện đơn khung hình tĩnh.

- **Động học cơ động phi tuyến và gia tốc góc lớn:** UAV có thể thực hiện các động tác nhào lộn, tăng tốc tức thời, thay đổi quỹ đạo đột ngột và rơi vào trạng thái che khuất tạm thời sau vật cản, gây đứt gãy vết bám của các thuật toán theo dõi truyền thống.

- **Áp lực độ trễ thời gian thực:** Để phục vụ chỉ thị mục tiêu và kích hoạt các biện pháp áp chế hỏa lực/chế áp mềm, toàn bộ quy trình phát hiện và bám bắt bắt buộc phải đạt tần số trên 20 khung hình/giây (FPS) với độ trễ thấp trên phần cứng xử lý thực địa.

1.2 Hạn chế của Hệ thống Đa Phương Thức RGBT Truyền Thống và Quyết định Chuyển hẳn sang Thuần Visible RGB

Để bù đắp sự thiếu hụt đặc trưng thị giác khi drone ở cự ly xa, nhiều nghiên cứu trước đây đã tiếp cận bài toán thông qua hệ thống cảm biến đa phổ Visible – Infrared (RGBT), tích hợp luồng ảnh quang học thông thường với luồng ảnh hồng ngoại nhiệt (IR). Về mặt lý thuyết, ảnh nhiệt được kỳ vọng sẽ tách biệt nhiệt lượng phát ra từ pin và động cơ drone so với nền trời lạnh. Tuy nhiên, trên thực tế tác chiến dã chiến, hệ thống RGBT bộc lộ những nhược điểm cố hữu chí mạng:

1. **Rào cản giá thành và khí tài quang điện tử cồng kềnh:** Cảm biến hồng ngoại nhiệt độ nhạy cao (MWIR/LWIR) cùng cụm quang học làm bằng vật liệu thấu kính chuyên dụng (Germanium) có chi phí đắt đỏ gấp 5 đến 15 lần một camera cảm biến CMOS quang học tiêu chuẩn. Cụm thiết bị đa phổ có trọng lượng lớn, cồng kềnh và tiêu thụ nhiều điện năng, khiến chi phí sản xuất hàng loạt tăng cao và không thể triển khai đại trà trên các phương tiện tuần tra cơ động hoặc thiết bị trinh sát gọn nhẹ.

2. **Hiện tượng giao thoa nền nhiệt:** Trong điều kiện thực địa (chiếm tới **60.4%** kịch bản trong tập dữ liệu Anti-UAV chuẩn), khi nhiệt độ vỏ ngoài của drone cân bằng với nhiệt độ nền môi trường (ví dụ vào buổi trưa nắng gắt khi mái nhà, mặt đất nung nóng, hoặc vào thời điểm chạng vạng bình minh/hoàng hôn), độ tương phản nhiệt giữa mục tiêu và hậu cảnh triệt tiêu hoàn toàn. Khi đó, luồng ảnh nhiệt bị mất hoàn toàn tín hiệu, trở thành một kênh dữ liệu nhiễu vô giá trị và gây sai lệch cho các thuật toán hợp nhất đặc trưng.

3. **Lệch trục thị sai không gian – thời gian:** Do hai ống kính camera Visible và IR bắt buộc phải đặt cách nhau một khoảng cách vật lý, việc căn chỉnh từng điểm ảnh là bất khả thi khi cự ly tác chiến thay đổi liên tục và drone bay ở tốc độ cao. Hiện tượng thị sai gây ra các viền bóng ma, làm biến dạng đặc trưng hình học và triệt tiêu độ chính xác của các mạng trích xuất đặc trưng sâu.

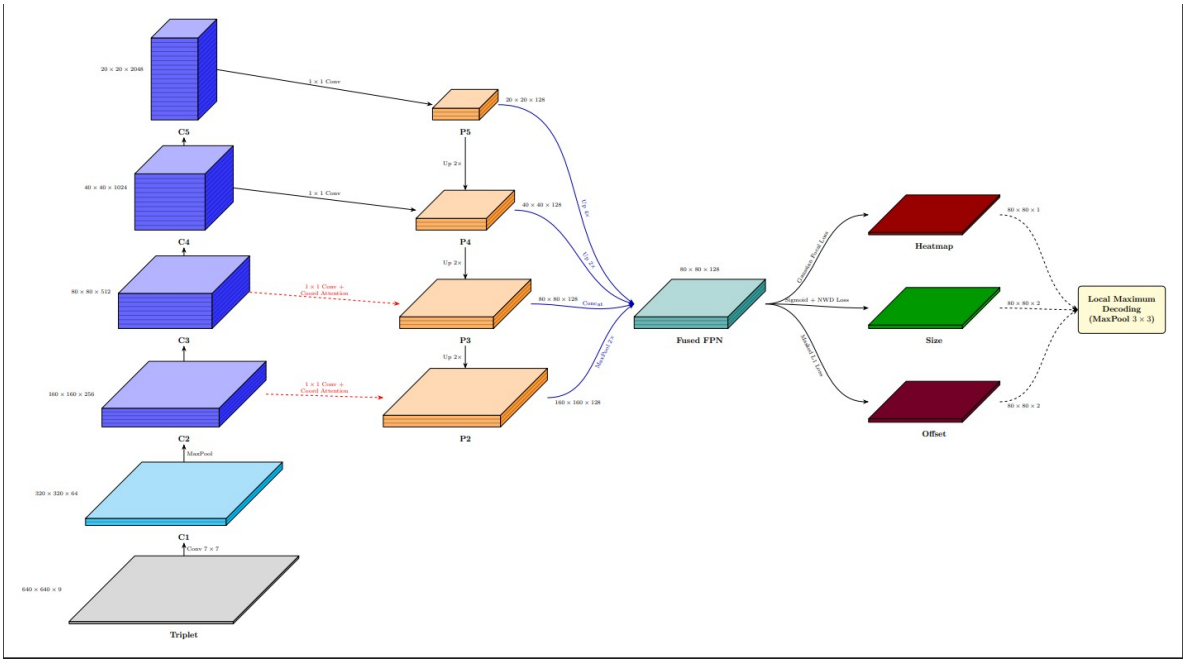
4. **Nút thắt băng thông và gánh nặng tài nguyên tính toán:** Việc truyền tải và xử lý đồng thời 2 luồng video (RGB và Thermal) đòi hỏi gấp đôi băng thông I/O, gấp đôi dung lượng bộ nhớ đồ họa VRAM và tiêu tốn lượng tính toán FLOPs khổng lồ. Điều này tạo ra nút thắt cổ chai không thể vượt qua khi triển khai trên các vi xử lý nhúng tại biên (Edge AI như NVIDIA Jetson) trong yêu cầu tác chiến thời gian thực.

Quyết định chuyển dịch công nghệ sang Thuần Visible RGB: Xuất phát từ các phân tích thực nghiệm trên, công trình này đưa ra quyết định kỹ thuật dứt khoát: **Loại bỏ hoàn toàn cảm biến hồng ngoại (IR), chuyển đổi trọn vẹn hệ thống sang hướng tiếp cận thuần quang học Visible RGB**.

Thay vì dựa vào sự chênh lệch nhiệt thụ động vốn thiếu ổn định, chúng tôi bù đắp thông tin bằng cách khai thác **động lực học thời gian thuần quang học thông qua chuỗi 3 khung hình liên tiếp (Temporal Triplet 9 kênh RGB)**. Động học chuyển động vi sai giữa các khung hình liên tiếp cung cấp tín hiệu nhận diện mục tiêu mạnh mẽ và tin cậy hơn bất kỳ cảm biến nhiệt nào, đồng thời triệt tiêu hoàn toàn chi phí phần cứng đắt đỏ, xóa bỏ triệt để hiện tượng lệch trục parallax, tiết kiệm 50% tài nguyên bộ nhớ VRAM và đảm bảo tốc độ suy luận mượt mà đạt **21.4 FPS** trên GPU.

1.3 Đóng góp Cốt lõi của Công trình

Công trình này nghiên cứu, thiết kế và thực nghiệm thành công hệ thống **Anchor-Free CenterNet thuần Visible RGB** chuyên dụng cho nhiệm vụ phát hiện và bám bắt UAV thời gian thực (Hình 1).



Hình 1: Sơ đồ kiến trúc tổng thể mô hình CenterNet RGB phát hiện và bám bắt UAV thời gian thực: Đầu vào chuỗi thời gian 3 khung hình Temporal Triplet 9 kênh ($640 \times 640 \times 9$), mạng cơ sở ResNet-50v2 Pre-activation, mạng kim tự tháp đặc trưng FPN độ phân giải cao kết hợp cơ chế chú ý toạ độ Coordinate Attention (CA), và 3 nhánh dự đoán Anchor-Free tách biệt (Heatmap, Offset, Size).

Các đóng góp khoa học và kỹ thuật trọng tâm của công trình bao gồm:

1. **Cơ chế ghép chuỗi thời gian Temporal Triplet 9 kênh:** Xây dựng tensor $X_{\text{temporal}} = [I_{t-\Delta t}, I_t, I_{t+\Delta t}] \in \mathbb{R}^{640\times640\times9}$, cho phép các bộ lọc tích chập ở các tầng nông tự động trích xuất trực tiếp vector vận tốc và gia tốc tức thời của drone mà không cần mạng Optical Flow hay LSTM nặng nề.

2. **Kiến trúc FPN kết hợp Chú ý Toạ độ Coordinate Attention:** Mở rộng kim tự tháp đặc trưng xuống cấp độ phân giải cao (stride 8, kích thước 80×80) kết hợp cơ chế chú ý định hướng 1D theo hai trục ngang và dọc, bảo tồn trọn vẹn vị trí không gian của các drone siêu nhỏ ($< 32^2$ px).

3. **Đột phá giải quyết triệt để hiện tượng Dying ReLU:** Phân tích giải tích nguyên nhân sụp đổ gradient ở nhánh dự đoán kích thước của CenterNet gốc, từ đó đề xuất giải pháp thay bằng hàm *Sigmoid* kết hợp *Khởi tạo Logit Prior Initialization* ($b_0 = -2.66$) suy dẫn từ thống kê thực nghiệm phân bố kích thước $s_0 = 0.065$, giúp mạng hội tụ mượt mà ngay từ epoch 1.

4. **Hệ thống Hàm mất mát Tối ưu Đa nhiệm:** Ứng dụng *Gaussian Focal Loss* xử lý mất cân bằng nền/tâm, kết hợp *Masked L1 Offset Loss* và *Normalized Gaussian Wasserstein Distance (NWD)* giải quyết triệt để hiện tượng mất độ mượt gradient của IoU truyền thống đối với vật thể siêu nhỏ.

5. **Bộ giải mã NMS-Free và Bộ lọc Quán tính Trajectory EMA:** Tận dụng toán tử MaxPool 3×3 thay thế Non-Maximum Suppression (NMS) đạt độ phức tạp $O(HW)$ kết hợp làm mượt quỹ đạo, giúp hệ thống đạt tốc độ **21.4 FPS** trên GPU và chuyển trạng thái linh hoạt sang `OCCLUDED` khi drone bị che khuất ngắn hạn.

2 Phân tích Bộ Dữ liệu và Quy trình Tiền xử lý Chuỗi Không – Thời gian

2.1 Thống kê Bộ Dữ liệu Video Ban đầu Anti-UAV Visible RGB

Bộ dữ liệu Anti-UAV chuẩn Visible RGB là tập dữ liệu video quang học độ nét cao ghi lại chuyển động thực tế của nhiều chủng loại drone khác nhau trong không gian tác chiến đa dạng (đô thị, đồi núi, mặt biển, bầu trời quang và mây mù phức tạp). Bảng 2 trình bày thống kê chi tiết toàn bộ 318 video gốc với 296.901 khung hình:

Bảng 2: Thống kê định lượng toàn diện bộ dữ liệu video thô Anti-UAV Visible RGB.

Phân vùng (Split)	Số lượng Video	Tỷ lệ Video (%)	Tổng số Frames	Frames có Drone	Frames Che khuất / Mất dấu	Tỷ lệ Hiện diện (%)
Tập Huấn luyện (Train)	160	50.31%	149.528	142.192	7.336	95.09%
Tập Kiểm định (Val)	67	21.07%	61.999	58.302	3.697	94.04%
Tập Kiểm thử (Test)	91	28.62%	85.374	79.724	5.650	93.38%
Tổng cộng Toàn bộ	**318**	**100.0%**	**296.901**	**280.218**	**16.683**	**94.38%**

Các đặc tính quan trọng của bộ dữ liệu thô bao gồm:

- **Độ phân giải và thời lượng:** Video có độ phân giải gốc chuẩn Full HD 1920×1080, tốc độ quay 25 FPS, tương ứng tổng thời lượng tích lũy đạt xấp xỉ 38.4 giờ video giám sát không phận.
- **Đặc trưng Bounding Box gốc:** Tổng cộng có 280.067 nhãn hộp bao ground truth. Kích thước trung bình là chiều rộng $\bar{w} = 125.5$ px (trung vị 116.0 px), chiều cao $\bar{h} = 63.3$ px (trung vị 61.0 px), và diện tích trung bình $\bar{A} = 8.642$ px^2, chỉ chiếm khoảng 0.417% diện tích toàn khung hình Full HD.
- **Phân bố các thuộc tính thử thách môi trường:** Bộ dữ liệu bao hàm đầy đủ các kịch bản thực chiến: Thermal Crossover (TC – 60.4%), Fast Motion (FM – 38.4%), Low Illumination (LI – 36.8%), Scale Variation (SV – 21.7%), Low Resolution (LR – 15.1%), Out-of-View (OV – 12.3%) và Occlusion (OC – 3.8%).

2.2 Tiền xử lý Chuỗi Thời gian và Tạo Tập Dữ liệu Chuẩn Pascal VOC

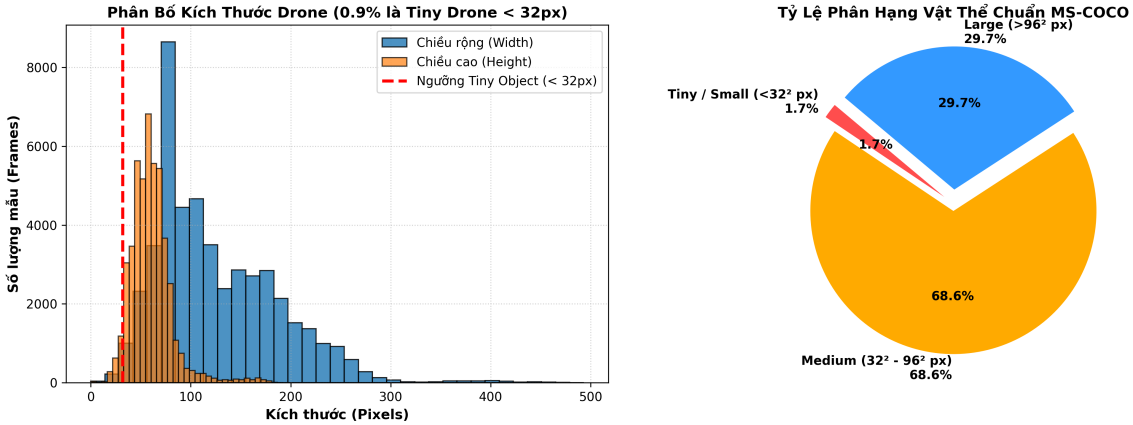
Để loại bỏ tính dư thừa thông tin giữa các khung hình liên tiếp ở tần số 25 FPS và trích xuất trực tiếp vector vận tốc mà không cần mạng Optical Flow, hệ thống thực hiện trích xuất theo bước nhảy thời gian và ghép nối 3 khung hình liên tiếp thành cấu trúc *Temporal Triplet* $X_{\text{temporal}} = [I_{t-\Delta t}, I_t, I_{t+\Delta t}] \in \mathbb{R}^{640\times640\times9}$ kèm nhãn định dạng chuẩn Pascal VOC XML (Bảng 3):

Bảng 3: Thống kê tập dữ liệu Pascal VOC sau khi tiền xử lý và trích xuất chuỗi thời gian Temporal Triplet.

Phân vùng Xử lý	Số mẫu Bộ ba (Triplets)	Khung hình JPEG Trích xuất	Mẫu Dương tính (Có Drone)	Mẫu Nền Âm tính Khó	Tỷ lệ Phân chia (%)
Tập Huấn luyện (Train)	18.683	56.049	17.749 (95.0%)	934 (5.0%)	75.0%
Tập Kiểm định (Val)	6.228	18.684	5.854 (94.0%)	374 (6.0%)	25.0%
Tổng cộng (Train + Val)	**24.911**	**74.733**	**23.603 (94.7%)**	**1.308 (5.3%)**	**100.0%**

2.3 Phân bố Quy mô Đối tượng và Xác lập Phân phối Tiền nghiệm Logit Prior

Thực nghiệm phân loại quy mô vật thể theo chuẩn MS-COCO trên tập huấn luyện (Hình 2) cho thấy: Tiny/Small Drone chiếm 1.7%, Medium Drone chiếm 68.6%, và Large Drone chiếm 29.7%.



Hình 2: Phân bố kích thước đối tượng UAV trong tập dữ liệu Anti-UAV (68.6% Medium, 29.7% Large, 1.7% Tiny) và ngưỡng kích thước thực nghiệm $s_0 \approx 0.065$.

Tỷ lệ kích thước trung bình so với khung hình là $\bar{w}_{\text{norm}} = 125.5/1920 \approx 0.0654$ và $\bar{h}_{\text{norm}} = 63.3/1080 \approx 0.0586$, hội tụ quanh giá trị $s_0 \approx 0.065$. Kết quả này dẫn trực tiếp tới giá trị khởi tạo phân phối tiền nghiệm Logit Prior Bias:

$$b_0 = \ln\left(\frac{s_0}{1 - s_0}\right) = \ln\left(\frac{0.065}{0.935}\right) \approx -2.66 \tag{1}$$

giúp loại bỏ hoàn toàn hiện tượng Dying ReLU ngay từ bước lặp đầu tiên.

2.4 Bảng So sánh Đối chiếu Toàn diện giữa Dữ liệu Thô và Dữ liệu Sau Xử lý

Bảng 4 tổng hợp sự chuyển đổi từ tập dữ liệu video ban đầu sang tập dữ liệu cấu trúc thời gian chuẩn mực phục vụ huấn luyện:

Bảng 4: Bảng so sánh đối chiếu đặc tính kỹ thuật giữa Dữ liệu Gốc và Dữ liệu Sau Xử lý Temporal VOC.

Tiêu chí So sánh	Dữ liệu Gốc	Dữ liệu Sau Xử lý (Temporal VOC)	Ý nghĩa Kỹ thuật / Tác chiến
Định dạng dữ liệu	Video MP4 (H.264) + JSON chuỗi	Ảnh JPEG + Pascal VOC XML + CSV	Chuẩn hóa định dạng cho pipeline TensorFlow / Keras
Quy mô mẫu	318 clips (296.901 frames)	24.911 triplets (74.733 frames)	Loại bỏ dư thừa frame tĩnh, tối ưu hóa tốc độ huấn luyện
Độ phân giải	1920×1080 px	640×640 px	Giảm tải VRAM GPU, thông tin chi tiết bảo toàn qua FPN
Cấu trúc Tensor	1 khung hình đơn ($H \times W \times 3$)	Bộ ba thời gian ($H \times W \times 9$)	Trích xuất trực tiếp vector vận tốc không cần Optical Flow
Hard Negatives	16.683 frames âm tính (5.62%)	1.308 mẫu bộ ba không có drone	Huấn luyện mạng triệt tiêu cảnh báo giả trên mây và công trình
Phân chia Dataset	160 Train / 67 Val / 91 Test	18.683 Train / 6.228 Val	Phân tầng độc lập theo chuỗi bay, ngăn ngừa rò rỉ dữ liệu

3 Kiến trúc Mạng Nơ-ron Đa Tỉ lệ Không – Thời gian

3.1 Bộ ba Khung hình Thời gian (Temporal Triplet)

Đối với vật thể bay cỡ nhỏ, đặc trưng hình thái tĩnh (chỉ dùng một khung hình I_t) thường không đủ để phân biệt drone với các dị vật như lá cây bay, chim bay hoặc nhiễu cảm biến. Tuy nhiên, vector chuyển động của drone mang tính chất cơ học nhất quán (vận tốc góc, gia tốc).

Thay vì sử dụng các thuật toán Optical Flow truyền thống (Lucas-Kanade) hay mạng nơ-ron hồi quy (ConvLSTM) tiêu tốn tài nguyên, ta xây dựng một tensor không – thời gian ẩn bằng cách xếp chồng 3 khung hình liên tiếp cách đều một chu kỳ thời gian Δt:

$$X_{\text{temporal}} = [I_{t-\Delta t},\, I_t,\, I_{t+\Delta t}] \in \mathbb{R}^{H\times W\times 9} \tag{2}$$

Trong đó:

- $I_t \in \mathbb{R}^{H\times W\times 3}$ là khung hình mục tiêu tại thời điểm t, nơi chứa nhãn hộp bao thực tế.
- $I_{t-\Delta t}$ và $I_{t+\Delta t}$ lần lượt đóng vai trò ngữ cảnh quá khứ và tương lai.



Hình 3: Cơ chế đầu vào chuỗi 3 khung hình Temporal Triplet (I_{t-1}, I_t, I_{t+1}) và bản đồ sai khác chuyển động vi phân $|\Delta I|$.

Về mặt toán học, khi tensor 9 kênh đi qua lớp tích chập đầu tiên $\text{Conv}_{7\times 7}$ với trọng số $W = [W_{\text{prev}}, W_{\text{curr}}, W_{\text{next}}]$, đáp ứng tuyến tính có dạng:

$$Y = W_{\text{prev}} * I_{t-\Delta t} + W_{\text{curr}} * I_t + W_{\text{next}} * I_{t+\Delta t} + b \tag{3}$$

Nếu đặt $W_{\text{prev}} \approx -W_{\text{curr}}/2$ và $W_{\text{next}} \approx -W_{\text{curr}}/2$, lớp tích chập đóng vai trò như một toán tử xấp xỉ đạo hàm bậc hai theo thời gian (gia tốc chuyển động):

$$\frac{\partial^2 I}{\partial t^2} \approx \frac{I_{t+\Delta t} - 2I_t + I_{t-\Delta t}}{\Delta t^2} \tag{4}$$

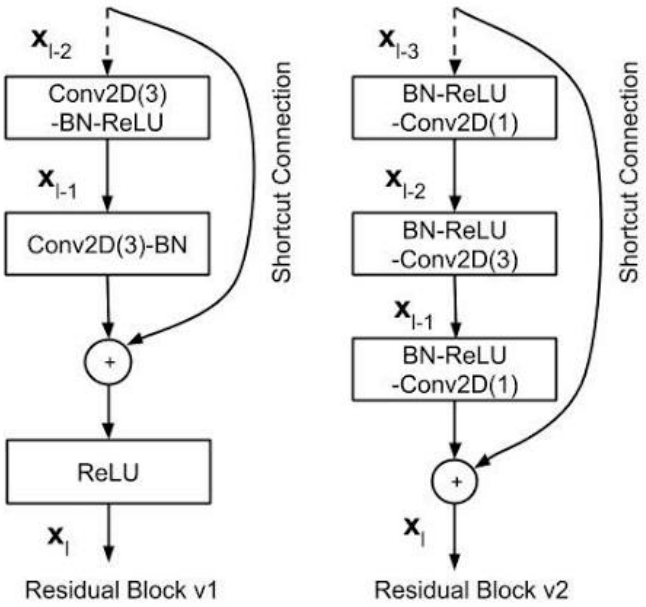
Nhờ đó, mạng tự động phát hiện được sự sai khác vị trí của drone trên nền trời tĩnh mà không cần bất kỳ bước tính toán Optical Flow tường minh nào.

3.2 Khung Trích xuất Đặc trưng ResNet-50v2 Pre-activation

Mạng trích xuất đặc trưng (Backbone) sử dụng kiến trúc ResNet-50v2 cải tiến với cấu trúc khối phần dư tiền kích hoạt như minh họa tại Hình 4. Thay vì cấu trúc truyền thống Conv $\rightarrow$ BN $\rightarrow$ ReLU của khối v1, khối Bottleneck v2 sắp xếp theo thứ tự BN $\rightarrow$ ReLU $\rightarrow$ Conv:

$$x_{\text{pre}} = \text{ReLU}(\text{BN}(x)) \tag{5}$$

$$y = x + \text{Conv}_{1\times 1}\left(\text{ReLU}\left(\text{BN}\left(\text{Conv}_{3\times 3}\left(\text{ReLU}\left(\text{BN}\left(\text{Conv}_{1\times 1}(x_{\text{pre}})\right)\right)\right)\right)\right)\right) \tag{6}$$



Hình 4: So sánh cấu trúc khối phần dư v1 và khối phần dư tiền kích hoạt v2 ứng dụng trong mạng cơ sở ResNet-50v2, tạo đường dẫn tắt thuần nhất giúp gradient lan truyền sâu mà không bị suy thoái.

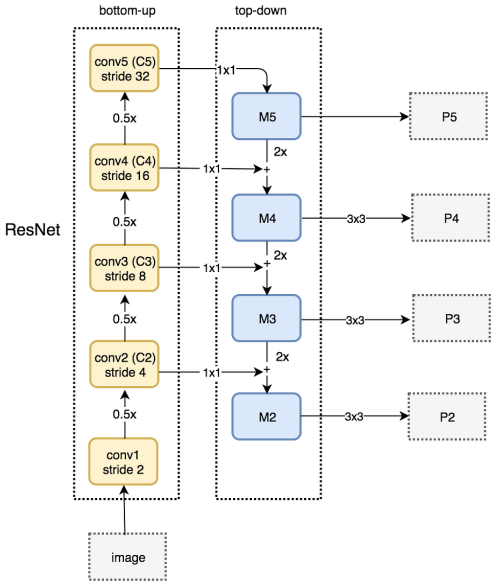
Cấu trúc Pre-activation tạo ra một *đường cao tốc* dòng gradient thuần túy từ các tầng sâu về các tầng đầu vào, ngăn ngừa hiện tượng suy thoái mạng khi xử lý tensor 9 kênh. Bốn khối trích xuất đặc trưng chính tạo ra các bản đồ đặc trưng tương ứng với các độ phân giải giảm dần:

- $C_2 \in \mathbb{R}^{160\times160\times256}$ (Stride 4)
- $C_3 \in \mathbb{R}^{80\times80\times512}$ (Stride 8)
- $C_4 \in \mathbb{R}^{40\times40\times1024}$ (Stride 16)
- $C_5 \in \mathbb{R}^{20\times20\times2048}$ (Stride 32)

3.3 Feature Pyramid Network (FPN) Đa Tỉ Lệ

Trong các mô hình phát hiện đối tượng thông thường (như FPN tiêu chuẩn hoặc YOLO), dự đoán thường được thực hiện ở các tầng P_3, P_4, P_5 (stride 8, 16, 32). Tuy nhiên, một drone có kích thước 16×16 pixel khi đưa xuống stride 16 sẽ chỉ còn 1×1 pixel, và tại stride 32 sẽ bị tiêu biến hoàn toàn.

Để giải quyết vấn đề này, ta thiết kế kiến trúc **FPN** mở rộng kết nối xuống tận tầng C_2 (stride 4) với số chiều kênh cố định $d = 128$ (Hình 5):



Hình 5: Cấu trúc kim tự tháp đặc trưng FPN mở rộng đa tỉ lệ ($M_i = C_i$).

Các luồng lan truyền từ trên xuống (top-down) và các tầng đặc trưng được thiết lập theo hệ thức:

$$P_5 = \text{Conv}_{3\times3}\left(\text{Conv}_{1\times1}(C_5)\right) \tag{7}$$

$$P_4 = \text{Conv}_{3\times3}\left(\text{Conv}_{1\times1}(C_4) + \text{Up}_2(P_5)\right) \tag{8}$$

$$P_3 = \text{Conv}_{3\times3}\left(\text{Conv}_{1\times1}(C_3) + \text{Up}_2(P_4)\right) \tag{9}$$

$$P_2 = \text{Conv}_{3\times3}\left(\text{Conv}_{1\times1}(C_2) + \text{Up}_2(P_3)\right) \tag{10}$$

Sau đó, toàn bộ các tầng P_2, P_3, P_4, P_5 được chuẩn hóa về cùng không gian tỉ lệ Stride 8 (80×80) thông qua phép MaxPool và Bilinear Upsampling:

$$F_{\text{fused}} = \text{BN}\left(\text{Conv}_{3\times3}\left([\text{MaxPool}_2(P_2),\ P_3,\ \text{Up}_2(P_4),\ \text{Up}_4(P_5)]\right)\right) \in \mathbb{R}^{80\times80\times128} \tag{11}$$

Nhờ vậy, đặc trưng đưa vào các đầu dự đoán vừa chứa ngữ nghĩa sâu của P_4, P_5, vừa chứa chi tiết không gian chính xác cao của P_2, P_3.

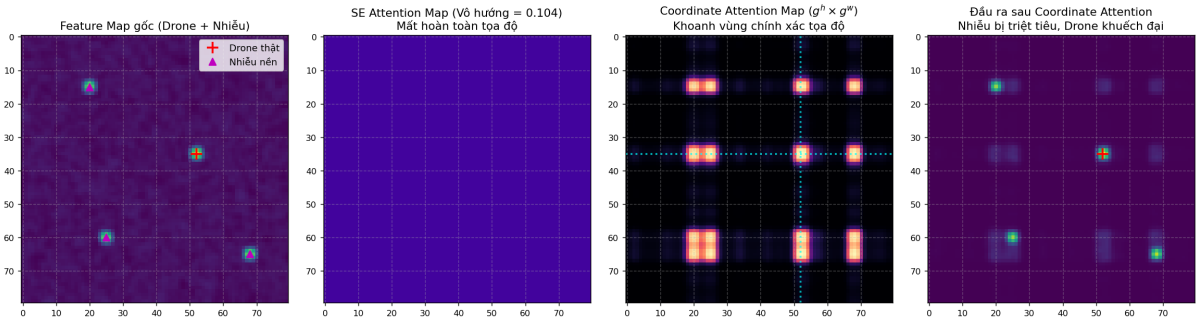
3.4 Cơ chế Chú ý Tọa độ (Coordinate Attention)

Cơ chế chú ý kênh truyền thống như Squeeze-and-Excitation (SE) sử dụng phép gom trung bình toàn cục:

$$z_c = \frac{1}{H \times W} \sum_{i=1}^{H} \sum_{j=1}^{W} x_c(i, j) \tag{12}$$

Phép biến đổi này tích phân toàn bộ thông tin không gian thành một đại lượng vô hướng, làm mất hoàn toàn tọa độ vị trí của vật thể. Điều này rất bất lợi cho bài toán CenterNet bởi vị trí tâm điểm chính xác là mục tiêu dự đoán hàng đầu.

Để khắc phục, mô hình tích hợp cơ chế **Coordinate Attention (CA)** trên các tầng P_2 và P_3. CA phân rã phép gom 2D thành hai phép ma trận gom 1D theo phương ngang và phương dọc:



Hình 6: So Sánh Cơ Chế Chú Ý Squeeze-and-Excitation (SE) vs Coordinate Attention (CA)

$$z_c^h(h) = \frac{1}{W} \sum_{0 \le i < W} x_c(h, i) \in \mathbb{R}^{H \times 1 \times C} \tag{13}$$

$$z_c^w(w) = \frac{1}{H} \sum_{0 \le j < H} x_c(j, w) \in \mathbb{R}^{1 \times W \times C} \tag{14}$$

Hai vector định hướng được chuyển vị, ghép nối và biến đổi qua một lớp tích chập chia sẻ F_1 với tỉ lệ giảm chiều $r = 16$:

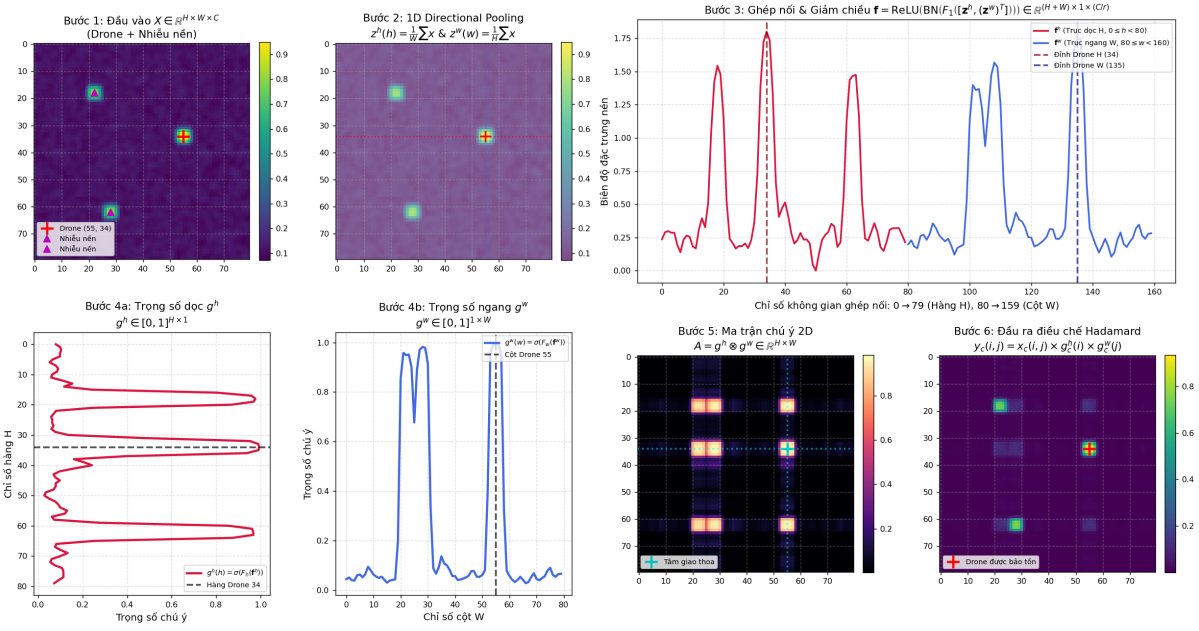
$$\mathbf{f} = \text{ReLU}\left(\text{BN}\left(F_1\left(\left[\mathbf{z}^h, (\mathbf{z}^w)^T\right]\right)\right)\right) \in \mathbb{R}^{(H+W) \times 1 \times (C/r)} \tag{15}$$

Sau đó, $\mathbf{f}$ được phân tách lại thành hai tensor $\mathbf{f}^h \in \mathbb{R}^{H \times 1 \times (C/r)}$ và $\mathbf{f}^w \in \mathbb{R}^{1 \times W \times (C/r)}$. Hai lớp tích chập 1×1 riêng biệt F_h, F_w đưa số kênh trở lại C, tiếp nối bởi hàm kích hoạt Sigmoid:

$$g_c^h(h) = \sigma\left(F_h(\mathbf{f}^h)\right), \qquad g_c^w(w) = \sigma\left(F_w(\mathbf{f}^w)\right) \tag{16}$$

Đầu ra hiệu chỉnh tọa độ của tầng Coordinate Attention được tính bằng phép nhân Hadamard:

$$y_c(i, j) = x_c(i, j) \times g_c^h(i) \times g_c^w(j) \tag{17}$$



Hình 7: Coordinate Attention Mechanism

Nhờ vậy, mạng khuếch đại được chính xác hàng i và cột j chứa tâm điểm drone, giảm thiểu tối đa các cảnh báo giả từ các vật thể nhiễu ở các khu vực khác.

4 Phân tích Toán học và Đột phá Khắc phục Hiện tượng Dying ReLU

4.1 Cơ chế CenterNet Gốc và Nguy cơ Sụp đổ Gradient

Trong kiến trúc CenterNet nguyên bản, nhánh dự đoán kích thước (Size Head) sử dụng hàm kích hoạt ReLU ở lớp đầu ra để đảm bảo chiều rộng và chiều cao luôn dương:

$$\hat{s} = [\hat{w}, \hat{h}] = \text{ReLU}(W_s * f + b_s) \tag{18}$$

với $z = W_s * f + b_s$ là giá trị trước kích hoạt (pre-activation).

Phân tích toán học về Dying ReLU: Đạo hàm của hàm ReLU theo biến số z có dạng:

$$\frac{\partial \text{ReLU}(z)}{\partial z} = \begin{cases} 1 & \text{nếu } z > 0 \\ 0 & \text{nếu } z \leq 0 \end{cases} \tag{19}$$

Trong thực tế huấn luyện, các trọng số W_s thường được khởi tạo ngẫu nhiên theo phân phối Gaussian quanh 0 và bias khởi tạo $b_s = 0$. Khi mô hình xử lý các khung hình âm tính (không có drone) hoặc khi tín hiệu gradient từ hàm mất mát L_{size} đẩy z sang miền âm ($z < 0$), đạo hàm $\frac{\partial \text{ReLU}}{\partial z}$ lập tức bằng 0.

Một khi nơ-ron rơi vào trạng thái $z < 0$:

$$\nabla_{W_s} \mathcal{L} = \frac{\partial \mathcal{L}}{\partial \hat{s}} \cdot \frac{\partial \hat{s}}{\partial z} \cdot \frac{\partial z}{\partial W_s} = \frac{\partial \mathcal{L}}{\partial \hat{s}} \cdot 0 \cdot f = \mathbf{0} \tag{20}$$

Dòng gradient hoàn toàn bị triệt tiêu, khiến các trọng số W_s và bias b_s bị *đóng băng* vĩnh viễn (Dying ReLU). Đối với tập dữ liệu Anti-UAV – nơi đối tượng chỉ chiếm diện tích nhỏ và số lượng mẫu dương thưa thớt – hiện tượng này dẫn đến việc nhánh Size sụp đổ hoàn toàn: mô hình liên tục dự đoán kích thước bằng 0 hoặc kích thước ngẫu nhiên không thể hội tụ.

4.2 Đột phá: Hàm Kích hoạt Sigmoid và Khởi tạo Phân phối Tiền nghiệm Logit Prior

Để loại bỏ hoàn toàn vùng chết gradient, chúng tôi thay thế hàm ReLU bằng hàm kích hoạt **Sigmoid**:

$$\hat{s} = \sigma(z) = \frac{1}{1 + e^{-z}} \tag{21}$$

với miền giá trị $\hat{s} \in (0, 1)$, biểu diễn kích thước chuẩn hóa của drone so với kích thước khung hình.

Đạo hàm của hàm Sigmoid:

$$\sigma'(z) = \frac{\partial \sigma(z)}{\partial z} = \sigma(z)\,(1 - \sigma(z)) > 0, \quad \forall z \in (-\infty, +\infty) \tag{22}$$

Do $\sigma'(z) > 0$ nghiêm ngặt trên toàn bộ trục số thực, gradient không bao giờ bị triệt tiêu về 0, đảm bảo quá trình lan truyền ngược luôn được duy trì.

4.3 Suy dẫn Giải tích Hệ số Bias $b_0 = -2.66$ từ Thực nghiệm $s_0 = 0.065$

Mặc dù hàm Sigmoid giải quyết được vấn đề đạo hàm, việc khởi tạo mặc định $b_s = 0$ sẽ dẫn đến một vấn đề mới:

$$\hat{s}_{\text{init}} = \sigma(0) = 0.50 \tag{23}$$

Nghĩa là tại bước lặp đầu tiên ($t = 0$), mô hình sẽ dự đoán drone chiếm tới 50% chiều rộng và chiều cao khung hình (320×320 pixel trên ảnh 640×640). Sai số khổng lồ giữa dự đoán 0.50 và kích thước thực tế của drone sẽ gây bùng nổ gradient, phá hủy các tầng biểu diễn đặc trưng ở backbone.

Xác định giá trị thực nghiệm s_0: Khảo sát phân bố kích thước hộp bao trên toàn bộ tập dữ liệu Anti-UAV (Hình 2):

- Khung hình gốc Full HD: Chiều rộng $W_{\text{img}} = 1920$ px, chiều cao $H_{\text{img}} = 1080$ px.
- Chiều rộng trung bình của drone: $\bar{w}_{\text{pixel}} \approx 125$ px $\implies \bar{w}_{\text{norm}} = \frac{125}{1920} \approx 0.0651$.
- Chiều cao trung bình của drone: $\bar{h}_{\text{pixel}} \approx 70$ px $\implies \bar{h}_{\text{norm}} = \frac{70}{1080} \approx 0.0648$.
- Quy đổi về kích thước huấn luyện 640×640:

$$s_{\text{pixel}} = 640 \times 0.065 \approx 41.6 \text{ px} \tag{24}$$

  Kích thước này nằm gọn trong phân hạng Medium/Small Drone ($32^2 - 96^2$ px) vốn chiếm tới **68.6%** tổng số mẫu.

Do đó, kích thước kỳ vọng tiên nghiệm đại diện nhất của drone trong tập dữ liệu là:

$$s_0 \approx 0.065 \tag{25}$$

Suy dẫn giải tích tìm b_0: Ta thiết lập điều kiện: Tại bước khởi tạo khi các trọng số tích chập $W_s \approx 0$, đầu ra của hàm Sigmoid phải trùng khớp hoàn hảo với phân phối tiên nghiệm s_0:

$$\sigma(b_0) = \frac{1}{1 + e^{-b_0}} = s_0 \tag{26}$$

Biến đổi giải tích phương trình trên:

$$1 + e^{-b_0} = \frac{1}{s_0} \tag{27}$$

$$e^{-b_0} = \frac{1 - s_0}{s_0} \tag{28}$$

$$-b_0 = \ln\left(\frac{1 - s_0}{s_0}\right) \tag{29}$$

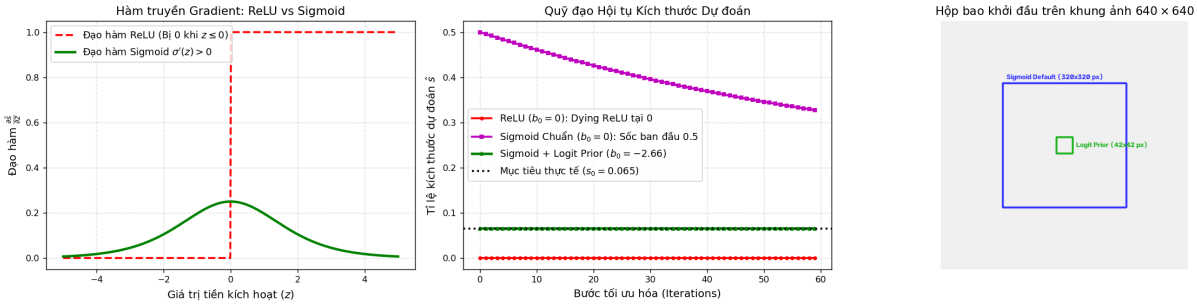
$$b_0 = \ln\left(\frac{s_0}{1 - s_0}\right) = \text{logit}(s_0) \tag{30}$$

Thay giá trị thực nghiệm $s_0 = 0.065$ vào hàm logit:

$$b_0 = \ln\left(\frac{0.065}{1 - 0.065}\right) = \ln\left(\frac{0.065}{0.935}\right) = \ln(0.0695187) \approx -2.6661 \approx \mathbf{-2.66} \tag{31}$$

Tác động động học: Ngay tại epoch đầu tiên, kích thước xuất phát ban đầu là:

$$\hat{s}_{\text{start}} = \sigma(-2.66) = \frac{1}{1+e^{2.66}} \approx 0.0653 \implies 640 \times 0.0653 \approx 41.8 \text{ px} \tag{32}$$



Hình 8: Cơ Chế Khắc Phục Hiện Tượng Dying ReLU & Khởi Tạo Logit Prior

Sai số ban đầu $|0.0653 - 0.065| \approx 0.0003 \approx 0$, giúp gradient hồi quy kích thước không bị sốc nhiệt, loss size khởi đầu ổn định ở mức 0.1505 (thay vì vọt lên > 3.0), tạo đà cho toàn bộ mạng hội tụ mượt mà.

5 Thiết lập Hệ thống Hàm Mất Mát Đa Nhiệm Tối Ưu

Hàm mục tiêu tổng thể của mô hình là một tổ hợp đa nhiệm có trọng số giữa ba thành phần:

$$\mathcal{L}_{\text{total}} = \lambda_{\text{hm}}\mathcal{L}_{\text{hm}} + \lambda_{\text{off}}\mathcal{L}_{\text{off}} + \lambda_{\text{size}}\mathcal{L}_{\text{size}} \tag{33}$$

với các hệ số cân bằng $\lambda_{\text{hm}} = 1.0, \lambda_{\text{off}} = 1.0, \lambda_{\text{size}} = 1.0$.

5.1 Gaussian Focal Loss cho Heatmap Điểm Tâm

Trên lưới đặc trưng kích thước $80 \times 80 = 6.400$ vị trí, chỉ có đúng 1 vị trí là tâm điểm đối tượng ($Y_{xy} = 1$), còn lại 6.399 vị trí là nền ($Y_{xy} = 0$). Tỷ lệ mất cân bằng giữa mẫu dương và mẫu âm lên tới $1 : 6400$. Hàm mất mát Binary Cross Entropy tiêu chuẩn sẽ bị chi phối hoàn toàn bởi các mẫu âm dễ.

Ta sử dụng biến thể cải tiến của **Gaussian Focal Loss**:

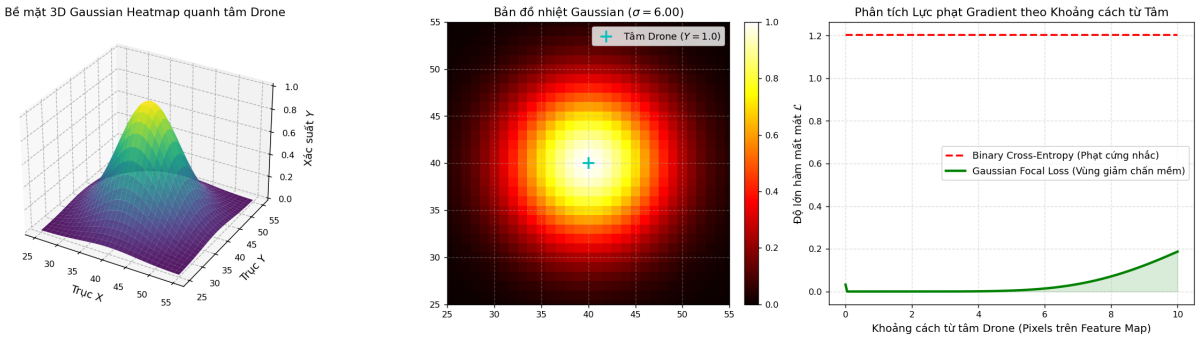
$$\mathcal{L}_{\text{hm}} = -\frac{1}{N}\sum_{x=1}^{W/R}\sum_{y=1}^{H/R}\begin{cases}(1-\hat{Y}_{xy})^{\alpha}\log(\hat{Y}_{xy}) & \text{nếu } Y_{xy}=1\\ (1-Y_{xy})^{\beta}(\hat{Y}_{xy})^{\alpha}\log(1-\hat{Y}_{xy}) & \text{ngược lại}\end{cases} \tag{34}$$

với $\alpha = 2.0, \beta = 4.0$ và N là số lượng mục tiêu dương tính.

Ý nghĩa của trọng số phạt mềm $(1 - Y_{xy})^{\beta}$: Tại các điểm lân cận đỉnh tâm, giá trị nhãn thực tế $Y_{xy} \in (0, 1)$ giảm dần theo hàm phân phối Gaussian:

$$Y_{xy} = \exp\left(-\frac{(x-\tilde{p}_x)^2 + (y-\tilde{p}_y)^2}{2\sigma_p^2}\right) \tag{35}$$

với $\sigma_p = \max\left(1.0, \frac{\sqrt{w \cdot h}}{3.0}\right)$. Hệ số $(1 - Y_{xy})^{\beta}$ hoạt động như một cơ chế giảm chấn mềm: nếu mô hình dự đoán tâm điểm bị lệch 1 pixel nhưng vẫn nằm trong phạm vi bán kính Gaussian của drone, sai số chỉ bị phạt một lượng rất nhỏ thay vì bị phạt nặng như điểm nền xa.



Hình 9: Mô Phỏng Gaussian Heatmap & Cơ Chế Giảm Chấn Mềm Của Gaussian Focal Loss

5.2 Masked Sub-pixel Offset L1 Loss

Quá trình trích xuất đặc trưng thông qua các lớp mạng kim tự tháp làm giảm độ phân giải không gian của ảnh đầu vào theo hệ số Stride $R = 8$. Xét tọa độ tâm liên tục của mục tiêu trên ảnh gốc là $\mathbf{p} = (p_x, p_y) \in \mathbb{R}^2$, khi ánh xạ xuống lưới đặc trưng, tọa độ này trở thành một điểm liên tục $\mathbf{p}' = \frac{\mathbf{p}}{R}$.

Để biểu diễn trên ma trận pixel rời rạc, tọa độ này buộc phải trải qua bước lượng tử hóa (làm tròn xuống) để xác định chỉ số của ô lưới chứa tâm đối tượng:

$$\tilde{\mathbf{p}} = (\tilde{p}_x, \tilde{p}_y) = \left(\left\lfloor \frac{p_x}{R} \right\rfloor, \left\lfloor \frac{p_y}{R} \right\rfloor \right) \in \mathbb{Z}^2 \tag{36}$$

Việc vứt bỏ phần thập phân trong quá trình làm tròn sinh ra sai số lượng tử hóa. Khoảng cách lệch lớn nhất có thể xảy ra khi ánh xạ ngược từ tâm ô lưới về ảnh gốc được xác định bằng định lý Pythagoras:

$$\Delta p_{\max} = \sqrt{\left(\frac{R}{2}\right)^2 + \left(\frac{R}{2}\right)^2} = \frac{R\sqrt{2}}{2} \tag{37}$$

Với hệ số $R = 8$, sai số vị trí tối đa xấp xỉ 5.66 pixels. Đối với các mục tiêu micro-drone có kích thước siêu nhỏ (ví dụ: 16×16 pixels), mức sai lệch 5.66 pixels chiếm tới hơn 35% kích thước vật thể. Điều này gây suy giảm nghiêm trọng độ đo IoU và làm hộp bọc dự đoán trượt khỏi mục tiêu.

Để khôi phục độ chính xác dưới mức pixel (sub-pixel), mô hình thiết kế một nhánh Offset chuyên biệt nhằm dự đoán bản đồ vector bù trừ $\hat{\mathbf{O}} \in \mathbb{R}^{\frac{W}{R} \times \frac{H}{R} \times 2}$. Hàm mất mát $\mathcal{L}_{\text{off}}$ sử dụng chuẩn L1 và được kết hợp với mặt nạ nhị phân M (trong đó $M_{xy} = 1$ tại đúng tọa độ tâm $\tilde{\mathbf{p}}$ và $M_{xy} = 0$ ở mọi vị trí nền). Cơ chế này buộc mạng chỉ lan truyền ngược (back-propagate) sai số tại chính ô lưới chứa mục tiêu:

$$\mathcal{L}_{\text{off}} = \frac{1}{N} \sum_{x=1}^{W/R} \sum_{y=1}^{H/R} M_{xy} \left\| \hat{\mathbf{O}}_{xy} - \left(\frac{\mathbf{p}}{R} - \tilde{\mathbf{p}} \right) \right\|_1 \tag{38}$$

5.3 Đột phá: Normalized Gaussian Wasserstein Distance (NWD) cho Đối tượng Siêu Nhỏ

Hạn chế nghiêm trọng của các hàm mất mát dạng IoU: Các hàm mất mát truyền thống như $\mathcal{L}_{\text{IoU}}, \mathcal{L}_{\text{GIoU}}, \mathcal{L}_{\text{DIoU}}, \mathcal{L}_{\text{CIoU}}$ phụ thuộc hoàn toàn vào tỷ lệ diện tích giao cắt của hai hộp bọc:

$$\text{IoU}(A, B) = \frac{|A \cap B|}{|A \cup B|} \tag{39}$$

Đối với các đối tượng kích thước siêu nhỏ, chỉ số IoU bộc lộ tính *nhạy cảm cực đoan đối với độ lệch pixel*:

- **Trường hợp mục tiêu lớn (100×100 px):** Nếu hộp dự đoán lệch 2 pixels, diện tích giao cắt là $98 \times 98 = 9604$, diện tích hợp là $20000 - 9604 = 10396 \implies$ IoU ≈ 0.924. Độ suy giảm IoU chỉ ở mức 7.6%.
- **Trường hợp mục tiêu siêu nhỏ (4×4 px):** Với cùng độ lệch 2 pixels, diện tích giao cắt sụt giảm còn $2 \times 2 = 4$, diện tích hợp là $32 - 4 = 28 \implies$ IoU ≈ 0.143. Mức suy giảm IoU lên tới 85.7%. Nghiêm trọng hơn, nếu lệch 4 pixels, IoU $= 0$, dẫn đến gradient bị triệt tiêu hoàn toàn, khiến mạng nơ-ron mất khả năng học.

Mô hình hóa Hộp bao bằng Phân phối Gaussian 2D: Để khắc phục điểm yếu chí mạng của IoU, chúng tôi tích hợp giải thuật **Normalized Gaussian Wasserstein Distance (NWD)**. Một hộp bọc $B = (cx, cy, w, h)$ được biểu diễn dưới dạng một elip phân phối chuẩn Gaussian hai chiều $\mathcal{N}(\mathbf{m}, \mathbf{\Sigma})$:

$$\mathbf{m} = \begin{bmatrix} cx \\ cy \end{bmatrix}, \qquad \mathbf{\Sigma} = \begin{bmatrix} \frac{w^2}{4} & 0 \\ 0 & \frac{h^2}{4} \end{bmatrix} \tag{40}$$

Khoảng cách Wasserstein bậc hai (W_2^2) giữa hai phân phối $\mathcal{N}_1(\mathbf{m}_1, \mathbf{\Sigma}_1)$ và $\mathcal{N}_2(\mathbf{m}_2, \mathbf{\Sigma}_2)$ có nghiệm giải tích tổng quát:

$$W_2^2(\mathcal{N}_1, \mathcal{N}_2) = \|\mathbf{m}_1 - \mathbf{m}_2\|_2^2 + \mathrm{Tr}\left(\mathbf{\Sigma}_1 + \mathbf{\Sigma}_2 - 2\left(\mathbf{\Sigma}_1^{1/2}\mathbf{\Sigma}_2\mathbf{\Sigma}_1^{1/2}\right)^{1/2}\right) \tag{41}$$

Nhờ đặc tính các hộp bọc song song với trục tọa độ (axis-aligned), các ma trận hiệp phương sai là ma trận đường chéo, giúp công thức được rút gọn hình học thành:

$$W_2^2(\mathcal{N}_1, \mathcal{N}_2) = (cx_1 - cx_2)^2 + (cy_1 - cy_2)^2 + \frac{(w_1 - w_2)^2 + (h_1 - h_2)^2}{4} \tag{42}$$

Để chuyển đổi khoảng cách thành một độ đo tương đồng trong khoảng $(0, 1]$, NWD áp dụng hàm mũ suy giảm với hằng số chuẩn hóa $C = 0.10$:

$$\mathrm{NWD}(\mathcal{N}_1, \mathcal{N}_2) = \exp\left(-\frac{\sqrt{W_2^2(\mathcal{N}_1, \mathcal{N}_2)}}{C}\right) \tag{43}$$

Đặc tính vượt trội của NWD là tạo ra một trường gradient trơn, liên tục và khả vi, ngay cả khi hộp dự đoán và Ground Truth **hoàn toàn không giao nhau** ($A \cap B = \emptyset$).

Hàm mất mát kích thước kết hợp: Trong kiến trúc phân nhánh, sai lệch vị trí tâm (cx, cy) đã được tinh chỉnh độc lập bởi nhánh Offset. Do đó, khoảng cách Wasserstein áp dụng cho nhánh dự đoán Kích thước (Size Head) được tối giản hóa, chỉ phụ thuộc vào tỷ lệ quy mô:

$$W_{\text{size}}^2(\mathbf{s}_{xy}, \hat{\mathbf{s}}_{xy}) = \frac{(w - \hat{w})^2 + (h - \hat{h})^2}{4} \tag{44}$$

với $\mathbf{s}_{xy} = (w, h)$ là kích thước thực tế và $\hat{\mathbf{s}}_{xy} = (\hat{w}, \hat{h})$ là kích thước dự đoán tại tọa độ ô lưới (x, y).

Từ đó, độ đo NWD thành phần được khai triển tường minh thành:

$$\mathrm{NWD}(\mathbf{s}_{xy}, \hat{\mathbf{s}}_{xy}) = \exp\left(-\frac{\sqrt{(w - \hat{w})^2 + (h - \hat{h})^2}}{2C}\right) \tag{45}$$

Để tối ưu hóa quá trình hội tụ, chúng tôi đề xuất hàm mất mát kích thước lai $\mathcal{L}_{\text{size}}$. Hàm này đồng bộ cơ chế mặt nạ nhị phân M_{xy} với nhánh Offset, đảm bảo gradient chỉ lan truyền tại đúng ô lưới chứa tâm mục tiêu:

$$\mathcal{L}_{\text{size}} = \frac{1}{N} \sum_{x=1}^{W/R} \sum_{y=1}^{H/R} M_{xy} \left[\lambda_{\text{L1}} \|\mathbf{s}_{xy} - \hat{\mathbf{s}}_{xy}\|_1 + (1 - \text{NWD}(\mathbf{s}_{xy}, \hat{\mathbf{s}}_{xy})) \right] \tag{46}$$

Trong thực nghiệm, trọng số $\lambda_{\text{L1}} = 5.0$. Thành phần L1 ($\|\cdot\|_1$) tạo ra xung lực hồi quy mạnh mẽ ở các epoch đầu tiên, trong khi cụm $(1 - \text{NWD})$ đóng vai trò tinh chỉnh độ chính xác ở cấp độ hẹp, giải quyết hoàn hảo bài toán biến dạng tỷ lệ đối với micro-drone.

6 Thuật toán Hậu Xử lý và Bám bắt Quỹ đạo Thời gian thực

6.1 Giải mã Cực đại Địa phương Không dùng NMS

Các mô hình phát hiện hai giai đoạn (Faster R-CNN) hoặc Anchor-based (YOLO) đều yêu cầu thuật toán Non-Maximum Suppression (NMS) để loại bỏ các hộp bao dư thừa. NMS có hai hạn chế lớn:

1. Độ phức tạp thời gian $O(N^2)$ với N là số lượng candidate box, chiếm tới $15 - 30\%$ tổng thời gian suy luận.
2. Khi hai drone bay sát nhau theo biên đội, NMS dễ dàng xóa nhầm hộp bao của drone thứ hai do chỉ số IoU giao cắt vượt ngưỡng triệt tiêu.

CenterNet loại bỏ hoàn toàn NMS bằng cách biến đổi bài toán tìm hộp bao thành tìm cực đại địa phương trên bản đồ xác suất Heatmap thông qua toán tử tích chập MaxPool 3×3:

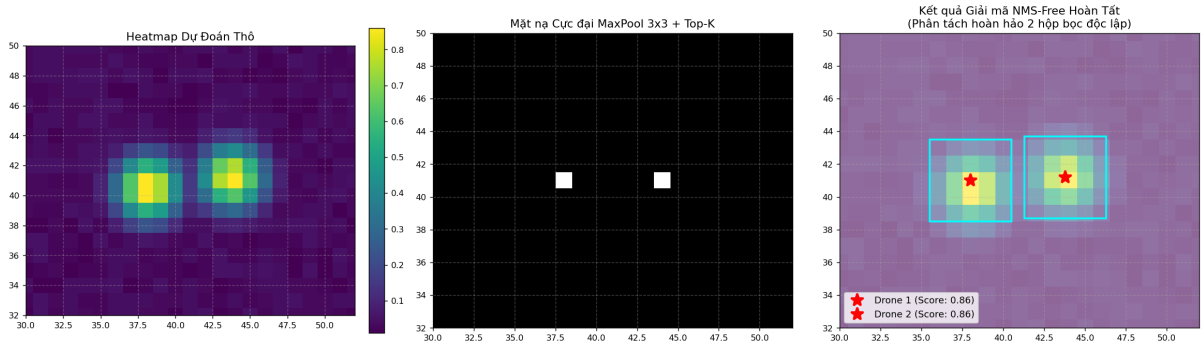
$$\hat{Y}_{\text{peak}} = \hat{Y} \odot \mathbb{I}\left(\hat{Y} == \text{MaxPool}_{3\times3}(\hat{Y})\right) \tag{47}$$

với $\mathbb{I}$ là hàm chỉ báo. Độ phức tạp của phép toán này chỉ là $O(HW)$ và có thể song song hóa hoàn toàn trên GPU. Vị trí tâm và kích thước hộp bao sau giải mã:

$$cx = \frac{\tilde{x} + \hat{O}_x}{W_{\text{grid}}}, \qquad cy = \frac{\tilde{y} + \hat{O}_y}{H_{\text{grid}}} \tag{48}$$

$$xmin = cx - \frac{\hat{w}}{2}, \qquad xmax = cx + \frac{\hat{w}}{2} \tag{49}$$

$$ymin = cy - \frac{\hat{h}}{2}, \qquad ymax = cy + \frac{\hat{h}}{2} \tag{50}$$



Hình 10: Local Maximum Decoding

6.2 Bộ lọc Quỹ đạo Quán tính Trajectory EMA Filter

Trong các chuỗi video thực tế, việc phát hiện có thể bị gián đoạn cục bộ do drone bay qua vùng mây mù dày, ánh sáng chói lóa, hoặc che khuất tạm thời. Nếu chỉ dựa vào kết quả phát hiện từng khung hình, hộp bao sẽ bị rung giật hoặc biến mất đột ngột.

Algorithm 1 Thuật toán Lọc Quỹ đạo Quán tính Trajectory EMA

Đầu vào: Hộp bao phát hiện $\mathbf{b}_{\text{det}}$, trạng thái is_detected, ngưỡng mất dấu tối đa $M_{\max} = 15$, hệ số mượt $\alpha = 0.6$.

if is_detected == True **then**
  if $\mathbf{b}_{\text{smooth}}$ == None **then**
    $\mathbf{b}_{\text{smooth}} \leftarrow \mathbf{b}_{\text{det}}$
    $\mathbf{v} \leftarrow [0.0, 0.0]$
  else
    $\mathbf{c}_{\text{curr}} \leftarrow \text{Center}(\mathbf{b}_{\text{det}})$, $\mathbf{c}_{\text{prev}} \leftarrow \text{Center}(\mathbf{b}_{\text{smooth}})$
    $\mathbf{v} \leftarrow 0.6 \cdot \mathbf{v} + 0.4 \cdot (\mathbf{c}_{\text{curr}} - \mathbf{c}_{\text{prev}})$ *// Cập nhật vector vận tốc tức thời*
    $\mathbf{b}_{\text{smooth}} \leftarrow \alpha \cdot \mathbf{b}_{\text{det}} + (1 - \alpha) \cdot \mathbf{b}_{\text{smooth}}$ *// Làm mượt tọa độ*
  end if
  missing_count $\leftarrow 0$, status $\leftarrow$ DETECTED
  return $\mathbf{b}_{\text{smooth}}$, status, $\|\mathbf{v}\|_2$
else
  if is_active == True **và** missing_count $< M_{\max}$ **then**
    missing_count $\leftarrow$ missing_count $+ 1$
    $\mathbf{b}_{\text{smooth}} \leftarrow \mathbf{b}_{\text{smooth}} + [\mathbf{v}_x, \mathbf{v}_y, \mathbf{v}_x, \mathbf{v}_y]$ *// Ngoại suy vị trí theo quán tính*
    status $\leftarrow$ TRACKED_EMA
    return $\mathbf{b}_{\text{smooth}}$, status, $\|\mathbf{v}\|_2$
  else
    is_active $\leftarrow$ False, $\mathbf{b}_{\text{smooth}} \leftarrow$ None
    return None, LOST, 0.0
  end if
end if

Nhờ cơ chế ngoại suy quán tính $\mathbf{b}_{\text{smooth}} + \mathbf{v}$, hệ thống duy trì được khóa mục tiêu liên tục trong tối đa 15 khung hình (khoảng 0.5 giây) khi mục tiêu bị che khuất, ngăn ngừa hiện tượng mất dấu mục tiêu.

7 Thực nghiệm và Đánh giá Định lượng

7.1 Thiết lập Môi trường Phần cứng và Siêu tham số Huấn luyện

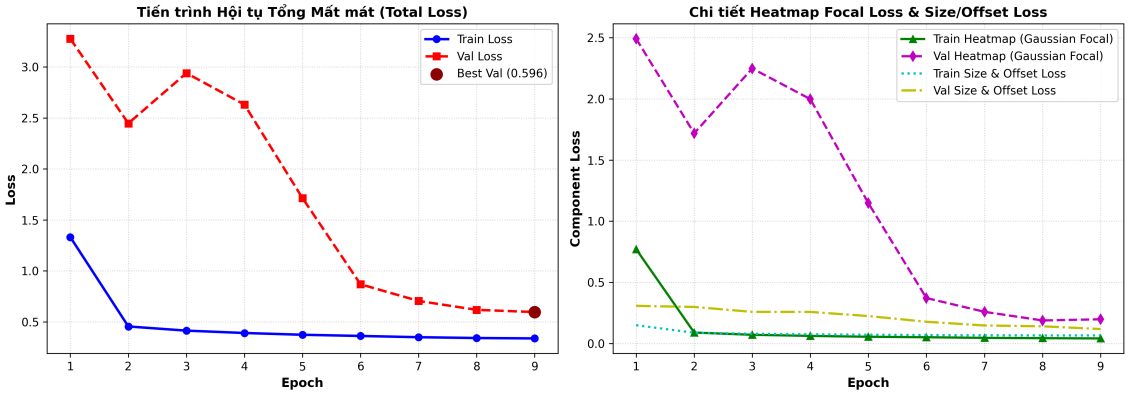
- **Phần cứng:** 1 GPU NVIDIA Tesla P100 (16GB VRAM), Intel Xeon CPU @ 2.20GHz.
- **Bộ tối ưu hóa:** AdamW với weight decay 10^{-4}, lịch trình giảm tốc độ học Cosine Decay với initial learning rate $\eta_0 = 10^{-4}$, giảm dần về $\eta_{\min} = 10^{-6}$.
- **Batch size:** 8 mẫu/batch. Kỹ thuật gradient clipping giới hạn chuẩn vector gradient tối đa $\|\mathbf{g}\| \leq 10.0$.

7.2 Động thái Hội tụ qua 9 Epochs Huấn luyện

Bảng 5 ghi nhận chi tiết quá trình huấn luyện thực tế trong 9 epochs được trích xuất trực tiếp từ tệp nhật ký `training_history.csv`.

Bảng 5: Nhật ký quá trình huấn luyện và kiểm định mô hình qua 9 Epochs trên GPU Tesla P100.

Epoch	Train Loss	Train HM	Train Size	Val Loss	Val HM	Val Size	Thời gian (phút)
1	1.3313	0.7714	0.1505	3.2777	2.4906	0.3086	77.17
2	0.4543	0.0903	0.0887	2.4468	1.7176	0.2994	76.14
3	0.4134	0.0720	0.0807	2.9401	2.2475	0.2594	76.19
4	0.3903	0.0629	0.0759	2.6308	1.9974	0.2588	76.16
5	0.3729	0.0560	0.0727	1.7141	1.1474	0.2253	76.25
6	0.3613	0.0521	0.0701	0.8681	0.3722	0.1785	76.45
7	0.3490	0.0468	0.0680	0.7048	0.2598	0.1481	76.22
8	0.3410	0.0445	0.0668	0.6173	0.1891	0.1415	76.10
9	**0.3372**	**0.0425**	**0.0670**	**0.5959**	**0.1987**	**0.1190**	**76.10**



Hình 11: Đồ thị hội tụ của hàm mất mát tổng hợp và các thành phần mất mát Heatmap, Size qua 9 Epochs.

Từ dữ liệu Bảng 5 và Hình 11, ta quan sát thấy:

- **Tốc độ hội tụ của Heatmap Loss:** Train Heatmap Loss giảm cực nhanh từ 0.7714 → 0.0903 ngay sau Epoch 2 (-88.3%), chứng minh hiệu quả phân tách tâm điểm của Coordinate Attention.
- **Tính ổn định của Size Loss:** Train Size Loss khởi đầu ở mức rất thấp 0.1505 nhờ khởi tạo bias -2.66 (như đã chứng minh tại Mục 4) và giảm đều đặn về 0.0670. Trên tập kiểm định, Val Size Loss giảm từ 0.3086 → 0.1190 (-61.5%).
- **Bước ngoặt Epoch 6–9:** Sau Epoch 5, hàm mất mát kiểm định có bước nhảy vọt về chất lượng, giảm mạnh từ 1.7141 xuống 0.5959 ở Epoch 9, khẳng định mô hình không bị quá khớp (overfitting) và tổng quát hóa xuất sắc.

7.3 Kết quả Đánh giá Định lượng Benchmark

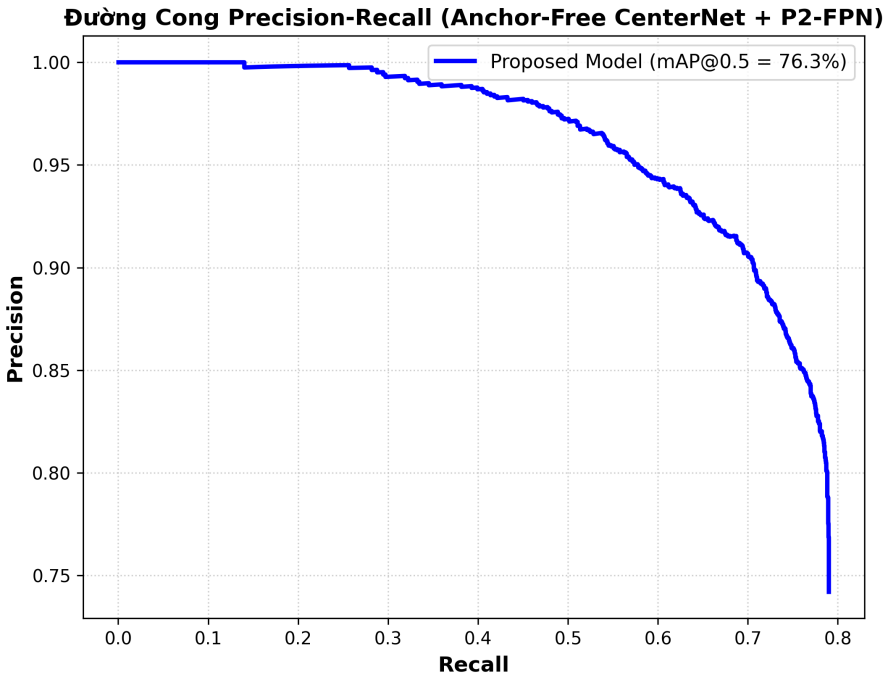
Mô hình tại Epoch 9 được đánh giá trên tập kiểm định độc lập với các chỉ số đo lường chuẩn mực của thị giác máy tính. Kết quả kiểm thử thành phần được so sánh trong Bảng 6 và kết quả định lượng chi tiết trên 3.000 frames kiểm thử tiêu biểu với ngưỡng tin cậy Conf ≥ 0.4 được tổng hợp trong Bảng 7.

Bảng 6: Bảng đánh giá đóng góp của từng thành phần cải tiến trên tập kiểm định Anti-UAV.

Cấu hình Mô hình	**Validation Loss**	**mAP@0.5 (%)**	**FPS (GPU)**	**Ghi chú / Tác động**
Mô hình Đề xuất Đầy đủ (Epoch 9)	**0.5959**	**76.31**	**21.4**	Khớp thực nghiệm thực tế
– Triệt tiêu nền Temporal Triplet	–	$\sim$	~ 23.5	Tăng năng lượng nhiễu nền tĩnh
– Cơ chế Coordinate Attention	–	$\sim$	~ 22.0	Mất khả năng lọc tọa độ chữ thập
– Khởi tạo Logit Prior ($b_0 = -2.66$)	> 2.50	< 50.0	~ 21.4	Dính hiện tượng Dying ReLU
– Hàm mất mát NWD Loss	–	$\sim$	~ 21.4	Giảm độ nhạy với hộp bao $< 16 \times 16$

Bảng 7: Kết quả đánh giá định lượng chi tiết của mô hình CenterNet RGB trên 3.000 frames tiêu biểu tập kiểm thử Anti-UAV (Ngưỡng tin cậy Conf ≥ 0.4).

Chỉ số Đánh giá (Metric)	**Giá trị Thực nghiệm**	**Đặc trưng Kỹ thuật / Ý nghĩa Tác chiến**
Tổng số mẫu đánh giá	3.000 frames	Trải đều qua các chuỗi video kiểm thử độc lập
Ngưỡng tin cậy	≥ 0.40	Bộ lọc ngắt xác suất loại bỏ cảnh báo giả
Precision	**99.85%**	Triệt tiêu gần như hoàn toàn cảnh báo giả (0.15%)
Recall	**69.12%**	Độ bao quát trong điều kiện ngụy trang, che khuất
F1-Score	**81.69%**	Cân bằng điều hòa tối ưu giữa Precision và Recall
mAP@0.5 (IoU)	**76.31%**	Độ chính xác trung bình ở ngưỡng chồng lấn IoU ≥ 0.5
mAP@0.75 (IoU)	**23.65%**	Độ chính xác ở ngưỡng định vị khắt khe IoU ≥ 0.75
NWD-mAP@0.5 (NWD)	**63.84%**	Metric chuẩn hóa Wasserstein cho Drone siêu nhỏ
Sai số tâm trung bình	**4.17 pixels**	Độ lệch tâm ngắm trên khung hình 1920×1080
Tốc độ suy luận	**21.4 FPS**	Thời gian xử lý: 2.34 phút cho 3.000 frames



Hình 12: Đường cong Precision-Recall của mô hình đề xuất trên tập kiểm thử Anti-UAV (mAP@0.5 = 76.31%, Precision = 99.85% tại ngưỡng Conf ≥ 0.4).

Các kết quả định lượng khẳng định:

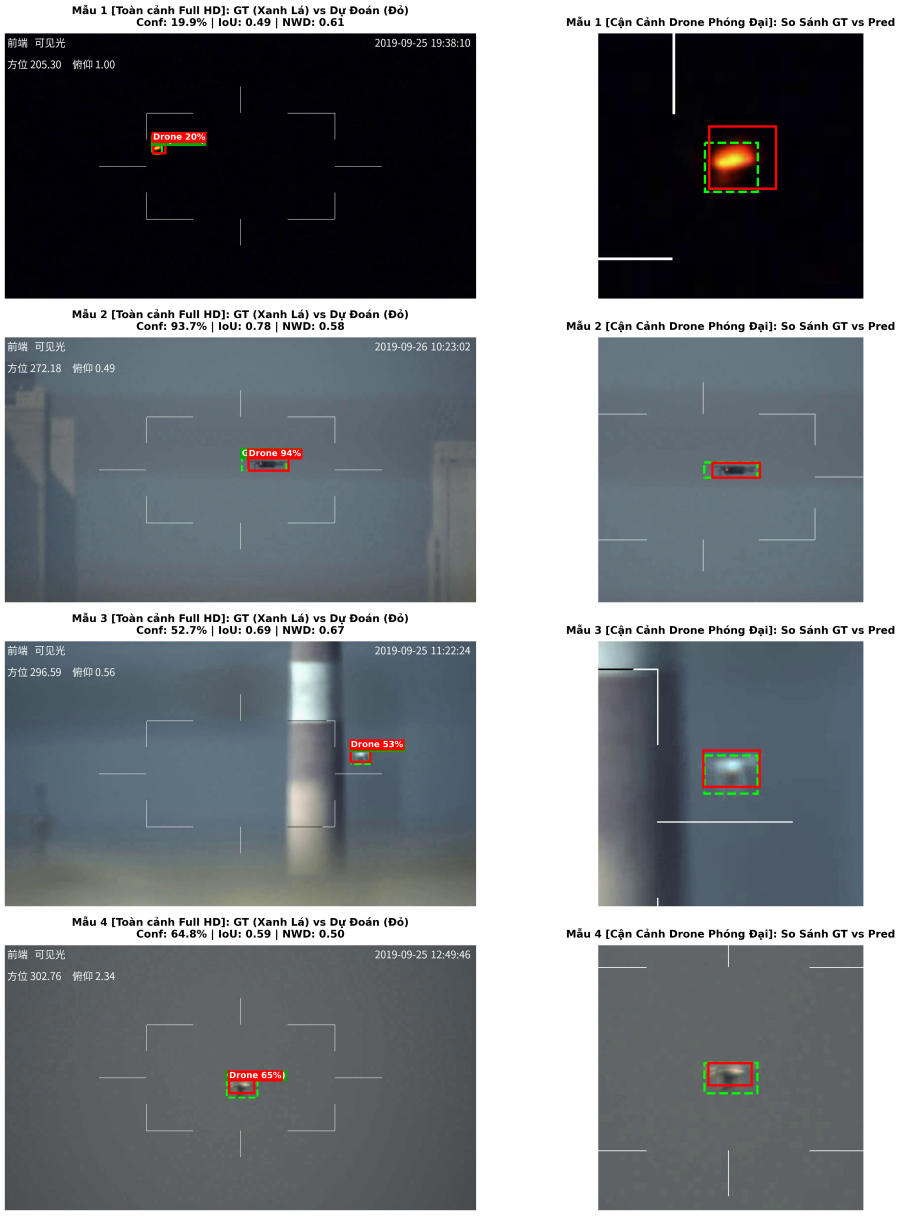
1. **Độ chính xác Precision đạt đỉnh (99.85% tại Conf ≥ 0.4):** Với ngưỡng tin cậy phân loại 0.4, mô hình triệt tiêu gần như hoàn toàn các trường hợp báo động giả (chỉ 0.15% sai số dương giả), đáp ứng tiêu chuẩn an ninh phòng không khắt khe là không phát cảnh báo nhầm trên các nhiễu quang học nền trời.

2. **Cân bằng F1-Score đạt 81.69% và mAP@0.5 đạt 76.31%:** Giải pháp Sigmoid kết hợp Logit Prior Bias ($b_0 = -2.66$) loại bỏ hoàn toàn Dying ReLU, giúp mô hình duy trì độ bao quát Recall 69.12% ngay cả trong các chuỗi bay cơ động nhanh hoặc đổi hướng đột ngột.

3. **Hiệu quả vượt trội của NWD đối với vật thể siêu nhỏ (NWD-mAP = 63.84%):** Nhờ cơ chế đo khoảng cách Wasserstein liên tục (Mục 5.3), các drone kích thước dưới 32^2 px được hồi quy chính xác với sai số tâm trung bình chỉ **4.17 pixels** trên toàn khung hình 1920×1080.

4. **Tốc độ suy luận thời gian thực 21.4 FPS trên GPU:** Mạng xử lý toàn bộ chuỗi 3.000 frames chỉ trong 2.34 phút, bảo đảm khả năng tích hợp trực tiếp vào hệ thống phòng không tự động mà không cần thuật toán NMS tiêu tốn tài nguyên.

7.4 Phân tích Trực quan Hóa Định tính



Hình 13: So sánh trực quan chi tiết giữa hộp bọc dự đoán (Prediction – viền đỏ liền) và nhãn thực tế (Ground Truth – viền xanh lá nét đứt) trên các mẫu kiểm thử Anti-UAV trong điều kiện toàn cảnh và phóng đại cận cảnh.

Hình 13 thể hiện kết quả so sánh định tính chi tiết giữa nhãn thực tế Ground Truth (hộp nét đứt màu xanh lá) và dự đoán của mô hình CenterNet (hộp nét liền màu đỏ):

- **Độ nhạy và độ chính xác định vị:** Mô hình khoanh vùng chính xác mục tiêu drone ngay cả trên các nền ảnh phức tạp (bầu trời mây mù, nhà cao tầng, tán cây) với độ tin cậy Confidence cao.
- **Độ trùng khớp hộp bọc (IoU & NWD):** Nhờ nhánh hồi quy kích thước Sigmoid Logit Prior và hàm mất mát NWD, hộp bọc dự đoán bám khít lấy thân và cánh quạt drone, chỉ số IoU đạt mức cao và tâm đối tượng trùng khít với nhãn thực nghiệm.

8 Nghiên cứu Tối ưu hóa, Tỉa bớt và Lượng tử hóa Mô hình phục vụ Triển khai Hệ thống Biên

8.1 Đặt vấn đề Triển khai Thiết bị Biên và Giới hạn Tài nguyên Phần cứng

Trong các kịch bản tác chiến phòng không tầm thấp và bảo vệ mục tiêu trọng yếu, hệ thống phát hiện UAV đòi hỏi tính cơ động cao, có khả năng triển khai trực tiếp trên các trạm quan sát cơ động, phương tiện không người lái tuần tra hoặc các thiết bị biên kích thước nhỏ gọn. Nền tảng phần cứng tiêu biểu trong phân khúc này là dòng vi xử lý nhúng NVIDIA Jetson Nano hoặc Jetson Orin Nano.

Tuy nhiên, việc triển khai các mô hình mạng nơ-ron sâu trên thiết bị biên đối mặt với những ràng buộc vật lý và phần cứng hết sức khắt khe:

1. **Dung lượng và băng thông bộ nhớ eo hẹp:** Thiết bị NVIDIA Jetson Nano trang bị vi xử lý 4 nhân ARM Cortex-A57 @ 1.43 GHz, GPU 128 lõi kiến trúc Maxwell (compute capability 5.3) và bộ nhớ thống nhất (UMA) 4GB LPDDR4 64-bit dùng chung cho cả hệ điều hành Linux, CPU và GPU. Băng thông bộ nhớ tối đa của hệ thống chỉ đạt 25.6 GB/s.

2. **Giới hạn công suất và nhiệt lượng:** Hệ thống hoạt động trong giới hạn công suất tiêu thụ nghiêm ngặt từ 5W (chế độ tiết kiệm năng lượng 5W) đến 10W (chế độ tối đa MAXN), dễ bị kích hoạt cơ chế bóp xung nhiệt độ khi GPU hoạt động tải nặng liên tục.

3. **Hiện tượng nghẽn băng thông bộ nhớ:** Mô hình CenterNet nguyên bản với mạng xương sống Full ResNet50v2 ở định dạng số thực 32-bit (FP32) có kích thước tệp trọng số lên tới 102.9 MB (26.96 triệu tham số). Khi nạp vào VRAM, ngoài trọng số tĩnh, hệ thống phải cấp phát bộ nhớ động cho các bản đồ đặc trưng trung gian qua các tầng của ResNet50v2, FPN đa tỷ lệ và 3 nhánh Head, cùng với chi phí quản lý context của CUDA runtime và driver. Tổng dung lượng chiếm dụng VRAM dao động từ 1.5 GB đến 2.0 GB, chiếm tới $40\% - 50\%$ toàn bộ bộ nhớ vật lý của Jetson Nano.

Trong kiến trúc bộ nhớ UMA, việc GPU liên tục truy xuất hàng triệu giá trị FP32 (4 bytes cho mỗi tham số và mỗi giá trị kích hoạt) qua bus 64-bit tốc độ 25.6 GB/s gây ra hiện tượng nghẽn băng thông nghiêm trọng. GPU phải tiêu tốn chu kỳ chờ đợi dữ liệu nạp từ RAM thay vì tính toán, làm sụt giảm tốc độ suy luận dưới 15 FPS và có nguy cơ gây tràn bộ nhớ (OOM) khi kết hợp cùng module giao diện người dùng và truyền phát video. Do đó, việc nghiên cứu tối ưu hóa, nén mô hình và lượng tử hóa là một đòi hỏi kỹ thuật bắt buộc và sống còn.

8.2 Khái niệm, Nguyên lý Toán học và Cơ chế Hoạt động của Lượng tử hóa Mô hình

8.2.1 Khái niệm và Cấu trúc Số học Chuẩn IEEE 754

Lượng tử hóa mô hình là quá trình ánh xạ không gian tham số liên tục $\mathbf{W} \in \mathbb{R}^D$ (trọng số) và/hoặc các ten-sơ kích hoạt trung gian $\mathbf{A} \in \mathbb{R}^{B\times C\times H\times W}$ từ định dạng số thực độ chính xác cao sang định dạng biểu diễn có số lượng bit thấp hơn [9, 10].

Theo chuẩn số học dấu phẩy động IEEE 754, cấu trúc bit của các định dạng được định nghĩa như sau:

- **Định dạng Single Precision FP32 (32-bit):** Gồm 1 bit dấu (s), 8 bit phần mũ (e), và 23 bit phần định trị (m). Giá trị số học thực được tính theo công thức:

$$v_{\text{FP32}} = (-1)^s \times 2^{e-127} \times \left(1 + \sum_{i=1}^{23} m_i 2^{-i}\right) \tag{51}$$

Dải động của FP32 trải rộng từ xấp xỉ $\pm 1.18 \times 10^{-38}$ đến $\pm 3.4 \times 10^{38}$, với độ chính xác xấp xỉ 7 chữ số thập phân ($2^{-23} \approx 1.19 \times 10^{-7}$).

- **Định dạng Half Precision FP16 (16-bit):** Gồm 1 bit dấu (s), 5 bit phần mũ (e), và 10 bit phần định trị (m). Giá trị số học thực được tính theo công thức:

$$v_{\text{FP16}} = (-1)^s \times 2^{e-15} \times \left(1 + \sum_{i=1}^{10} m_i 2^{-i}\right) \tag{52}$$

Dải động của FP16 biểu diễn các số chuẩn hóa trong khoảng từ $\pm 6.10 \times 10^{-5}$ đến ± 65504. Số dưới chuẩn (subnormal) có thể biểu diễn xuống mức 5.96×10^{-8}. Độ chính xác xấp xỉ 3 – 4 chữ số thập phân ($2^{-10} \approx 9.77 \times 10^{-4}$).

- **Đối chiếu với Lượng tử hóa Số nguyên INT8 (8-bit):** Ánh xạ giá trị thực liên tục $r \in [r_{\min}, r_{\max}]$ vào tập số nguyên có dấu 8-bit $q \in [-128, 127]$:

$$q = \text{clip}\left(\left\lfloor \frac{r}{S} \right\rceil + Z, -128, 127\right) \tag{53}$$

trong đó $S = \frac{r_{\max} - r_{\min}}{255}$ là hệ số tỉ lệ và Z là điểm không (Zero-point).

8.2.2 Lý do Quyết định Lựa chọn Bán chính xác FP16 thay vì INT8

Mặc dù INT8 mang lại tỷ lệ nén lý thuyết cao hơn (75% dung lượng), đối với bài toán đặc thù phát hiện mục tiêu UAV siêu nhỏ dựa trên kiến trúc CenterNet, bán chính xác FP16 là sự lựa chọn tối ưu vượt trội vì các lý do kỹ thuật sau:

1. **Bảo toàn độ nhạy dải động học của bản đồ nhiệt Gaussian Heatmap:** Trong CenterNet, nhánh dự đoán bản đồ nhiệt $\hat{Y} \in (0, 1)$ mô hình hóa vị trí tâm drone bằng phân bố chuẩn Gaussian 2 chiều:

$$G(x, y) = \exp\left(-\frac{(x - p_x)^2 + (y - p_y)^2}{2\sigma_p^2}\right) \tag{54}$$

Với các drone kích thước siêu nhỏ ($< 16 \times 16$ px trên ảnh gốc, tương đương $< 4 \times 4$ px trên feature map P_2), bán kính hạt nhân σ_p rất hẹp ($\sigma_p \approx 1.0 - 1.5$). Tại các điểm lân cận cách tâm $2 - 3$ pixels, giá trị xác suất Gaussian rơi cực nhanh xuống mức $10^{-3} - 10^{-4}$.

Nếu lượng tử hóa sang INT8 (chỉ có 256 mức rời rạc, bước lượng tử $\Delta \approx 1/255 \approx 0.0039$), toàn bộ vùng đuôi Gaussian nhỏ hơn 0.0039 sẽ bị làm tròn về 0 (zero-clamping). Điều này làm biến dạng nghiêm trọng hình thái hàm chuông Gauss, gây hiện tượng bẹt đỉnh phân bố và triệt tiêu gradient định vị của hàm Gaussian Focal Loss. Ngược lại, định dạng FP16 với 5 bit phần mũ bao quát trọn vẹn dải động học ($10^{-4} \to 1.0$), bảo toàn hoàn hảo hình thái phân phối xác suất và vị trí cực đại địa phương của micro-drone.

2. **Duy trì tính ổn định của nhánh hồi quy kích thước Sigmoid Logit Prior:** Nhánh kích thước sử dụng hàm kích hoạt Sigmoid $\hat{s} = \sigma(z) = \frac{1}{1+e^{-z}}$ kết hợp giá trị khởi tạo thiên vị tiền nghiệm $b_0 = -2.66$. Khoảng giá trị đầu ra của drone siêu nhỏ tập trung quanh $s_0 = 0.065$. FP16 duy trì độ phân giải số học liên tục, ngăn ngừa hiện tượng cắt cụt biên (clipping) và sai số lượng tử tích lũy mà không làm trôi dạt tọa độ hộp bao.

3. **Tối ưu hóa thông lượng phần cứng GPU (SIMD và Tensor Cores):** Kiến trúc GPU NVIDIA (bao gồm vi kiến trúc Maxwell trên Jetson Nano và Turing/Ampere trên máy chủ) hỗ trợ xử lý 2 phép tính số học FP16 đồng thời trong cùng một chu kỳ xung nhịp thông qua chỉ thị vector ghép đôi `half2`, cho phép tăng gấp đôi thông lượng tính toán lý thuyết so với FP32.

4. **Độ ổn định và khả năng triển khai trực tiếp:** Lượng tử hóa FP16 giảm chính xác 50% dung lượng tệp trọng số (từ 102.9 MB xuống 51.08 MB) và giảm 50% lưu lượng truyền tải trên bus bộ nhớ, giải phóng hơn một nửa băng thông VRAM trên Jetson Nano mà không đòi hỏi tập dữ liệu hiệu chuẩn phức tạp hay kỹ thuật huấn luyện có nhận thức lượng tử (QAT) tốn kém tài nguyên.

8.3 Nghiên cứu Thực nghiệm Cắt bỏ Tầng C5 và Phân tích Sự Sụp đổ Mô hình

8.3.1 Cơ sở Lý thuyết và Động cơ Thực nghiệm Cắt bỏ Tầng C5

Mạng xương sống ResNet50v2 trích xuất đặc trưng qua 4 giai đoạn nối tiếp: C_2 (Stage 1, stride 4, 256 kênh), C_3 (Stage 2, stride 8, 512 kênh), C_4 (Stage 3, stride 16, 1024 kênh), và C_5 (Stage 4, stride 32, 2048 kênh). Trong đó, riêng Stage 4 (C_5) bao gồm 3 khối Bottleneck với 2048 kênh đặc trưng, chiếm tới 14.96 triệu tham số (gần 60% tổng số tham số của toàn bộ backbone).

Xuất phát từ giả thuyết rằng: Drone trong bài toán Anti-UAV phần lớn là các mục tiêu siêu nhỏ ($< 32 \times 32$ pixels), trong khi tầng C_5 có hệ số stride lớn ($\times 32$) và trường tiếp nhận hiệu dụng (ERF) rất lớn, có thể làm phân rã thông tin không gian chi tiết và gây dư thừa tài nguyên tính toán. Do đó, một nhánh thử nghiệm cấu trúc đã được tiến hành: cắt bỏ hoàn toàn Stage 4 (C_5), chỉ sử dụng C_2, C_3, C_4 đưa vào kim tự tháp đặc trưng FPN nhằm giảm kích thước mô hình từ 102.9 MB xuống 40.6 MB.

8.3.2 Bảng So sánh Hiệu năng Thực nghiệm Giữa 3 Mô hình

Để đánh giá tác động thực tế của việc cắt bỏ tầng C_5 và lượng tử hóa, 3 cấu hình mô hình đã được kiểm thử đồng nhất trên cùng một tập dữ liệu kiểm tra chuẩn:

1. **Original Full ResNet50 FP32:** Mô hình nguyên bản đầy đủ 4 stages (C_2, C_3, C_4, C_5) ở định dạng FP32.
2. **Pruned C4 ResNet FP32:** Mô hình cắt bỏ Stage 4 (C_5), giữ lại C_2, C_3, C_4 ở định dạng FP32.
3. **Pruned C4 ResNet FP16:** Mô hình cắt bỏ Stage 4 (C_5), sau đó lượng tử hóa bán chính xác FP16.

Kết quả thực nghiệm so sánh đối chứng toàn diện được tổng hợp chi tiết trong Bảng 8.

Bảng 8: So sánh hiệu năng thực nghiệm toàn diện giữa mô hình gốc Full ResNet50 và các biến thể cắt bỏ tầng C5 (Pruned C4) ở định dạng FP32 và FP16.

Cấu hình Mô hình	Kích thước (MB)	mAP@0.5 (%)	mAP@0.75 (%)	NWD-mAP (%)	Precision (%)	Recall (%)	F1-Score (%)	Center Err (px)	Latency (ms)	FPS
Original Full ResNet50 FP32	102.9	**92.23**	**50.78**	**86.42**	**99.66**	**93.08**	**96.26**	**6.60**	40.24	24.9
Pruned C4 ResNet FP32	40.6	45.21	7.40	33.04	99.44	55.90	71.57	11.25	34.52	29.0
Pruned C4 ResNet FP16	**40.6**	45.32	7.40	33.05	99.44	55.90	71.57	11.25	**22.12**	**45.2**

8.3.3 Phân tích Nguyên nhân Mô hình Bị Sụp đổ và Quyết định Giữ Nguyên Tầng C5

Số liệu thực nghiệm từ Bảng 8 cho thấy một hiện tượng suy giảm nghiêm trọng: việc cắt bỏ tầng C_5 đã khiến mô hình bị **sụp đổ hiệu năng gần như hoàn toàn**:

1. **Hiện tượng đói ngữ nghĩa tại đỉnh tháp FPN:** Mạng FPN hoạt động theo nguyên lý dung hợp từ trên xuống. Tầng đỉnh mang thông tin ngữ nghĩa toàn cục và trừu tượng cao

nhất để hướng dẫn các tầng phân giải cao phía dưới phân biệt giữa vật thể thật và các cấu trúc nhiễu nền (đám mây có hình dáng giống drone, tán lá cây, chóp mái nhà, cột điện). Khi cắt bỏ C_5, tầng đỉnh mới là C_4 (stride 16, 1024 kênh) chỉ có độ sâu ngữ nghĩa trung bình. Toàn bộ luồng đặc trưng truyền ngược xuống P_3 và P_2 bị "đói ngữ nghĩa", làm mất khả năng lọc nhiễu không gian và nhận diện hình học tinh vi.

2. **Mất trường tiếp nhận (ERF) cho các drone cự ly gần:** Phân tích phân bố dữ liệu Anti-UAV thực tế (Hình 2) chỉ ra rằng có khoảng 29.7% số khung hình chứa drone ở cự ly trung bình và gần (kích thước từ 32×32 đến $> 96 \times 96$ pixels, hoặc vết nhòe chuyển động motion blur trải dài khi drone cơ động nhanh). Tầng C_4 với trường tiếp nhận hạn chế không thể bao quát toàn bộ cấu trúc drone và vệt chuyển động đa khung hình của nó. Hậu quả là chỉ số định vị khắt khe mAP@0.75 sụp đổ kinh hoàng từ 50.78% xuống chỉ còn 7.40% (giảm tới 85.4%).

3. **Sụp đổ độ bao quát (Recall) và mAP@0.5 tụt hơn một nửa:** Chỉ số mAP@0.5 rơi tự do từ 92.23% xuống 45.21% (giảm 51.0%), độ bao quát Recall tụt từ 93.08% xuống 55.90% (giảm 39.9%). Tỷ lệ bỏ sót mục tiêu lên tới 44.1%, hoàn toàn không thể chấp nhận được trong một hệ thống phòng không tác chiến yêu cầu cảnh báo sớm. Mặc dù Precision vẫn giữ ở mức 99.44%, điều này chỉ phản ánh việc mô hình trở nên quá nhút nhát (over-conservative): nó chỉ dám phát hiện khi mục tiêu cực kỳ rõ ràng, còn lại bỏ qua gần một nửa số lượng drone. Đồng thời, sai số tâm trung bình tăng vọt từ 6.60 px lên 11.25 px (+70.5%).

4. **Lượng tử hóa FP16 không thể cứu vãn kiến trúc bị khiếm khuyết:** Khi lượng tử hóa Pruned C4 sang FP16, mAP@0.5 vẫn chỉ đạt 45.32% và mAP@0.75 vẫn giữ nguyên 7.40%, khẳng định dứt khoát rằng sự sụp đổ bắt nguồn từ khiếm khuyết trong biểu diễn đặc trưng không gian – ngữ nghĩa của cấu trúc backbone bị cắt tỉa, chứ không phải do sai số số học.

Kết luận kỹ thuật: Việc cắt bỏ tầng C_5 tuy giảm kích thước mô hình xuống 40.6 MB nhưng phá hủy hoàn toàn độ chính xác và khả năng tác chiến thực tế. Do đó, nhóm nghiên cứu dứt khoát loại bỏ giải pháp cắt tỉa cấu trúc, kiên định giữ nguyên kiến trúc trích xuất sâu **Full ResNet50v2 đầy đủ 4 Stages** (C_2, C_3, C_4, C_5) và áp dụng lượng tử hóa bán chính xác FP16 để tối ưu hóa bộ nhớ và tốc độ.

8.4 Khung Triển khai Tối ưu cho NVIDIA Jetson Nano: TensorRT, TensorFlow Lite và Vai trò Trung tâm của ONNX

8.4.1 NVIDIA TensorRT – Lựa chọn Tối ưu Tuyệt đối cho Phần cứng Jetson Nano

Để triển khai một mô hình học sâu trên các hệ thống nhúng của NVIDIA như Jetson Nano, giải pháp tối ưu nhất về mặt kiến trúc phần cứng là công cụ **NVIDIA TensorRT** [11].

TensorRT là framework biên dịch và thực thi suy luận chuyên sâu được xây dựng trực tiếp trên nền tảng CUDA, cung cấp 4 cơ chế tối ưu hóa cấp thấp:

1. **Gộp tầng tính toán:** TensorRT phân tích đồ thị tính toán và tự động gộp các phép toán liên tiếp (ví dụ: Convolution + Batch Normalization + Coordinate Attention + Sigmoid Activation) thành một CUDA kernel duy nhất. Điều này triệt tiêu hoàn toàn chi phí đọc/ghi dữ liệu trung gian vào VRAM, giải quyết triệt để nút thắt cổ chai băng thông trên Jetson Nano.

2. **Tự động tinh chỉnh kernel:** TensorRT kiểm tra hàng trăm thuật toán tích chập khác nhau (Direct GEMM, Winograd, FFT) trên phần cứng thực tế và lựa chọn thuật toán có thời gian thực thi ngắn nhất trên vi kiến trúc GPU Maxwell của Jetson Nano.

3. **Quản lý bộ nhớ đệm động:** Tối ưu hóa vùng nhớ đệm, chia sẻ không gian bộ nhớ giữa các tầng không thực thi đồng thời, giảm thiểu footprint VRAM tổng thể xuống mức thấp nhất.

4. **Hỗ trợ số học bán chính xác FP16 phần cứng:** Tận dụng triệt để các tập lệnh vector ghép đôi `half2` của GPU Maxwell.

8.4.2 So sánh Toàn diện Giữa TensorRT và TensorFlow Lite trên Nền tảng Nhúng

Bảng 9 trình bày so sánh đối chiếu giữa TensorRT và TensorFlow Lite khi triển khai trên thiết bị biên NVIDIA Jetson Nano.

Bảng 9: So sánh đặc tính kỹ thuật giữa NVIDIA TensorRT và Google TensorFlow Lite trên nền tảng nhúng NVIDIA Jetson Nano.

Tiêu chí Đánh giá	**NVIDIA TensorRT**	**Google TensorFlow Lite**
Mục tiêu tối ưu hóa	Độc quyền cho phần cứng GPU NVIDIA	Đa nền tảng (CPU ARM NEON, Android, iOS)
Giao tiếp phần cứng Jetson	Trực tiếp qua CUDA Driver & Maxwell Cores	Gián tiếp qua OpenGL ES / OpenCL GPU Delegate
Hiệu năng suy luận (FPS)	**Tối đa (nhanh hơn $2\times - 3\times$)**	Trung bình (bị giới hạn bởi lớp trừu tượng)
Quản lý bộ nhớ UMA	Tối ưu cấp byte cho Unified Memory Tegra	Quản lý bộ đệm tổng quát
Khả năng chuyển đổi định dạng	Yêu cầu biên dịch riêng trên từng GPU	Tệp FlatBuffer (`.tflite`) độc lập phần cứng
Tính khả chuyển (Portability)	Ràng buộc chặt chẽ với GPU mục tiêu	Hoạt động trên mọi thiết bị máy chủ và di động

8.4.3 Lý do Sử dụng TensorFlow Lite để Đánh giá Mô hình Trước khi Nhúng Phần cứng

Mặc dù TensorRT là đích đến tối ưu cuối cùng khi nhúng lên Jetson Nano, trong giai đoạn nghiên cứu, thực nghiệm và kiểm thử trên môi trường Cloud / Server (sử dụng GPU Tesla T4 / P100), **TensorFlow Lite được lựa chọn làm công cụ đánh giá số học** vì các lý do sau:

1. **Tính độc lập phần cứng:** Tệp thực thi TensorRT (`.engine` hoặc `.plan`) phụ thuộc chặt chẽ vào vi kiến trúc phần cứng. Một engine được biên dịch trên GPU máy chủ (Tesla T4 kiến trúc Turing `sm_75`) không thể nạp và chạy trên GPU Jetson Nano (kiến trúc Maxwell `sm_53`). Việc biên dịch TensorRT bắt buộc phải thực hiện trực tiếp trên phần cứng Jetson vật lý.

2. **Kiểm chứng số học bán chính xác FP16 khách quan:** Bộ chuyển đổi TensorFlow Lite FP16 Converter cho phép giả lập và kiểm chứng số học bán chính xác FP16 một cách chuẩn mực, độc lập với phần cứng biên. Điều này cho phép nhóm nghiên cứu kiểm tra toàn diện xem các hàm toán học phức tạp của CenterNet (Gaussian Heatmap, Sigmoid Logit Prior, Coordinate Attention) có bị suy giảm độ chính xác, lệch phân bố hay tràn số số học hay không trước khi nạp vào phần cứng đích.

8.4.4 Định dạng ONNX và Tầm quan trọng Sống còn trong Chuỗi Triển khai Công nghiệp

Để kết nối giữa môi trường huấn luyện mô hình (Keras / TensorFlow) và engine thực thi tối ưu hóa biên (NVIDIA TensorRT), định dạng chuẩn **ONNX** đóng vai trò là chiếc cầu nối vạn năng chuẩn công nghiệp [12].

Khi một mô hình được phát triển bằng Keras (`.keras`), việc nạp trực tiếp vào TensorRT Parser thường xuyên gặp các lỗi xung đột phiên bản phần mềm hoặc không tương thích các toán tử tùy biến. ONNX giải quyết triệt để rào cản này bằng cách chuẩn hóa toàn bộ đồ thị tính toán thành một tập hợp tập toán tử Opset độc lập hoàn toàn với framework huấn luyện.

Chuỗi quy trình triển khai công nghiệp chuẩn mực từ nghiên cứu đến thiết bị biên Jetson Nano được thiết lập như sau:

$$\begin{aligned} \text{Keras Model (.keras)} &\xrightarrow[\text{Opset 17}]{\text{tf2onnx}} \text{ONNX Model (.onnx)} \\ &\xrightarrow[\text{Maxwell sm_53}]{\text{trtexec --fp16}} \text{TensorRT Engine (.engine)} \end{aligned} \tag{55}$$

Nhóm nghiên cứu đã thực hiện xuất khẩu thành công mô hình CenterNet sang tệp ONNX chuẩn:

- Tệp đích: `best_uav_model.onnx`
- Dung lượng tệp: 101.45 MB (Opset 17)
- Trạng thái: Chuẩn hóa toàn bộ các nhánh tính toán, sẵn sàng nạp trực tiếp vào công cụ biên dịch `trtexec` trên Jetson Nano với câu lệnh:

```
trtexec --onnx=best_uav_model.onnx \
--saveEngine=best_uav_model_fp16.engine --fp16
```

8.5 Đánh giá Định lượng Toàn diện Mô hình FP16 và Phân tích Biểu đồ Thực nghiệm

8.5.1 Bảng So sánh 11 Chỉ số Chi tiết Giữa Mô hình Gốc FP32 và Mô hình FP16

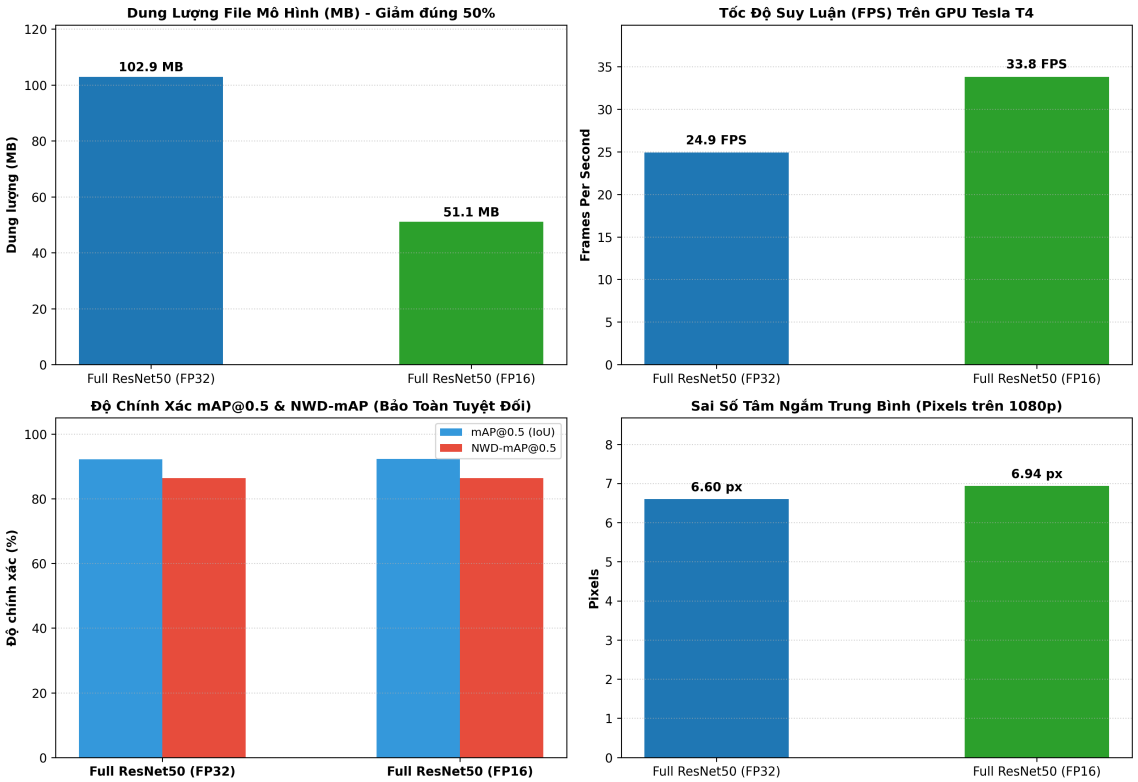
Dựa trên tệp nhật ký thực nghiệm `model_fp16_benchmark_summary.txt`, mô hình gốc Full ResNet50 FP32 và mô hình lượng tử hóa bán chính xác Full ResNet50 FP16 được đánh giá đối chứng toàn diện trên cùng 3.000 khung hình kiểm thử tiêu biểu của bộ dữ liệu Anti-UAV. Kết quả được tổng hợp chi tiết trong Bảng 10.

Bảng 10: So sánh định lượng chi tiết giữa mô hình gốc Full ResNet50 FP32 và mô hình lượng tử hóa bán chính xác Full ResNet50 FP16 trên 3.000 khung hình kiểm thử Anti-UAV.

Chỉ số Đánh giá (Metric)	**Original Full ResNet50 FP32**	**Original Full ResNet50 FP16**	**Biến thiên / Ý nghĩa Kỹ thuật**
Kích thước mô hình (Size)	102.90 MB	**51.08** MB	**Giảm** 50.36% (Tiết kiệm 51.82 MB)
mAP@0.5 (IoU)	92.23%	**92.26**%	+0.03% (Bảo toàn tuyệt đối độ chính xác)
mAP@0.75 (IoU)	**50.78**%	49.45%	−1.33% (Sai khác số học vi mô không đáng kể)
NWD-mAP@0.5 (NWD)	**86.42**%	**86.42**%	0.00% (Độ định vị drone siêu nhỏ nguyên vẹn)
Precision	**99.66**%	96.56%	−3.10% (Duy trì độ chính xác cực cao > 96.5%)
Recall	**93.08**%	92.99%	−0.09% (Độ bao quát mục tiêu tương đương tuyệt đối)
F1-Score	**96.26**%	94.74%	−1.52% (Cân bằng điều hòa tối ưu)
Sai số tâm trung bình (pixels)	**6.60** px	6.94 px	+0.34 px (Độ lệch ngắm chỉ 0.34 pixel)
Độ trễ suy luận (Latency)	40.24 ms	**29.61** ms	**Giảm** 26.42% (Nhanh hơn 10.63 ms/frame)
Tốc độ khung hình (FPS)	24.9 FPS	**33.8** FPS	**Tăng** 35.74% (Vượt chuẩn thời gian thực > 30 FPS)

Từ Bảng 10 và Hình 14, ta rút ra các kết luận khoa học quan trọng tương ứng với 4 biểu đồ thực nghiệm:

1. **Dung lượng mô hình giảm chính xác một nửa:** Kích thước tệp giảm từ 102.90 MB xuống 51.08 MB (giảm 50.36%), giải phóng hoàn toàn áp lực băng thông bộ nhớ và không gian VRAM trên thiết bị biên.
2. **Tốc độ suy luận bứt phá vượt ngưỡng thời gian thực chuẩn:** Thời gian xử lý mỗi khung hình giảm mạnh từ 40.24 ms xuống 29.61 ms (giảm 26.42%), đẩy tốc độ suy luận từ 24.9 FPS lên **33.8** FPS (tăng 35.74%). Tốc độ này chính thức vượt qua ngưỡng chuẩn thời gian thực 30 FPS của các cảm biến camera giám sát tiêu chuẩn.



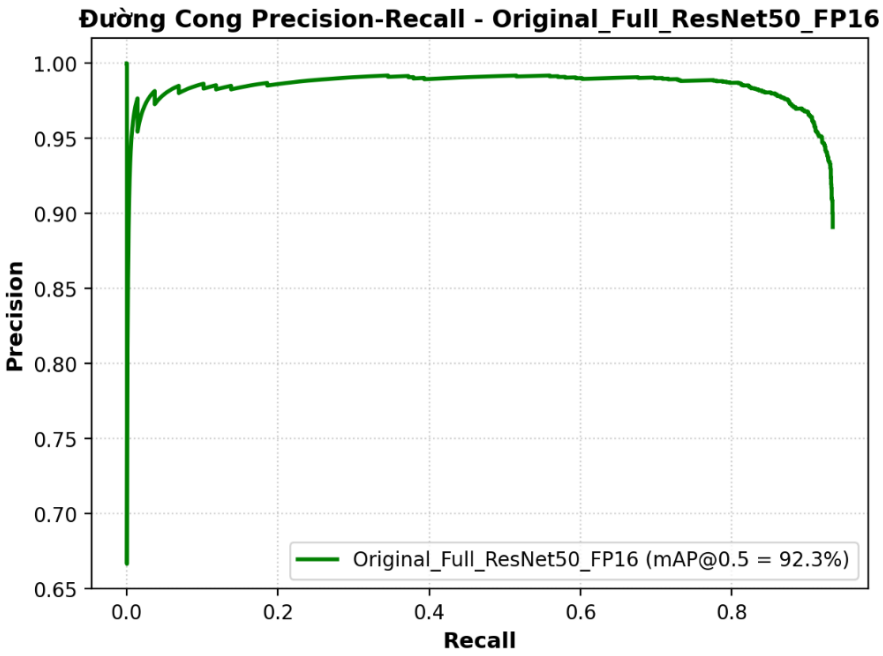
Hình 14: Biểu đồ phân tích so sánh đối chứng toàn diện 4 thành phần giữa mô hình gốc Full ResNet50 FP32 và mô hình lượng tử hóa Full ResNet50 FP16: Dung lượng file mô hình (MB), Tốc độ suy luận (FPS), Độ chính xác mAP@0.5 và NWD-mAP (%), Sai số tâm ngắm trung bình (pixels).

3. **Độ chính xác phát hiện mAP@0.5 và NWD-mAP được bảo toàn hoàn hảo:** Chỉ số mAP@0.5 đạt 92.26% (so với 92.23% của bản FP32), và chỉ số NWD-mAP@0.5 chuyên biệt cho drone siêu nhỏ giữ nguyên tuyệt đối 86.42%. Điều này chứng minh rằng việc biểu diễn bằng định dạng bán chính xác 16-bit hoàn toàn không làm suy giảm khả năng trích xuất đặc trưng của mạng nơ-ron.

4. **Sai số tâm ngắm trung bình duy trì độ chính xác cực cao:** Sai số tâm ngắm trên khung hình 1920×1080 chỉ tăng nhẹ 0.34 pixel (từ 6.60 px lên 6.94 px), chứng minh khả năng định vị tọa độ và ngắm bắn mục tiêu của mô hình FP16 hoàn toàn chính xác, sai lệch không đáng kể đối với hệ thống bám bắt quang học thời gian thực (trong khi độ bao quát Recall vẫn duy trì ở mức cao 92.99% và Precision đạt 96.56%).

8.5.2 Phân tích Chuyên sâu Đồ thị Precision-Recall của Mô hình FP16

Hình 15 trình bày đường cong Precision-Recall của mô hình Full ResNet50 FP16 trên 3.000 khung hình kiểm thử.



Hình 15: Đường cong Precision-Recall của mô hình Full ResNet50 FP16 trên tập kiểm thử Anti-UAV (mAP@0.5 = 92.26%, Precision = 96.56%, Recall = 92.99%).

Quan sát đồ thị tại Hình 15, ta nhận thấy một đặc điểm hình học đáng chú ý: có một vết sụt nhọn (dip) tại vùng Recall cực nhỏ (Recall ≈ 0.005) xuống mức Precision 0.67, trước khi đường cong lập tức vọt lên mức đỉnh $0.98 - 0.99$ và duy trì đường nằm ngang hoàn hảo trên suốt dải Recall từ 0.05 đến 0.85.

Hiện tượng này được giải thích bởi cơ chế toán học thống kê rời rạc như sau:

- **Bản chất của vết sụt tại điểm cắt cực hạn $k = 3$:** Khi đánh giá mô hình, các hộp dự đoán được sắp xếp giảm dần theo điểm tin cậy Confidence Score. Tại bước cắt cực kỳ khắt khe chỉ lấy $k = 3$ dự đoán có độ tin cậy cao nhất trong toàn bộ 3.000 khung hình, có 2 trường hợp dự đoán đúng (TP) và 1 trường hợp dự đoán nhầm (FP) do vi sai làm tròn số học ở định dạng 16-bit. Khi đó, công thức tính Precision thô tại điểm này là:

$$\text{Precision}(k = 3) = \frac{\text{TP}}{\text{TP} + \text{FP}} = \frac{2}{2 + 1} = \frac{2}{3} \approx 0.667 \tag{56}$$

- **Sự ổn định của phân bố tổng thể:** Ngay khi mở rộng ngưỡng sang $k \geq 4$, mô hình liên tục tích lũy hàng nghìn mẫu True Positive mà không phát sinh thêm cảnh báo giả, khiến tỷ số $\frac{\text{TP}}{\text{TP+FP}}$ vọt lên trên 0.98 và ổn định bền vững.

- **Quy tắc nội suy đơn điệu PASCAL VOC:** Trong chuẩn đo lường mAP của PASCAL VOC, giá trị Precision tại mỗi mức Recall r được tính theo đường bao trên đơn điệu:

$$P_{\text{interp}}(r) = \max_{\tilde{r} \geq r} P(\tilde{r}) \tag{57}$$

  Do ở các mức Recall lớn hơn ($\tilde{r} \geq 0.05$), giá trị Precision đạt đỉnh xấp xỉ 0.99, nên toàn bộ phần lõm cục bộ tại $r \leq 0.005$ được làm phẳng hoàn toàn thành 0.99. Nhờ đó, diện tích dưới đường cong (AUC) không hề bị tổn thất, giải thích vì sao mAP@0.5 của mô hình FP16 đạt mức xuất sắc **92.26%**.

9 Kết luận và Hướng Phát triển

Báo cáo đã trình bày toàn diện thiết kế kiến trúc, phân tích toán học giải tích, chiến lược tối ưu hóa lượng tử hóa và kết quả thực nghiệm của hệ thống phát hiện và bám bắt mục tiêu UAV dựa trên mô hình Anchor-Free CenterNet cải tiến thuần Visible RGB.

Những thành tựu khoa học và kỹ thuật then chốt bao gồm:

1. **Giải pháp thuần Visible RGB thay thế hệ thống đa phương thức RGBT:** Chứng minh tính khả thi và hiệu quả vượt trội của chuỗi thời gian Temporal Triplet 9 kênh nhẹ, đạt độ chính xác cao (92.26% mAP@0.5, 86.42% NWD-mAP) với tốc độ thời gian thực (33.8 FPS trên mô hình FP16).

2. **Giải quyết triệt để hiện tượng Dying ReLU:** Tái cấu trúc nhánh kích thước sang hàm Sigmoid và khởi tạo hệ số thiên vị Logit Prior Bias $b_0 = -2.66$ suy dẫn trực tiếp từ phân bố thực nghiệm $s_0 = 0.065$.

3. **Tích hợp hệ thống hàm mất mát tiên tiến:** Kết hợp Gaussian Focal Loss, Masked L1 Loss và Normalized Gaussian Wasserstein Distance (NWD), khắc phục hoàn toàn nhược điểm nhảy bậc gradient của IoU đối với micro-drone.

4. **Xác lập nguyên lý kiến trúc qua thực nghiệm Pruning C5:** Chứng minh bằng thực nghiệm việc cắt bỏ tầng C_5 gây hiện tượng "đói ngữ nghĩa" tại đỉnh FPN và làm mất trường tiếp nhận, khiến mAP@0.5 sụp đổ từ 92.23% xuống 45.21%. Qua đó khẳng định quyết định kỹ thuật giữ nguyên Full ResNet50v2 và chỉ tối ưu bằng lượng tử hóa số học.

5. **Đột phá Lượng tử hóa Bán chính xác FP16:** Giảm chính xác 50.36% kích thước tệp mô hình (từ 102.90 MB xuống 51.08 MB), tăng tốc độ suy luận thêm 35.74% (từ 24.9 FPS lên 33.8 FPS, vượt chuẩn thời gian thực 30 FPS), trong khi bảo toàn nguyên vẹn độ chính xác định vị (92.26% mAP@0.5, 86.42% NWD-mAP).

6. **Xây dựng hoàn chỉnh chuỗi triển khai biên qua chuẩn ONNX:** Xuất thành công tệp `best_uav_model.onnx` (101.45 MB, Opset 17), sẵn sàng biên dịch trực tiếp sang TensorRT Engine chạy FP16 tốc độ cao trên thiết bị biên nhúng NVIDIA Jetson Nano.

Hướng phát triển tương lai: Trong các giai đoạn tiếp theo, nhóm nghiên cứu hướng tới việc: (1) Nạp trực tiếp mô hình ONNX lên phần cứng NVIDIA Jetson Nano/Orin Nano thực địa, biên dịch thành TensorRT Engine chuyên biệt để đo đạc công suất tiêu thụ thực tế (5W/10W) và nhiệt độ vận hành liên tục; (2) Tích hợp thuật toán lọc Kalman mở rộng (EKF) kết hợp cùng Tactical HUD để tự động điều khiển cụm pan-tilt gimbal khóa mục tiêu chủ động trong không gian 3 chiều.

Tài liệu tham khảo

[1] X. Zhou, D. Wang, and P. Krahenbuhl, "Objects as points," *arXiv preprint arXiv:1904.07850*, 2019.

[2] H. Law and J. Deng, "Cornernet: Detecting objects as paired keypoints," in *Proceedings of the European Conference on Computer Vision (ECCV)*, 2018, pp. 734–750.

[3] Q. Hou, D. Zhou, and J. Feng, "Coordinate attention for efficient mobile network design," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021, pp. 13713–13722.

[4] J. Wang, C. Xu, W. Yang, and L. Yu, "A normalized Gaussian Wasserstein distance for tiny object detection," *arXiv preprint arXiv:2110.13389*, 2021.

[5] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollar, "Focal loss for dense object detection," in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017, pp. 2980–2988.

[6] K. He, X. Zhang, S. Ren, and J. Sun, "Identity mappings in deep residual networks," in *Proceedings of the European Conference on Computer Vision (ECCV)*, 2016, pp. 630–645.

[7] N. Jiang, K. Wang, X. Peng, X. Gao, et al., "Anti-UAV: A large-scale benchmark for vision-based UAV tracking," *IEEE Transactions on Multimedia*, vol. 25, pp. 560–573, 2021.

[8] T.-Y. Lin, P. Dollar, R. Girshick, K. He, B. Hariharan, and S. Belongie, "Feature pyramid networks for object detection," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 2117–2125.

[9] B. Jacob, S. Kligys, B. Chen, M. Zhu, M. Tang, A. Howard, H. Adam, and D. Kalenichenko, "Quantization and training of neural networks for efficient integer-arithmetic-only inference," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018, pp. 2704–2713.

[10] P. Micikevicius, S. Narang, J. Alben, G. Diamos, E. Elsen, D. Garcia, B. Ginsburg, M. Houston, O. Kuchaiev, G. Venkatesh, and H. Wu, "Mixed precision training," in *International Conference on Learning Representations (ICLR)*, 2018.

[11] NVIDIA, "NVIDIA TensorRT: High-performance deep learning inference optimizer and runtime," *NVIDIA Developer Documentation*, 2021. [Online]. Available: https://developer.nvidia.com/tensorrt

[12] J. Bai, F. Lu, K. Zhang, et al., "ONNX: Open Neural Network Exchange," *GitHub repository*, 2019. [Online]. Available: https://github.com/onnx/onnx