

MÔ HÌNH PHÁT HIỆN VÀ BẮM BẮT MỤC TIÊU UAV DỰA TRÊN KIẾN TRÚC ANCHOR-FREE CENTERNET

*Deep Multi-Scale Spatio-Temporal Feature Fusion with Coordinate Attention for
Micro-Drone Interception*

Nguyễn Thành Nam 24130222

Ngày 2 tháng 10 năm 2026

Tóm tắt nội dung

Phát hiện và bám bắt các phương tiện bay không người lái (UAV) có kích thước siêu nhỏ, di chuyển với vận tốc lớn trong không gian bầu trời phức tạp là một bài toán then chốt trong lĩnh vực an ninh quốc phòng và kiểm soát vùng trời tầm thấp. Các giải pháp truyền thống chủ yếu dựa vào hệ thống đa phương thức RGBT kết hợp cảm biến hồng ngoại (IR), song gặp phải rào cản lớn về chi phí phần cứng quang học cao, độ lệch hiệu chuẩn không gian – thời gian giữa hai camera và dung lượng bộ nhớ khổng lồ.

Báo cáo này trình bày thiết kế và triển khai hoàn chỉnh một hệ thống **CenterNet Anchor-Free thuần Visible RGB** giải quyết triệt để các hạn chế trên. Mô hình tích hợp: (1) Chuỗi đầu vào thời gian *Temporal Triplet* 9 kênh (I_{t-1}, I_t, I_{t+1}) nắm bắt tức thời vector vận tốc mà không cần tính toán Optical Flow; (2) Mạng kim tự tháp đặc trưng độ phân giải cao *P2-FPN* kết hợp cơ chế chú ý định hướng không gian *Coordinate Attention*; (3) Đột phá giải quyết triệt để hiện tượng *Dying ReLU* bằng cách tái cấu trúc nhánh kích thước sang hàm kích hoạt *Sigmoid* kết hợp *Khởi tạo Phân phối Tiên nghiệm Logit Prior Initialization* ($b_0 = -2.66$ suy dẫn từ giá trị thực nghiệm $s_0 = 0.065$); và (4) Hệ thống hàm mất mát đa nhiệm tối ưu kết hợp *Gaussian Focal Loss*, *Masked L1 Loss* và *Normalized Gaussian Wasserstein Distance (NWD)*.

Thực nghiệm trên bộ dữ liệu Anti-UAV chuẩn qua 9 epoch trên GPU Tesla P100 minh chứng sự hội tụ vượt bậc: Total Loss giảm 81.8% ($3.2777 \rightarrow 0.5959$). Đánh giá độc lập trên 3.000 frames kiểm thử tiêu biểu với ngưỡng tin cậy $\text{Conf} \geq 0.4$ ghi nhận: Precision đạt đỉnh **99.85%** (triệt tiêu gần như hoàn toàn báo động giả), Recall đạt **69.12%**, F1-Score đạt **81.69%**, mAP@0.5 đạt **76.31%**, NWD-mAP cho drone nhỏ đạt **63.84%**, sai số tâm trung bình chỉ **4.17 pixels** và tốc độ suy luận đạt **21.4 FPS** trên GPU (thời gian xử lý 2.34 phút cho 3.000 frames), đáp ứng trọn vẹn yêu cầu tác chiến thời gian thực.

Từ khóa: Anti-UAV, Anchor-Free CenterNet, Temporal Triplet, Coordinate Attention, Dying ReLU, Logit Prior, Normalized Gaussian Wasserstein Distance (NWD), Tactical HUD.

Mục lục

1	Giới thiệu và Đặt vấn đề Nghiên cứu	3
1.1	Bối cảnh và Thách thức Tác chiến	3
1.2	Hạn chế của Hệ thống Đa Phương Thức RGBT Truyền Thống và Quyết định Chuyển hẳn sang Thuần Visible RGB	3
1.3	Đóng góp Cốt lõi của Công trình	4
2	Phân tích Bộ Dữ liệu và Quy trình Tiền xử lý Chuỗi Không – Thời gian	6
2.1	Thống kê Bộ Dữ liệu Video Ban đầu Anti-UAV (Visible RGB Stream)	6
2.2	Tiền xử lý Chuỗi Thời gian và Tạo Tập Dữ liệu Chuẩn Pascal VOC (Temporal Triplet)	6
2.3	Phân bố Quy mô Đối tượng và Xác lập Phân phối Tiền nghiệm Logit Prior	6
2.4	Bảng So sánh Đối chiếu Toàn diện giữa Dữ liệu Thô và Dữ liệu Sau Xử lý	7
3	Kiến trúc Mạng Nơ-ron Đa Tỷ lệ Không – Thời gian	7
3.1	Bộ ba Khung hình Thời gian (Temporal Triplet)	7
3.2	Khung Trích xuất Đặc trưng ResNet-50v2 Pre-activation	8
3.3	Feature Pyramid Network P2-FPN Đa Tỷ Lệ	9
3.4	Cơ chế Chú ý Tọa độ (Coordinate Attention Mechanism)	10
4	Phân tích Toán học và Đột phá Khắc phục Hiện tượng Dying ReLU	12
4.1	Cơ chế CenterNet Gốc và Nguy cơ Sụp đổ Gradient	12
4.2	Đột phá: Hàm Kích hoạt Sigmoid và Khởi tạo Phân phối Tiền nghiệm Logit Prior	12
4.3	Suy dẫn Giải tích Hệ số Bias $b_0 = -2.66$ từ Thực nghiệm $s_0 = 0.065$	13
5	Thiết lập Hệ thống Hàm Mất Mát Đa Nhiệm Tối Ưu	14
5.1	Gaussian Focal Loss cho Heatmap Điểm Tâm	14
5.2	Masked Sub-pixel Offset L1 Loss	15
5.3	Đột phá: Normalized Gaussian Wasserstein Distance (NWD) cho Đối tượng Siêu Nhỏ	15
6	Thuật toán Hậu Xử lý và Bám bắt Quỹ đạo Thời gian thực	17
6.1	Local Maximum Decoding không dùng NMS (NMS-Free Decoding)	17
6.2	Bộ lọc Quỹ đạo Quán tính Trajectory EMA Filter	18
7	Thực nghiệm và Đánh giá Định lượng	18
7.1	Thiết lập Môi trường Phần cứng và Siêu tham số Huấn luyện	18
7.2	Động thái Hội tụ qua 9 Epochs Huấn luyện	18
7.3	Kết quả Đánh giá Định lượng Benchmark	19
7.4	Phân tích Trực quan Hóa Định tính	22
8	Kết luận và Hướng Phát triển	23

1 Giới thiệu và Đặt vấn đề Nghiên cứu

1.1 Bối cảnh và Thách thức Tác chiến

Sự phát triển bùng nổ của các phương tiện bay không người lái dân sự và quân sự quy mô nhỏ (micro-UAVs, FPV Drones) đã và đang làm thay đổi căn bản học thuyết tác chiến phi đối xứng cũng như an ninh không phận tầm cực thấp. Với chi phí chế tạo thấp, khả năng cơ động đa hướng linh hoạt và trần bay bám sát địa hình (terrain-following flight), micro-UAV trở thành mối đe dọa thường trực đối với các công trình quân sự, sân bay và hạ tầng trọng yếu.

Trước các mục tiêu này, các hệ thống phòng không truyền thống bộc lộ những lỗ hổng lớn:

- (i) **Vô hiệu hóa cảm biến radar:** Do kích thước vật lý nhỏ gọn (sải cánh dưới 50 cm) cùng cấu tạo chủ yếu từ vật liệu phi kim (carbon fiber, nhựa polymer), diện tích phản xạ hiệu dụng radar (Radar Cross Section – RCS) của micro-UAV thường nhỏ hơn 0.01 m^2 , chìm sâu dưới ngưỡng phát hiện của radar cảnh giới tầm xa.
- (ii) **Hạn chế của cảm biến âm thanh và vô tuyến:** Phương thức thụ động bắt sóng điều khiển vô tuyến (RF scanning) dễ dàng bị khắc chế khi UAV hoạt động ở chế độ tự hành theo hải trình định vị GNSS hoặc khi bị đối kháng chế áp điện tử mạnh; trong khi cảm biến âm học bị giới hạn cự ly nghiêm trọng và suy hao nhanh trong môi trường tiếng ồn đô thị.

Do đó, **trình sát và cảnh giới quang học (Electro-Optical/EO Surveillance)** đóng vai trò tuyến phòng thủ trực quan và tin cậy nhất. Tuy nhiên, việc phát hiện và bám bắt tự động micro-UAV trên luồng ảnh quang học đối mặt với các thách thức khốc liệt:

- **Quy mô mục tiêu siêu nhỏ (Tiny Object Detection):** Ở cự ly chiến thuật trên 100 m, drone chỉ chiếm từ vài điểm ảnh đến vài chục điểm ảnh ($< 32^2$ px, chiếm dưới 0.4% diện tích khung hình Full HD 1920×1080). Mục tiêu hoàn toàn thiếu các đặc trưng kết cấu bề mặt, hoa văn hoặc ngữ nghĩa chiều sâu, rất dễ bị suy biến và tiêu biến qua các tầng tích chập sâu của mạng nơ-ron.
- **Nhiều nền không gian và quang sai môi trường phức tạp:** Khung cảnh tác chiến trên không thường xuyên xuất hiện mây trời chuyển động, ánh nắng chói lóa (sun flare), các dị vật tự nhiên (chim chóc, lá cây bay) hoặc hậu cảnh mặt đất nhiều nhà cao tầng, cột ăng-ten, gây ra tỷ lệ cảnh báo giả (false alarm) cực kỳ cao nếu chỉ dựa vào phát hiện đơn khung hình tĩnh.
- **Động học cơ động phi tuyến và gia tốc góc lớn:** UAV có thể thực hiện các động tác nhào lộn, tăng tốc tức thời, thay đổi quỹ đạo đột ngột và rơi vào trạng thái che khuất tạm thời (occlusion) sau vật cản, gây đứt gãy vết bám của các thuật toán theo dõi truyền thống.
- **Áp lực độ trễ thời gian thực (Real-time Constraints):** Để phục vụ chỉ thị mục tiêu và kích hoạt các biện pháp áp chế hỏa lực/chế áp mềm, toàn bộ quy trình phát hiện và bám bắt bắt buộc phải đạt tần số trên 20 khung hình/giây (FPS) với độ trễ thấp trên phần cứng xử lý thực địa.

1.2 Hạn chế của Hệ thống Đa Phương Thức RGBT Truyền Thống và Quyết định Chuyển hẳn sang Thuần Visible RGB

Để bù đắp sự thiếu hụt đặc trưng thị giác khi drone ở cự ly xa, nhiều nghiên cứu trước đây đã tiếp cận bài toán thông qua hệ thống cảm biến đa phổ Visible – Infrared (RGBT), tích hợp luồng ảnh quang học thông thường với luồng ảnh hồng ngoại nhiệt (Thermal IR). Về mặt lý

thuyết, ảnh nhiệt được kỳ vọng sẽ tách biệt nhiệt lượng phát ra từ pin và động cơ drone so với nền trời lạnh. Tuy nhiên, trên thực tế tác chiến dã chiến, hệ thống RGBT bộc lộ những nhược điểm cố hữu chí mạng:


1. **Rào cản giá thành và khí tài quang điện tử công kênh:** Cảm biến hồng ngoại nhiệt độ nhạy cao (MWIR/LWIR) cùng cụm quang học làm bằng vật liệu thấu kính chuyên dụng (Germanium) có chi phí đắt đỏ gấp 5 đến 15 lần một camera cảm biến CMOS quang học tiêu chuẩn. Cụm thiết bị đa phổ có trọng lượng lớn, công kênh và tiêu thụ nhiều điện năng, khiến chi phí sản xuất hàng loạt tăng cao và không thể triển khai đại trà trên các phương tiện tuần tra cơ động hoặc thiết bị trinh sát gọn nhẹ.
2. **Nghịch lý Giao thoa Nền Nhiệt (Thermal Crossover Paradox):** Trong điều kiện thực địa (chiếm tới **60.4%** kịch bản trong tập dữ liệu Anti-UAV chuẩn), khi nhiệt độ vỏ ngoài của drone cân bằng với nhiệt độ nền môi trường (ví dụ vào buổi trưa nắng gắt khi mái nhà, mặt đất nung nóng, hoặc vào thời điểm chạng vạng bình minh/hoàng hôn), độ tương phản nhiệt giữa mục tiêu và hậu cảnh triệt tiêu hoàn toàn. Khi đó, luồng ảnh nhiệt bị mất hoàn toàn tín hiệu, trở thành một kênh dữ liệu nhiễu vô giá trị và gây sai lệch cho các thuật toán hợp nhất đặc trưng.
3. **Lệch trục thị sai không gian – thời gian (Spatial-Temporal Parallax Misalignment):** Do hai ống kính camera Visible và IR bắt buộc phải đặt cách nhau một khoảng cách vật lý (baseline parallax), việc căn chỉnh từng điểm ảnh (pixel-level registration) là bất khả thi khi cự ly tác chiến thay đổi liên tục và drone bay ở tốc độ cao. Hiện tượng thị sai gây ra các viền bóng ma (ghosting artifacts), làm biến dạng đặc trưng hình học và triệt tiêu độ chính xác của các mạng trích xuất đặc trưng sâu.
4. **Nút thắt băng thông và gánh nặng tài nguyên tính toán (Computational Overload):** Việc truyền tải và xử lý đồng thời 2 luồng video (RGB và Thermal) đòi hỏi gấp đôi băng thông I/O, gấp đôi dung lượng bộ nhớ đồ họa VRAM và tiêu tốn lượng tính toán FLOPs khổng lồ. Điều này tạo ra nút thắt cổ chai không thể vượt qua khi triển khai trên các vi xử lý nhúng tại biên (Edge AI như NVIDIA Jetson) trong yêu cầu tác chiến thời gian thực.

Quyết định chuyển dịch công nghệ sang Thuần Visible RGB: Xuất phát từ các phân tích thực nghiệm trên, công trình này đưa ra quyết định kỹ thuật dứt khoát: **Loại bỏ hoàn toàn cảm biến hồng ngoại (IR), chuyển đổi trọn vẹn hệ thống sang hướng tiếp cận thuần quang học Visible RGB.**

Thay vì dựa vào sự chênh lệch nhiệt thụ động vốn thiếu ổn định, chúng tôi bù đắp thông tin bằng cách khai thác **động lực học thời gian thuần quang học thông qua chuỗi 3 khung hình liên tiếp (Temporal Triplet 9 kênh RGB)**. Động học chuyển động vi sai giữa các khung hình liên tiếp cung cấp tín hiệu nhận diện mục tiêu mạnh mẽ và tin cậy hơn bất kỳ cảm biến nhiệt nào, đồng thời triệt tiêu hoàn toàn chi phí phần cứng đắt đỏ, xóa bỏ triệt để hiện tượng lệch trục parallax, tiết kiệm 50% tài nguyên bộ nhớ VRAM và đảm bảo tốc độ suy luận mượt mà đạt **21.4 FPS** trên GPU.

1.3 Đóng góp Cốt lõi của Công trình

Công trình này nghiên cứu, thiết kế và thực nghiệm thành công hệ thống **Anchor-Free CenterNet thuần Visible RGB** chuyên dụng cho nhiệm vụ phát hiện và bám bắt UAV thời gian thực (Hình 1).



Hình 1: Sơ đồ kiến trúc tổng thể mô hình CenterNet RGB phát hiện và bám bắt UAV thời gian thực: Đầu vào chuỗi thời gian 3 khung hình Temporal Triplet 9 kênh ($640 \times 640 \times 9$), mạng cơ sở ResNet-50v2 Pre-activation, mạng kim tự tháp đặc trưng P2-FPN độ phân giải cao kết hợp cơ chế chú ý tọa độ Coordinate Attention (CA), và 3 nhánh dự đoán Anchor-Free tách biệt (Heatmap, Offset, Size).

Các đóng góp khoa học và kỹ thuật trọng tâm của công trình bao gồm:

1. **Cơ chế ghép chuỗi thời gian Temporal Triplet 9 kênh:** Xây dựng tensor $X_{\text{temporal}} = [I_{t-\Delta t}, I_t, I_{t+\Delta t}] \in \mathbb{R}^{640 \times 640 \times 9}$, cho phép các bộ lọc tích chập ở các tầng nông tự động trích xuất trực tiếp vector vận tốc và gia tốc tức thời của drone mà không cần mạng Optical Flow hay LSTM nặng nề.
2. **Kiến trúc P2-FPN kết hợp Chú ý Tọa độ Coordinate Attention:** Mở rộng kim tự tháp đặc trưng xuống cấp độ phân giải cao P2 (stride 8, kích thước 80×80) kết hợp cơ chế chú ý định hướng 1D theo hai trục ngang và dọc, bảo tồn trọn vẹn vị trí không gian của các drone siêu nhỏ ($< 32^2$ px).
3. **Đột phá giải quyết triệt để hiện tượng Dying ReLU:** Phân tích giải tích nguyên nhân sụp đổ gradient ở nhánh dự đoán kích thước của CenterNet gốc, từ đó đề xuất giải pháp thay bằng hàm *Sigmoid* kết hợp *Khởi tạo Logit Prior Initialization* ($b_0 = -2.66$) suy dẫn từ thống kê thực nghiệm phân bố kích thước $s_0 = 0.065$, giúp mạng hội tụ mượt mà ngay từ epoch 1.
4. **Hệ thống Hàm mất mát Tối ưu Đa nhiệm:** Ứng dụng *Gaussian Focal Loss* xử lý mất cân bằng nền/tâm, kết hợp *Masked L1 Offset Loss* và *Normalized Gaussian Wasserstein Distance (NWD)* giải quyết triệt để hiện tượng mất độ mượt gradient của IoU truyền thống đối với vật thể siêu nhỏ.
5. **Bộ giải mã NMS-Free và Bộ lọc Quán tính Trajectory EMA:** Tận dụng toán tử *MaxPool* 3×3 thay thế Non-Maximum Suppression (NMS) đạt độ phức tạp $O(HW)$ kết hợp làm mượt quỹ đạo, giúp hệ thống đạt tốc độ **21.4 FPS** trên GPU và chuyển trạng thái linh hoạt sang *OCCLUDED* khi drone bị che khuất ngắn hạn.

2 Phân tích Bộ Dữ liệu và Quy trình Tiền xử lý Chuỗi Không – Thời gian

2.1 Thống kê Bộ Dữ liệu Video Ban đầu Anti-UAV (Visible RGB Stream)

Bộ dữ liệu Anti-UAV chuẩn (Visible RGB stream) là tập dữ liệu video quang học độ nét cao ghi lại chuyển động thực tế của nhiều chủng loại drone khác nhau trong không gian tác chiến đa dạng (đô thị, đồi núi, mặt biển, bầu trời quang và mây mù phức tạp). Bảng 1 trình bày thống kê chi tiết toàn bộ 318 video gốc với 296.901 khung hình:

Bảng 1: Thống kê định lượng toàn diện bộ dữ liệu video thô Anti-UAV (Visible RGB Stream).

Phân vùng (Split)	Số lượng Video	Tỷ lệ Video (%)	Tổng số Frames	Frames có Drone	Frames Che khuất / Mất dấu	Tỷ lệ Hiện diện (%)
Tập Huấn luyện (Train)	160	50.31%	149.528	142.192	7.336	95.09%
Tập Kiểm định (Val)	67	21.07%	61.999	58.302	3.697	94.04%
Tập Kiểm thử (Test)	91	28.62%	85.374	79.724	5.650	93.38%
Tổng cộng Toàn bộ	318	100.0%	296.901	280.218	16.683	94.38%

Các đặc tính quan trọng của bộ dữ liệu thô bao gồm:

- **Độ phân giải và thời lượng:** Video có độ phân giải gốc chuẩn Full HD 1920×1080 , tốc độ quay 25 FPS, tương ứng tổng thời lượng tích lũy đạt xấp xỉ 38.4 giờ video giám sát không phân.
- **Đặc trưng Bounding Box gốc:** Tổng cộng có 280.067 nhãn hộp bao ground truth. Kích thước trung bình là chiều rộng $\bar{w} = 125.5$ px (trung vị 116.0 px), chiều cao $\bar{h} = 63.3$ px (trung vị 61.0 px), và diện tích trung bình $\bar{A} = 8.642$ px², chỉ chiếm khoảng 0.417% diện tích toàn khung hình Full HD.
- **Phân bố các thuộc tính thử thách môi trường (Challenge Attributes):** Bộ dữ liệu bao hàm đầy đủ các kịch bản thực chiến: Thermal Crossover (TC – 60.4%), Fast Motion (FM – 38.4%), Low Illumination (LI – 36.8%), Scale Variation (SV – 21.7%), Low Resolution (LR – 15.1%), Out-of-View (OV – 12.3%) và Occlusion (OC – 3.8%).

2.2 Tiền xử lý Chuỗi Thời gian và Tạo Tập Dữ liệu Chuẩn Pascal VOC (Temporal Triplet)


Để loại bỏ tính dư thừa thông tin giữa các khung hình liên tiếp ở tần số 25 FPS và trích xuất trực tiếp vector vận tốc mà không cần mạng Optical Flow, hệ thống thực hiện trích xuất theo bước nhảy thời gian (temporal stride) và ghép nối 3 khung hình liên tiếp thành cấu trúc *Temporal Triplet* $X_{\text{temporal}} = [I_{t-\Delta t}, I_t, I_{t+\Delta t}] \in \mathbb{R}^{640 \times 640 \times 9}$ kèm nhãn định dạng chuẩn Pascal VOC XML (Bảng 2):

Bảng 2: Thống kê tập dữ liệu Pascal VOC sau khi tiền xử lý và trích xuất chuỗi thời gian Temporal Triplet.

Phân vùng Xử lý	Số mẫu Bộ ba (Triplets)	Khung hình JPEG Trích xuất	Mẫu Dương tính (Có Drone)	Mẫu Neg (Hard Negatives)	Tỷ lệ Phân chia (%)
Tập Huấn luyện (Train)	18.683	56.049	17.749 (95.0%)	934 (5.0%)	75.0%
Tập Kiểm định (Val)	6.228	18.684	5.854 (94.0%)	374 (6.0%)	25.0%
Tổng cộng (Train + Val)	24.911	74.733	23.603 (94.7%)	1.308 (5.3%)	100.0%

2.3 Phân bố Quy mô Đối tượng và Xác lập Phân phối Tiên nghiệm Logit Prior

Thực nghiệm phân loại quy mô vật thể theo chuẩn MS-COCO trên tập huấn luyện (Hình 2) cho thấy: Tiny/Small Drone chiếm 1.7%, Medium Drone chiếm 68.6%, và Large Drone chiếm 29.7%.



Hình 2: Phân bố kích thước đối tượng UAV trong tập dữ liệu Anti-UAV (68.6% Medium, 29.7% Large, 1.7% Tiny) và ngưỡng kích thước thực nghiệm $s_0 \approx 0.065$.

Tỷ lệ kích thước trung bình so với khung hình là $\bar{w}_{\text{norm}} = 125.5/1920 \approx 0.0654$ và $\bar{h}_{\text{norm}} = 63.3/1080 \approx 0.0586$, hội tụ quanh giá trị $s_0 \approx 0.065$. Kết quả này dẫn trực tiếp tới giá trị khởi tạo phân phối tiên nghiệm Logit Prior Bias:

$$b_0 = \ln \left(\frac{s_0}{1 - s_0} \right) = \ln \left(\frac{0.065}{0.935} \right) \approx -2.66 \quad (1)$$

giúp loại bỏ hoàn toàn hiện tượng Dying ReLU ngay từ bước lập đầu tiên.

2.4 Bảng So sánh Đối chiếu Toàn diện giữa Dữ liệu Thô và Dữ liệu Sau Xử lý

Bảng 3 tổng hợp sự chuyển đổi từ tập dữ liệu video ban đầu sang tập dữ liệu cấu trúc thời gian chuẩn mực phục vụ huấn luyện:

Bảng 3: Bảng so sánh đối chiếu đặc tính kỹ thuật giữa Dữ liệu Gốc và Dữ liệu Sau Xử lý Temporal VOC.

Tiêu chí So sánh	Dữ liệu Gốc (Raw Anti-UAV RGB)	Dữ liệu Sau Xử lý (Temporal VOC)	Ý nghĩa Kỹ thuật / Tác chiến
Định dạng dữ liệu	Video MP4 (H.264) + JSON chuỗi	Ảnh JPEG + Pascal VOC XML + CSV	Chuẩn hóa định dạng cho pipeline TensorFlow / Keras
Quy mô mẫu	318 clips (296.901 frames)	24.911 triplets (74.733 frames)	Loại bỏ dư thừa frame tĩnh, tối ưu hóa tốc độ huấn luyện
Độ phân giải	1920 × 1080 px (Full HD)	640 × 640 px (Bi-linear resize)	Giảm tải VRAM GPU, thông tin chi tiết bảo toàn qua P2-FPN
Cấu trúc Tensor	1 khung hình đơn ($H \times W \times 3$)	Bộ ba thời gian ($H \times W \times 9$)	Trích xuất trực tiếp vector vận tốc không cần Optical Flow
Hard Negatives	16.683 frames âm tính (5.62%)	1.308 mẫu bộ ba không có drone	Huấn luyện mạng triplet tiêu cảnh báo giả trên mây và công trình
Phân chia Dataset	160 Train / 67 Val / 91 Test	18.683 Train / 6.228 Val	Phân tầng độc lập theo chuỗi bay, ngăn ngừa rò rỉ dữ liệu

3 Kiến trúc Mạng Nơ-ron Đa Tỷ lệ Không – Thời gian

3.1 Bộ ba Khung hình Thời gian (Temporal Triplet)

Đối với vật thể bay cỡ nhỏ, đặc trưng hình thái tĩnh (chỉ dùng một khung hình I_t) thường không đủ để phân biệt drone với các dị vật như lá cây bay, chim bay hoặc nhiễu cảm biến. Tuy nhiên, vector chuyển động của drone mang tính chất cơ học nhất quán (vận tốc góc, gia tốc).

Thay vì sử dụng các thuật toán Optical Flow truyền thống (Lucas-Kanade) hay mạng nơ-ron hồi quy (ConvLSTM) tiêu tốn tài nguyên, ta xây dựng một tensor không – thời gian ẩn (implicit

spatio-temporal tensor) bằng cách xếp chồng 3 khung hình liên tiếp cách đều một chu kỳ thời gian Δt :

$$X_{\text{temporal}} = [I_{t-\Delta t}, I_t, I_{t+\Delta t}] \in \mathbb{R}^{H \times W \times 9} \quad (2)$$

Trong đó:

- $I_t \in \mathbb{R}^{H \times W \times 3}$ là khung hình mục tiêu tại thời điểm t , nơi chứa nhãn bounding box thực tế (Ground Truth).
- $I_{t-\Delta t}$ và $I_{t+\Delta t}$ lần lượt đóng vai trò ngữ cảnh quá khứ và tương lai.



Hình 3: Cơ chế đầu vào chuỗi 3 khung hình Temporal Triplet (I_{t-1}, I_t, I_{t+1}) và bản đồ sai khác chuyển động vi phân $|\Delta I|$.

Về mặt toán học, khi tensor 9 kênh đi qua lớp tích chập đầu tiên $\text{Conv}_{7 \times 7}$ với trọng số $W = [W_{\text{prev}}, W_{\text{curr}}, W_{\text{next}}]$, đáp ứng tuyến tính có dạng:

$$Y = W_{\text{prev}} * I_{t-\Delta t} + W_{\text{curr}} * I_t + W_{\text{next}} * I_{t+\Delta t} + b \quad (3)$$

Nếu đặt $W_{\text{prev}} \approx -W_{\text{curr}}/2$ và $W_{\text{next}} \approx -W_{\text{curr}}/2$, lớp tích chập đóng vai trò như một toán tử xấp xỉ đạo hàm bậc hai theo thời gian (gia tốc chuyển động):

$$\frac{\partial^2 I}{\partial t^2} \approx \frac{I_{t+\Delta t} - 2I_t + I_{t-\Delta t}}{\Delta t^2} \quad (4)$$


Nhờ đó, mạng tự động phát hiện được sự sai khác vị trí của drone trên nền trời tĩnh mà không cần bất kỳ bước tính toán Optical Flow tường minh nào.

3.2 Khung Trích xuất Đặc trưng ResNet-50v2 Pre-activation

Mạng trích xuất đặc trưng (Backbone) sử dụng kiến trúc ResNet-50v2 cải tiến với cấu trúc khối phần dư tiền kích hoạt (Pre-activation Residual Block) như minh họa tại Hình 4. Thay vì cấu trúc truyền thống $\text{Conv} \rightarrow \text{BN} \rightarrow \text{ReLU}$ (Residual Block v1), khối Bottleneck v2 sắp xếp theo thứ tự $\text{BN} \rightarrow \text{ReLU} \rightarrow \text{Conv}$ (Residual Block v2):

$$x_{\text{pre}} = \text{ReLU}(\text{BN}(x)) \quad (5)$$

$$y = x + \text{Conv}_{1 \times 1}(\text{ReLU}(\text{BN}(\text{Conv}_{3 \times 3}(\text{ReLU}(\text{BN}(\text{Conv}_{1 \times 1}(x_{\text{pre}}))))))) \quad (6)$$



Hình 4: So sánh cấu trúc khối phần dư chuẩn (Residual Block v1) và khối phần dư tiền kích hoạt (Pre-activation Residual Block v2) ứng dụng trong mạng cơ sở ResNet-50v2, tạo đường dẫn tắt thuận nhất giúp gradient lan truyền sâu mà không bị suy thoái.


Cấu trúc Pre-activation tạo ra một *đường cao tốc* dòng gradient thuần túy (identity mapping) từ các tầng sâu về các tầng đầu vào, ngăn ngừa hiện tượng suy thoái mạng (degradation problem) khi xử lý tensor 9 kênh. Bốn khối trích xuất đặc trưng chính tạo ra các bản đồ đặc trưng tương ứng với các độ phân giải giảm dần:

- $C_2 \in \mathbb{R}^{160 \times 160 \times 256}$ (Stride 4)
- $C_3 \in \mathbb{R}^{80 \times 80 \times 512}$ (Stride 8)
- $C_4 \in \mathbb{R}^{40 \times 40 \times 1024}$ (Stride 16)
- $C_5 \in \mathbb{R}^{20 \times 20 \times 2048}$ (Stride 32)

3.3 Feature Pyramid Network P2-FPN Đa Tỷ Lệ

Trong các mô hình phát hiện đối tượng thông thường (như FPN tiêu chuẩn hoặc YOLO), dự đoán thường được thực hiện ở các tầng P_3, P_4, P_5 (stride 8, 16, 32). Tuy nhiên, một drone có kích thước 16×16 pixel khi đưa xuống stride 16 sẽ chỉ còn 1×1 pixel, và tại stride 32 sẽ bị tiêu biến hoàn toàn.

Để giải quyết vấn đề này, ta thiết kế kiến trúc **P2-FPN** mở rộng kết nối xuống tận tầng C_2 (stride 4) với số chiều kênh cố định $d = 128$ (Hình 5):



Hình 5: Cấu trúc kim tự tháp đặc trưng P2-FPN mở rộng đa tỉ lệ ($M_i = C_i$).

Các luồng lan truyền từ trên xuống (top-down) và các tầng đặc trưng được thiết lập theo hệ thức:

$$P_5 = \text{Conv}_{3 \times 3}(\text{Conv}_{1 \times 1}(C_5)) \quad (7)$$

$$P_4 = \text{Conv}_{3 \times 3}(\text{Conv}_{1 \times 1}(C_4) + \text{Up}_2(P_5)) \quad (8)$$

$$P_3 = \text{Conv}_{3 \times 3}(\text{Conv}_{1 \times 1}(C_3) + \text{Up}_2(P_4)) \quad (9)$$

$$P_2 = \text{Conv}_{3 \times 3}(\text{Conv}_{1 \times 1}(C_2) + \text{Up}_2(P_3)) \quad (10)$$

Sau đó, toàn bộ các tầng P_2, P_3, P_4, P_5 được chuẩn hóa về cùng không gian tỉ lệ Stride 8 (80×80) thông qua phép MaxPool và Bilinear Upsampling:

$$F_{\text{fused}} = \text{BN}(\text{Conv}_{3 \times 3}([\text{MaxPool}_2(P_2), P_3, \text{Up}_2(P_4), \text{Up}_4(P_5)])) \in \mathbb{R}^{80 \times 80 \times 128} \quad (11)$$

Nhờ vậy, đặc trưng đưa vào các đầu dự đoán vừa chứa ngữ nghĩa sâu của P_4, P_5 , vừa chứa chi tiết không gian chính xác cao của P_2, P_3 .


3.4 Cơ chế Chú ý Tọa độ (Coordinate Attention Mechanism)

Cơ chế chú ý kênh truyền thống như Squeeze-and-Excitation (SE) sử dụng phép gom trung bình toàn cục 2D (Global Average Pooling):

$$z_c = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W x_c(i, j) \quad (12)$$

Phép biến đổi này tích phân toàn bộ thông tin không gian thành một đại lượng vô hướng, làm mất hoàn toàn tọa độ vị trí của vật thể. Điều này rất bất lợi cho bài toán CenterNet bởi vị trí tâm điểm chính xác là mục tiêu dự đoán hàng đầu.

Để khắc phục, mô hình tích hợp cơ chế **Coordinate Attention (CA)** trên các tầng P_2 và P_3 . CA phân rã phép gom 2D thành hai phép ma trận gom 1D theo phương ngang và phương dọc:



Hình 6: So Sánh Cơ Chế Chú Ý Squeeze-and-Excitation (SE) vs Coordinate Attention (CA)

$$z_c^h(h) = \frac{1}{W} \sum_{0 \leq i < W} x_c(h, i) \in \mathbb{R}^{H \times 1 \times C} \quad (13)$$

$$z_c^w(w) = \frac{1}{H} \sum_{0 \leq j < H} x_c(j, w) \in \mathbb{R}^{1 \times W \times C} \quad (14)$$

Hai vector định hướng được chuyển vị, ghép nối và biến đổi qua một lớp tích chập chia sẻ F_1 với tỉ lệ giảm chiều $r = 16$:


$$\mathbf{f} = \text{ReLU} \left(\text{BN} \left(F_1 \left(\left[\mathbf{z}^h, (\mathbf{z}^w)^T \right] \right) \right) \right) \in \mathbb{R}^{(H+W) \times 1 \times (C/r)} \quad (15)$$

Sau đó, $\mathbf{f}$ được phân tách lại thành hai tensor $\mathbf{f}^h \in \mathbb{R}^{H \times 1 \times (C/r)}$ và $\mathbf{f}^w \in \mathbb{R}^{1 \times W \times (C/r)}$. Hai lớp tích chập 1×1 riêng biệt F_h, F_w đưa số kênh trở lại C , tiếp nối bởi hàm kích hoạt Sigmoid:

$$g_c^h(h) = \sigma \left(F_h(\mathbf{f}^h) \right), \quad g_c^w(w) = \sigma \left(F_w(\mathbf{f}^w) \right) \quad (16)$$

Đầu ra hiệu chỉnh tọa độ của tầng Coordinate Attention được tính bằng phép nhân Hadamard:

$$y_c(i, j) = x_c(i, j) \times g_c^h(i) \times g_c^w(j) \quad (17)$$



Hình 7: Coordinate Attention Mechanism

Nhờ vậy, mạng khuếch đại được chính xác hàng i và cột j chứa tâm điểm drone, giảm thiểu tối đa các cảnh báo giả từ các vật thể nhiễu ở các khu vực khác.

4 Phân tích Toán học và Đột phá Khắc phục Hiện tượng Dying ReLU

4.1 Cơ chế CenterNet Gốc và Nguy cơ Sụp đổ Gradient

Trong kiến trúc CenterNet nguyên bản, nhánh dự đoán kích thước (Size Head) sử dụng hàm kích hoạt ReLU ở lớp đầu ra để đảm bảo chiều rộng và chiều cao luôn dương:

$$\hat{s} = [\hat{w}, \hat{h}] = \text{ReLU}(W_s * f + b_s) \quad (18)$$

với $z = W_s * f + b_s$ là giá trị trước kích hoạt (pre-activation).

Phân tích toán học về Dying ReLU: Đạo hàm của hàm ReLU theo biến số z có dạng:

$$\frac{\partial \text{ReLU}(z)}{\partial z} = \begin{cases} 1 & \text{nếu } z > 0 \\ 0 & \text{nếu } z \leq 0 \end{cases} \quad (19)$$

Trong thực tế huấn luyện, các trọng số W_s thường được khởi tạo ngẫu nhiên theo phân phối Gaussian quanh 0 và bias khởi tạo $b_s = 0$. Khi mô hình xử lý các khung hình âm tính (không có drone) hoặc khi tín hiệu gradient từ hàm mất mát L_{size} đẩy z sang miền âm ($z < 0$), đạo hàm $\frac{\partial \text{ReLU}}{\partial z}$ lập tức bằng 0.

Một khi nơ-ron rơi vào trạng thái $z < 0$:

$$\nabla_{W_s} \mathcal{L} = \frac{\partial \mathcal{L}}{\partial \hat{s}} \cdot \frac{\partial \hat{s}}{\partial z} \cdot \frac{\partial z}{\partial W_s} = \frac{\partial \mathcal{L}}{\partial \hat{s}} \cdot 0 \cdot f = \mathbf{0} \quad (20)$$

Dòng gradient hoàn toàn bị triệt tiêu, khiến các trọng số W_s và bias b_s bị *đóng băng* vĩnh viễn (Dying ReLU). Đối với tập dữ liệu Anti-UAV – nơi đối tượng chỉ chiếm diện tích nhỏ và số lượng mẫu dương thưa thớt – hiện tượng này dẫn đến việc nhánh Size sụp đổ hoàn toàn: mô hình liên tục dự đoán kích thước bằng 0 hoặc kích thước ngẫu nhiên không thể hội tụ.

4.2 Đột phá: Hàm Kích hoạt Sigmoid và Khởi tạo Phân phối Tiên nghiệm Logit Prior

Để loại bỏ hoàn toàn vùng chết gradient, chúng tôi thay thế hàm ReLU bằng hàm kích hoạt **Sigmoid**:

$$\hat{s} = \sigma(z) = \frac{1}{1 + e^{-z}} \quad (21)$$

với miền giá trị $\hat{s} \in (0, 1)$, biểu diễn kích thước chuẩn hóa của drone so với kích thước khung hình.

Đạo hàm của hàm Sigmoid:

$$\sigma'(z) = \frac{\partial \sigma(z)}{\partial z} = \sigma(z) (1 - \sigma(z)) > 0, \quad \forall z \in (-\infty, +\infty) \quad (22)$$

Do $\sigma'(z) > 0$ nghiêm ngặt trên toàn bộ trục số thực, gradient không bao giờ bị triệt tiêu về 0, đảm bảo quá trình lan truyền ngược luôn được duy trì.

4.3 Suy dẫn Giải tích Hệ số Bias $b_0 = -2.66$ từ Thực nghiệm $s_0 = 0.065$

Mặc dù hàm Sigmoid giải quyết được vấn đề đạo hàm, việc khởi tạo mặc định $b_s = 0$ sẽ dẫn đến một vấn đề mới:

$$\hat{s}_{\text{init}} = \sigma(0) = 0.50 \quad (23)$$

Nghĩa là tại bước lặp đầu tiên ($t = 0$), mô hình sẽ dự đoán drone chiếm tới 50% chiều rộng và chiều cao khung hình (320×320 pixel trên ảnh 640×640). Sai số khổng lồ giữa dự đoán 0.50 và kích thước thực tế của drone sẽ gây bùng nổ gradient, phá hủy các tầng biểu diễn đặc trưng ở backbone.

Xác định giá trị thực nghiệm s_0 : Khảo sát phân bố kích thước hộp bao trên toàn bộ tập dữ liệu Anti-UAV (Hình 2):

- Khung hình gốc Full HD: Chiều rộng $W_{\text{img}} = 1920$ px, chiều cao $H_{\text{img}} = 1080$ px.
- Chiều rộng trung bình của drone: $\bar{w}_{\text{pixel}} \approx 125$ px $\implies \bar{w}_{\text{norm}} = \frac{125}{1920} \approx 0.0651$.
- Chiều cao trung bình của drone: $\bar{h}_{\text{pixel}} \approx 70$ px $\implies \bar{h}_{\text{norm}} = \frac{70}{1080} \approx 0.0648$.
- Quy đổi về kích thước huấn luyện 640×640 :

$$s_{\text{pixel}} = 640 \times 0.065 \approx 41.6 \text{ px} \quad (24)$$

Kích thước này nằm gọn trong phân hạng Medium/Small Drone ($32^2 - 96^2$ px) vốn chiếm tới **68.6%** tổng số mẫu.

Do đó, kích thước kỳ vọng tiên nghiệm đại diện nhất của drone trong tập dữ liệu là:

$$s_0 \approx 0.065 \quad (25)$$

Suy dẫn giải tích tìm b_0 : Ta thiết lập điều kiện: Tại bước khởi tạo khi các trọng số tích chập $W_s \approx 0$, đầu ra của hàm Sigmoid phải trùng khớp hoàn hảo với phân phối tiên nghiệm s_0 :

$$\sigma(b_0) = \frac{1}{1 + e^{-b_0}} = s_0 \quad (26)$$

Biến đổi giải tích phương trình trên:

$$1 + e^{-b_0} = \frac{1}{s_0} \quad (27)$$

$$e^{-b_0} = \frac{1 - s_0}{s_0} \quad (28)$$

$$-b_0 = \ln\left(\frac{1 - s_0}{s_0}\right) \quad (29)$$


$$b_0 = \ln\left(\frac{s_0}{1 - s_0}\right) = \text{logit}(s_0) \quad (30)$$

Thay giá trị thực nghiệm $s_0 = 0.065$ vào hàm logit:

$$b_0 = \ln\left(\frac{0.065}{1 - 0.065}\right) = \ln\left(\frac{0.065}{0.935}\right) = \ln(0.0695187) \approx -2.6661 \approx -\mathbf{2.66} \quad (31)$$

Tác động động học: Ngay tại epoch đầu tiên, kích thước xuất phát ban đầu là:

$$\hat{s}_{\text{start}} = \sigma(-2.66) = \frac{1}{1 + e^{2.66}} \approx 0.0653 \implies 640 \times 0.0653 \approx 41.8 \text{ px} \quad (32)$$



Hình 8: Cơ Chế Khắc Phục Hiện Tượng Dying ReLU & Khởi Tạo Logit Prior

Sai số ban đầu $|0.0653 - 0.065| \approx 0.0003 \approx 0$, giúp gradient hồi quy kích thước không bị sốc nhiệt, loss size khởi đầu ổn định ở mức 0.1505 (thay vì vọt lên > 3.0), tạo đà cho toàn bộ mạng hội tụ mượt mà.

5 Thiết lập Hệ thống Hàm Mất Mát Đa Nhiệm Tối Ưu

Hàm mục tiêu tổng thể của mô hình là một tổ hợp đa nhiệm có trọng số giữa ba thành phần:

$$\mathcal{L}_{\text{total}} = \lambda_{\text{hm}} \mathcal{L}_{\text{hm}} + \lambda_{\text{off}} \mathcal{L}_{\text{off}} + \lambda_{\text{size}} \mathcal{L}_{\text{size}} \quad (33)$$

với các hệ số cân bằng $\lambda_{\text{hm}} = 1.0$, $\lambda_{\text{off}} = 1.0$, $\lambda_{\text{size}} = 1.0$.

5.1 Gaussian Focal Loss cho Heatmap Điểm Tâm

Trên lưới đặc trưng kích thước $80 \times 80 = 6.400$ vị trí, chỉ có đúng 1 vị trí là tâm điểm đối tượng ($Y_{xy} = 1$), còn lại 6.399 vị trí là nền ($Y_{xy} = 0$). Tỷ lệ mất cân bằng giữa mẫu dương và mẫu âm lên tới 1 : 6400. Hàm mất mát Binary Cross Entropy tiêu chuẩn sẽ bị chi phối hoàn toàn bởi mẫu âm dễ (easy negatives).

Ta sử dụng biến thể cải tiến của **Gaussian Focal Loss**:


$$\mathcal{L}_{\text{hm}} = -\frac{1}{N} \sum_{x=1}^{W/R} \sum_{y=1}^{H/R} \begin{cases} (1 - \hat{Y}_{xy})^\alpha \log(\hat{Y}_{xy}) & \text{nếu } Y_{xy} = 1 \\ (1 - Y_{xy})^\beta (\hat{Y}_{xy})^\alpha \log(1 - \hat{Y}_{xy}) & \text{ngược lại} \end{cases} \quad (34)$$

với $\alpha = 2.0$, $\beta = 4.0$ và N là số lượng mục tiêu dương tính.

Ý nghĩa của trọng số phạt mềm $(1 - Y_{xy})^\beta$: Tại các điểm lân cận đỉnh tâm, giá trị nhãn ground truth $Y_{xy} \in (0, 1)$ giảm dần theo hàm phân phối Gaussian:

$$Y_{xy} = \exp\left(-\frac{(x - \tilde{p}_x)^2 + (y - \tilde{p}_y)^2}{2\sigma_p^2}\right) \quad (35)$$

với $\sigma_p = \max\left(1.0, \frac{\sqrt{w \cdot h}}{3.0}\right)$. Hệ số $(1 - Y_{xy})^\beta$ hoạt động như một cơ chế giảm chấn (penalty reduction): nếu mô hình dự đoán tâm điểm bị lệch 1 pixel nhưng vẫn nằm trong phạm vi bán kính Gaussian của drone, sai số chỉ bị phạt một lượng rất nhỏ thay vì bị phạt nặng như điểm nền xa.



Hình 9: Mô Phỏng Gaussian Heatmap & Cơ Chế Giảm Chấn Mềm Của Gaussian Focal Loss

5.2 Masked Sub-pixel Offset L1 Loss

Quá trình trích xuất đặc trưng thông qua các lớp mạng kim tự tháp làm giảm độ phân giải không gian của ảnh đầu vào theo hệ số Stride $R = 8$. Xét tọa độ tâm liên tục của mục tiêu trên ảnh gốc là $\mathbf{p} = (p_x, p_y) \in \mathbb{R}^2$, khi ánh xạ xuống lưới đặc trưng, tọa độ này trở thành một điểm liên tục $\mathbf{p}' = \frac{\mathbf{p}}{R}$.

Để biểu diễn trên ma trận pixel rời rạc, tọa độ này buộc phải trải qua bước lượng tử hóa (làm tròn xuống) để xác định chỉ số của ô lưới chứa tâm đối tượng:

$$\tilde{\mathbf{p}} = (\tilde{p}_x, \tilde{p}_y) = \left(\left\lfloor \frac{p_x}{R} \right\rfloor, \left\lfloor \frac{p_y}{R} \right\rfloor \right) \in \mathbb{Z}^2 \quad (36)$$

Việc vứt bỏ phần thập phân trong quá trình làm tròn sinh ra sai số lượng tử hóa. Khoảng cách lệch lớn nhất có thể xảy ra khi ánh xạ ngược từ tâm ô lưới về ảnh gốc được xác định bằng định lý Pythagoras:

$$\Delta p_{\max} = \sqrt{\left(\frac{R}{2}\right)^2 + \left(\frac{R}{2}\right)^2} = \frac{R\sqrt{2}}{2} \quad (37)$$

Với hệ số $R = 8$, sai số vị trí tối đa xấp xỉ 5.66 pixels. Đối với các mục tiêu micro-drone có kích thước siêu nhỏ (ví dụ: 16×16 pixels), mức sai lệch 5.66 pixels chiếm tới hơn 35% kích thước vật thể. Điều này gây suy giảm nghiêm trọng độ đo IoU và làm hộp bọc dự đoán trượt khỏi mục tiêu.

Để khôi phục độ chính xác dưới mức pixel (sub-pixel), mô hình thiết kế một nhánh Offset chuyên biệt nhằm dự đoán bản đồ vector bù trừ $\hat{\mathbf{O}} \in \mathbb{R}^{\frac{W}{R} \times \frac{H}{R} \times 2}$. Hàm mất mát $\mathcal{L}_{\text{off}}$ sử dụng chuẩn L1 và được kết hợp với mất nạ nhị phân M (trong đó $M_{xy} = 1$ tại đúng tọa độ tâm $\tilde{\mathbf{p}}$ và $M_{xy} = 0$ ở mọi vị trí nền). Cơ chế này buộc mạng chỉ lan truyền ngược (back-propagate) sai số tại chính ô lưới chứa mục tiêu:

$$\mathcal{L}_{\text{off}} = \frac{1}{N} \sum_{x=1}^{W/R} \sum_{y=1}^{H/R} M_{xy} \left\| \hat{\mathbf{O}}_{xy} - \left(\frac{\mathbf{p}}{R} - \tilde{\mathbf{p}} \right) \right\|_1 \quad (38)$$

5.3 Đột phá: Normalized Gaussian Wasserstein Distance (NWD) cho Đối tượng Siêu Nhỏ

Hạn chế nghiêm trọng của các hàm mất mát dạng IoU: Các hàm mất mát truyền thống như $\mathcal{L}_{\text{IoU}}$, $\mathcal{L}_{\text{GIoU}}$, $\mathcal{L}_{\text{DIoU}}$, $\mathcal{L}_{\text{CIoU}}$ phụ thuộc hoàn toàn vào tỷ lệ diện tích giao cắt của hai hộp bọc:

$$\text{IoU}(A, B) = \frac{|A \cap B|}{|A \cup B|} \quad (39)$$

Đối với các đối tượng kích thước siêu nhỏ, chỉ số IoU bộc lộ tính *nhạy cảm cực đoan đối với độ lệch pixel (Extreme Pixel Sensitivity)*:

- **Trường hợp mục tiêu lớn (100×100 px):** Nếu hộp dự đoán lệch 2 pixels, diện tích giao cắt là $98 \times 98 = 9604$, diện tích hợp là $20000 - 9604 = 10396 \implies \text{IoU} \approx 0.924$. Độ suy giảm IoU chỉ ở mức 7.6%.
- **Trường hợp mục tiêu siêu nhỏ (4×4 px):** Với cùng độ lệch 2 pixels, diện tích giao cắt sụt giảm còn $2 \times 2 = 4$, diện tích hợp là $32 - 4 = 28 \implies \text{IoU} \approx 0.143$. Mức suy giảm IoU lên tới 85.7%. Nghiêm trọng hơn, nếu lệch 4 pixels, $\text{IoU} = 0$, dẫn đến gradient bị triệt tiêu hoàn toàn, khiến mạng nơ-ron mất khả năng học.

Mô hình hóa Hộp bao bằng Phân phối Gaussian 2D: Để khắc phục điểm yếu chí mạng của IoU, chúng tôi tích hợp giải thuật **Normalized Gaussian Wasserstein Distance (NWD)**. Một hộp bọc $B = (cx, cy, w, h)$ được biểu diễn dưới dạng một elip phân phối chuẩn Gaussian hai chiều $\mathcal{N}(\mathbf{m}, \mathbf{\Sigma})$:

$$\mathbf{m} = \begin{bmatrix} cx \\ cy \end{bmatrix}, \quad \mathbf{\Sigma} = \begin{bmatrix} \frac{w^2}{4} & 0 \\ 0 & \frac{h^2}{4} \end{bmatrix} \quad (40)$$

Khoảng cách Wasserstein bậc hai (W_2^2) giữa hai phân phối $\mathcal{N}_1(\mathbf{m}_1, \mathbf{\Sigma}_1)$ và $\mathcal{N}_2(\mathbf{m}_2, \mathbf{\Sigma}_2)$ có nghiệm giải tích tổng quát:

$$W_2^2(\mathcal{N}_1, \mathcal{N}_2) = \|\mathbf{m}_1 - \mathbf{m}_2\|_2^2 + \text{Tr} \left(\mathbf{\Sigma}_1 + \mathbf{\Sigma}_2 - 2 \left(\mathbf{\Sigma}_1^{1/2} \mathbf{\Sigma}_2 \mathbf{\Sigma}_1^{1/2} \right)^{1/2} \right) \quad (41)$$

Nhờ đặc tính các hộp bọc song song với trục tọa độ (axis-aligned), các ma trận hiệp phương sai là ma trận đường chéo, giúp công thức được rút gọn hình học thành:

$$W_2^2(\mathcal{N}_1, \mathcal{N}_2) = (cx_1 - cx_2)^2 + (cy_1 - cy_2)^2 + \frac{(w_1 - w_2)^2 + (h_1 - h_2)^2}{4} \quad (42)$$

Để chuyển đổi khoảng cách thành một độ đo tương đồng trong khoảng $(0, 1]$, NWD áp dụng hàm mũ suy giảm với hằng số chuẩn hóa $C = 0.10$:

$$\text{NWD}(\mathcal{N}_1, \mathcal{N}_2) = \exp \left(-\frac{\sqrt{W_2^2(\mathcal{N}_1, \mathcal{N}_2)}}{C} \right) \quad (43)$$

Đặc tính vượt trội của NWD là tạo ra một trường gradient trơn, liên tục và khả vi, ngay cả khi hộp dự đoán và Ground Truth **hoàn toàn không giao nhau** ($A \cap B = \emptyset$).

Hàm mất mát kích thước kết hợp (Hybrid Size Loss): Trong kiến trúc phân nhánh (Decoupled Heads), sai lệch vị trí tâm (cx, cy) đã được tinh chỉnh độc lập bởi nhánh Offset. Do đó, khoảng cách Wasserstein áp dụng cho nhánh dự đoán Kích thước (Size Head) được tối giản hóa, chỉ phụ thuộc vào tỷ lệ quy mô:

$$W_{\text{size}}^2(\mathbf{s}_{xy}, \hat{\mathbf{s}}_{xy}) = \frac{(w - \hat{w})^2 + (h - \hat{h})^2}{4} \quad (44)$$

với $\mathbf{s}_{xy} = (w, h)$ là kích thước thực tế và $\hat{\mathbf{s}}_{xy} = (\hat{w}, \hat{h})$ là kích thước dự đoán tại tọa độ ô lưới (x, y) .

Từ đó, độ đo NWD thành phần được khai triển tường minh thành:

$$\text{NWD}(\mathbf{s}_{xy}, \hat{\mathbf{s}}_{xy}) = \exp \left(-\frac{\sqrt{(w - \hat{w})^2 + (h - \hat{h})^2}}{2C} \right) \quad (45)$$

Để tối ưu hóa quá trình hội tụ, chúng tôi đề xuất hàm mất mát kích thước lại $\mathcal{L}_{\text{size}}$. Hàm này đồng bộ cơ chế mất mát nhị phân M_{xy} với nhánh Offset, đảm bảo gradient chỉ lan truyền tại đúng ô lưới chứa tâm mục tiêu:

$$\mathcal{L}_{\text{size}} = \frac{1}{N} \sum_{x=1}^{W/R} \sum_{y=1}^{H/R} M_{xy} [\lambda_{L1} \|\mathbf{s}_{xy} - \hat{\mathbf{s}}_{xy}\|_1 + (1 - \text{NWD}(\mathbf{s}_{xy}, \hat{\mathbf{s}}_{xy}))] \quad (46)$$

Trong thực nghiệm, trọng số $\lambda_{L1} = 5.0$. Thành phần L1 ($\|\cdot\|_1$) tạo ra xung lực hồi quy mạnh mẽ ở các epoch đầu tiên, trong khi cụm $(1 - \text{NWD})$ đóng vai trò tinh chỉnh độ chính xác ở cấp độ hẹp, giải quyết hoàn hảo bài toán biến dạng tỷ lệ đối với micro-drone.

6 Thuật toán Hậu Xử lý và Bám bắt Quỹ đạo Thời gian thực

6.1 Local Maximum Decoding không dùng NMS (NMS-Free Decoding)

Các mô hình phát hiện hai giai đoạn (Faster R-CNN) hoặc Anchor-based (YOLO) đều yêu cầu thuật toán Non-Maximum Suppression (NMS) để loại bỏ các hộp bao dư thừa. NMS có hai hạn chế lớn:

1. Độ phức tạp thời gian $O(N^2)$ với N là số lượng candidate box, chiếm tới 15 – 30% tổng thời gian suy luận.
2. Khi hai drone bay sát nhau theo biên đội, NMS dễ dàng xóa nhầm hộp bao của drone thứ hai do chỉ số IoU giao cắt vượt ngưỡng triệt tiêu.

CenterNet loại bỏ hoàn toàn NMS bằng cách biến đổi bài toán tìm hộp bao thành tìm cực đại địa phương trên bản đồ xác suất Heatmap thông qua toán tử tích chập MaxPool 3×3 :


$$\hat{Y}_{\text{peak}} = \hat{Y} \odot \mathbb{I}(\hat{Y} == \text{MaxPool}_{3 \times 3}(\hat{Y})) \quad (47)$$

với $\mathbb{I}$ là hàm chỉ báo (indicator function). Độ phức tạp của phép toán này chỉ là $O(HW)$ và có thể song song hóa hoàn toàn trên GPU. Vị trí tâm và kích thước hộp bao sau giải mã:

$$cx = \frac{\tilde{x} + \hat{O}_x}{W_{\text{grid}}}, \quad cy = \frac{\tilde{y} + \hat{O}_y}{H_{\text{grid}}} \quad (48)$$

$$xmin = cx - \frac{\hat{w}}{2}, \quad xmax = cx + \frac{\hat{w}}{2} \quad (49)$$

$$ymin = cy - \frac{\hat{h}}{2}, \quad ymax = cy + \frac{\hat{h}}{2} \quad (50)$$



Hình 10: Local Maximum Decoding

6.2 Bộ lọc Quỹ đạo Quán tính Trajectory EMA Filter

Trong các chuỗi video thực tế, việc phát hiện có thể bị gián đoạn cục bộ do drone bay qua vùng mây mù dày, ánh sáng chói lóa, hoặc che khuất tạm thời. Nếu chỉ dựa vào kết quả phát hiện từng khung hình, hộp bao sẽ bị rung giật hoặc biến mất đột ngột.

Algorithm 1 Thuật toán Lọc Quỹ đạo Quán tính Trajectory EMA

Đầu vào: Hộp bao phát hiện $\mathbf{b}_{\text{det}}$, trạng thái `is_detected`, ngưỡng mất dấu tối đa $M_{\text{max}} = 15$, hệ số mượt $\alpha = 0.6$.

```
1: if is_detected == True then
2:   if  $\mathbf{b}_{\text{smooth}}$  == None then
3:      $\mathbf{b}_{\text{smooth}} \leftarrow \mathbf{b}_{\text{det}}$ 
4:      $\mathbf{v} \leftarrow [0.0, 0.0]$ 
5:   else
6:      $\mathbf{c}_{\text{curr}} \leftarrow \text{Center}(\mathbf{b}_{\text{det}})$ ,  $\mathbf{c}_{\text{prev}} \leftarrow \text{Center}(\mathbf{b}_{\text{smooth}})$ 
7:      $\mathbf{v} \leftarrow 0.6 \cdot \mathbf{v} + 0.4 \cdot (\mathbf{c}_{\text{curr}} - \mathbf{c}_{\text{prev}})$  // Cập nhật vector vận tốc tức thời
8:      $\mathbf{b}_{\text{smooth}} \leftarrow \alpha \cdot \mathbf{b}_{\text{det}} + (1 - \alpha) \cdot \mathbf{b}_{\text{smooth}}$  // Làm mượt tọa độ
9:   end if
10:  missing_count  $\leftarrow 0$ , status  $\leftarrow$  DETECTED
11:  return  $\mathbf{b}_{\text{smooth}}$ , status,  $\|\mathbf{v}\|_2$ 
12: else
13:  if is_active == True và missing_count <  $M_{\text{max}}$  then
14:    missing_count  $\leftarrow$  missing_count + 1
15:     $\mathbf{b}_{\text{smooth}} \leftarrow \mathbf{b}_{\text{smooth}} + [\mathbf{v}_x, \mathbf{v}_y, \mathbf{v}_x, \mathbf{v}_y]$  // Ngoại suy vị trí theo quán tính
16:    status  $\leftarrow$  TRACKED_EMA
17:    return  $\mathbf{b}_{\text{smooth}}$ , status,  $\|\mathbf{v}\|_2$ 
18:  else
19:    is_active  $\leftarrow$  False,  $\mathbf{b}_{\text{smooth}} \leftarrow$  None
20:    return None, LOST, 0.0
21:  end if
22: end if
```

Nhờ cơ chế ngoại suy quán tính $\mathbf{b}_{\text{smooth}} + \mathbf{v}$, hệ thống duy trì được khóa mục tiêu liên tục trong tối đa 15 khung hình (khoảng 0.5 giây) khi mục tiêu bị che khuất, ngăn ngừa hiện tượng mất dấu mục tiêu.

7 Thực nghiệm và Đánh giá Định lượng

7.1 Thiết lập Môi trường Phần cứng và Siêu tham số Huấn luyện


- **Phần cứng:** 1 GPU NVIDIA Tesla P100 (16GB VRAM), Intel Xeon CPU @ 2.20GHz.
- **Bộ tối ưu hóa:** AdamW với weight decay 10^{-4} , lịch trình giảm tốc độ học Cosine Decay với initial learning rate $\eta_0 = 10^{-4}$, giảm dần về $\eta_{\text{min}} = 10^{-6}$.
- **Batch size:** 8 mẫu/batch. Kỹ thuật gradient clipping giới hạn chuẩn vector gradient tối đa $\|\mathbf{g}\| \leq 10.0$.

7.2 Động thái Hội tụ qua 9 Epochs Huấn luyện

Bảng 4 ghi nhận chi tiết quá trình huấn luyện thực tế trong 9 epochs được trích xuất trực tiếp từ tệp nhật ký `training_history.csv`.

Bảng 4: Nhật ký quá trình huấn luyện và kiểm định mô hình qua 9 Epochs trên GPU Tesla P100.

Epoch	Train Loss	Train HM	Train Size	Val Loss	Val HM	Val Size	Thời gian (phút)
1	1.3313	0.7714	0.1505	3.2777	2.4906	0.3086	77.17
2	0.4543	0.0903	0.0887	2.4468	1.7176	0.2994	76.14
3	0.4134	0.0720	0.0807	2.9401	2.2475	0.2594	76.19
4	0.3903	0.0629	0.0759	2.6308	1.9974	0.2588	76.16
5	0.3729	0.0560	0.0727	1.7141	1.1474	0.2253	76.25
6	0.3613	0.0521	0.0701	0.8681	0.3722	0.1785	76.45
7	0.3490	0.0468	0.0680	0.7048	0.2598	0.1481	76.22
8	0.3410	0.0445	0.0668	0.6173	0.1891	0.1415	76.10
9	0.3372	0.0425	0.0670	0.5959	0.1987	0.1190	76.10



Hình 11: Đồ thị hội tụ của hàm mất mát tổng hợp (Total Loss) và các thành phần mất mát Heatmap, Size qua 9 Epochs.

Từ dữ liệu Bảng 4 và Hình 11, ta quan sát thấy:

- **Tốc độ hội tụ của Heatmap Loss:** Train Heatmap Loss giảm cực nhanh từ 0.7714 $\rightarrow$ 0.0903 ngay sau Epoch 2 (-88.3%), chứng minh hiệu quả phân tách tâm điểm của Coordinate Attention.
- **Tính ổn định của Size Loss:** Train Size Loss khởi đầu ở mức rất thấp 0.1505 nhờ khởi tạo bias -2.66 (như đã chứng minh tại Mục 4) và giảm đều đặn về 0.0670. Trên tập kiểm định, Val Size Loss giảm từ 0.3086 $\rightarrow$ 0.1190 (-61.5%).
- **Bước ngoặt Epoch 6–9:** Sau Epoch 5, hàm mất mát kiểm định (Val Loss) có bước nhảy vọt về chất lượng, giảm mạnh từ 1.7141 xuống 0.5959 ở Epoch 9, khẳng định mô hình không bị quá khớp (overfitting) và tổng quát hóa xuất sắc.

7.3 Kết quả Đánh giá Định lượng Benchmark


Mô hình tại Epoch 9 được đánh giá trên tập kiểm định độc lập với các chỉ số đo lường chuẩn mực của thị giác máy tính. Kết quả kiểm thử thành phần được so sánh trong Bảng 5 và kết quả định lượng chi tiết trên 3.000 frames kiểm thử tiêu biểu với ngưỡng tin cậy $\text{Conf} \geq 0.4$ được tổng hợp trong Bảng 6.

Bảng 5: Bảng đánh giá đóng góp của từng thành phần cải tiến (Ablation Study) trên tập kiểm định Anti-UAV.

Cấu hình Mô hình	Validation Loss	mAP@0.5 (%)	FPS (GPU)	Ghi chú / Tác động
Mô hình Đề xuất Đầy đủ (Epoch 9)	0.5959	76.31	21.4	Khớp thực nghiệm thực tế
- Triệt tiêu nền Temporal Triplet	-	~	~ 23.5	Tăng năng lượng nhiều nền tĩnh
- Cơ chế Coordinate Attention	-	~	~ 22.0	Mất khả năng lọc tọa độ chữ thập
- Khởi tạo Logit Prior ($b_0 = -2.66$)	> 2.50	< 50.0	~ 21.4	Dính hiện tượng Dying ReLU
- Hàm mất mát NWD Loss	-	~	~ 21.4	Giảm độ nhạy với hộp bao < 16×16

Bảng 6: Kết quả đánh giá định lượng chi tiết của mô hình CenterNet RGB trên 3.000 frames tiêu biểu tập kiểm thử Anti-UAV (Ngưỡng tin cậy Conf ≥ 0.4).

Chỉ số Đánh giá (Metric)	Giá trị Thực nghiệm	Đặc trưng Kỹ thuật / Ý nghĩa Tác chiến
Tổng số mẫu đánh giá	3.000 frames	Trải đều qua các chuỗi video kiểm thử độc lập
Ngưỡng tin cậy (Confidence Threshold)	≥ 0.40	Bộ lọc ngặt xác suất loại bỏ cảnh báo giả
Precision	99.85%	Triệt tiêu gần như hoàn toàn cảnh báo giả (0.15%)
Recall	69.12%	Độ bao quát trong điều kiện nguy trang, che khuất
F1-Score	81.69%	Cân bằng điều hòa tối ưu giữa Precision và Recall
mAP@0.5 (IoU)	76.31%	Độ chính xác trung bình ở ngưỡng chồng lấn IoU ≥ 0.5
mAP@0.75 (IoU)	23.65%	Độ chính xác ở ngưỡng định vị khắt khe IoU ≥ 0.75
NWD-mAP@0.5 (NWD)	63.84%	Metric chuẩn hóa Wasserstein cho Drone siêu nhỏ
Sai số tâm trung bình (Center Error)	4.17 pixels	Độ lệch tâm ngắm trên khung hình 1920×1080
Tốc độ suy luận (Inference Speed)	21.4 FPS	Thời gian xử lý: 2.34 phút cho 3.000 frames




Hình 12: Đường cong Precision-Recall của mô hình đề xuất trên tập kiểm thử Anti-UAV (mAP@0.5 = 76.31%, Precision = 99.85% tại ngưỡng Conf ≥ 0.4).

Các kết quả định lượng khẳng định:

- Độ chính xác Precision đạt đỉnh (99.85% tại Conf ≥ 0.4):** Với ngưỡng tin cậy phân loại 0.4, mô hình triệt tiêu gần như hoàn toàn các trường hợp báo động giả (chỉ 0.15% sai số dương giả), đáp ứng tiêu chuẩn an ninh phòng không khắt khe là không phát cảnh báo nhầm trên các nhiễu quang học nền trời.

2. **Cân bằng F1-Score đạt 81.69% và mAP@0.5 đạt 76.31%:** Giải pháp Sigmoid kết hợp Logit Prior Bias ($b_0 = -2.66$) loại bỏ hoàn toàn Dying ReLU, giúp mô hình duy trì độ bao quát Recall 69.12% ngay cả trong các chuỗi bay cơ động nhanh hoặc đổi hướng đột ngột.
3. **Hiệu quả vượt trội của NWD đối với vật thể siêu nhỏ (NWD-mAP = 63.84%):** Nhờ cơ chế đo khoảng cách Wasserstein liên tục (Mục 5.3), các drone kích thước dưới 32^2 px được hồi quy chính xác với sai số tâm trung bình chỉ **4.17 pixels** trên toàn khung hình 1920×1080 .
4. **Tốc độ suy luận thời gian thực 21.4 FPS trên GPU:** Mạng xử lý toàn bộ chuỗi 3.000 frames chỉ trong 2.34 phút, bảo đảm khả năng tích hợp trực tiếp vào hệ thống phòng không tự động mà không cần thuật toán NMS tiêu tốn tài nguyên.

7.4 Phân tích Trực quan Hóa Định tính



Hình 13: So sánh trực quan chi tiết giữa hộp boc dự đoán (Prediction – viền đỏ liền) và nhãn thực tế (Ground Truth – viền xanh lá nét đứt) trên các mẫu kiểm thử Anti-UAV trong điều kiện toàn cảnh và phóng đại cận cảnh.

Hình 13 thể hiện kết quả so sánh định tính chi tiết giữa nhãn thực tế Ground Truth (hộp nét đứt màu xanh lá) và dự đoán của mô hình CenterNet (hộp nét liền màu đỏ):

- **Độ nhạy và độ chính xác định vị:** Mô hình khoanh vùng chính xác mục tiêu drone ngay cả trên các nền ảnh phức tạp (bầu trời mây mù, nhà cao tầng, tán cây) với độ tin cậy Confidence cao.
- **Độ trùng khớp hộp boc (IoU & NWD):** Nhờ nhánh hồi quy kích thước Sigmoid Logit Prior và hàm mất mát NWD, hộp boc dự đoán bám khít lấy thân và cánh quạt drone, chỉ số IoU đạt mức cao và tâm đối tượng trùng khít với nhãn thực nghiệm.

8 Kết luận và Hướng Phát triển

Báo cáo đã trình bày toàn diện thiết kế kiến trúc, phân tích toán học giải tích và kết quả thực nghiệm của hệ thống phát hiện và bám bắt mục tiêu UAV dựa trên mô hình Anchor-Free CenterNet cải tiến thuần Visible RGB.

Những thành tựu khoa học then chốt bao gồm:

1. Chứng minh tính khả thi và hiệu quả vượt trội của giải pháp thay thế hệ thống đa phương thức RGBT tốn kém bằng chuỗi thời gian Temporal Triplet 9 kênh nhẹ, đạt độ chính xác cao (76.31% mAP@0.5, 99.85% Precision tại Conf ≥ 0.4) với tốc độ thời gian thực (21.4 FPS).
2. Đóng góp giải pháp toán học giải quyết triệt để hiện tượng Dying ReLU trong mạng phát hiện Anchor-Free: Thay thế bằng hàm Sigmoid và khởi tạo hệ số thiên vị Logit Prior Bias $b_0 = -2.66$ suy dẫn trực tiếp từ phân bố thực nghiệm $s_0 = 0.065$.
3. Tích hợp hoàn chỉnh hệ thống hàm mất mát tiên tiến Gaussian Focal Loss và Normalized Gaussian Wasserstein Distance (NWD), khắc phục nhược điểm nhảy bậc gradient của IoU truyền thống đối với micro-drone.
4. Xây dựng pipeline xử lý thời gian thực không dùng NMS kết hợp bộ lọc quán tính quỹ đạo Trajectory EMA Filter, hỗ trợ bám bắt mượt mà và duy trì khóa mục tiêu ngay cả khi bị che khuất tạm thời.

Hướng phát triển tương lai: Trong các giai đoạn tiếp theo, nhóm nghiên cứu hướng tới việc lượng tử hóa mô hình sang định dạng TensorRT / INT8 để triển khai trực tiếp trên các vi xử lý biên tiết kiệm năng lượng (NVIDIA Jetson Orin Nano), đồng thời tích hợp thêm cơ chế lọc Kalman đa hướng (Extended Kalman Filter) để dự báo quỹ đạo bay 3D trong không gian tác chiến thực tế.

Tài liệu tham khảo

- [1] X. Zhou, D. Wang, and P. Krahenbuhl, “Objects as points,” *arXiv preprint arXiv:1904.07850*, 2019.
- [2] H. Law and J. Deng, “Cornersnet: Detecting objects as paired keypoints,” in *Proceedings of the European Conference on Computer Vision (ECCV)*, 2018, pp. 734–750.
- [3] Q. Hou, D. Zhou, and J. Feng, “Coordinate attention for efficient mobile network design,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021, pp. 13713–13722.
- [4] J. Wang, C. Xu, W. Yang, and L. Yu, “A normalized Gaussian Wasserstein distance for tiny object detection,” *arXiv preprint arXiv:2110.13389*, 2021.
- [5] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollar, “Focal loss for dense object detection,” in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017, pp. 2980–2988.
- [6] K. He, X. Zhang, S. Ren, and J. Sun, “Identity mappings in deep residual networks,” in *Proceedings of the European Conference on Computer Vision (ECCV)*, 2016, pp. 630–645.
- [7] N. Jiang, K. Wang, X. Peng, X. Gao, et al., “Anti-UAV: A large-scale benchmark for vision-based UAV tracking,” *IEEE Transactions on Multimedia*, vol. 25, pp. 560–573, 2021.
- [8] T.-Y. Lin, P. Dollar, R. Girshick, K. He, B. Hariharan, and S. Belongie, “Feature pyramid networks for object detection,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 2117–2125.