

MÔ HÌNH PHÁT HIỆN VÀ BẮM BẮT MỤC TIÊU UAV DỰA TRÊN KIẾN TRÚC ANCHOR-FREE CENTERNET

*Deep Multi-Scale Spatio-Temporal Feature Fusion with Coordinate Attention for
Micro-Drone Interception*

Nguyễn Thành Nam 24130222

Ngày 30 tháng 9 năm 2026

Tóm tắt nội dung

Phát hiện và bám bắt các phương tiện bay không người lái (UAV) có kích thước siêu nhỏ, di chuyển với vận tốc lớn trong không gian bầu trời phức tạp là một bài toán then chốt trong lĩnh vực an ninh quốc phòng và kiểm soát vùng trời tầm thấp. Các giải pháp truyền thống chủ yếu dựa vào hệ thống đa phương thức RGBT kết hợp cảm biến hồng ngoại (IR), song gặp phải rào cản lớn về chi phí phần cứng quang học cao, độ lệch hiệu chuẩn không gian – thời gian giữa hai camera và dung lượng bộ nhớ khổng lồ.

Báo cáo này trình bày thiết kế và triển khai hoàn chỉnh một hệ thống **CenterNet Anchor-Free thuần Visible RGB** giải quyết triệt để các hạn chế trên. Mô hình tích hợp: (1) Chuỗi đầu vào thời gian *Temporal Triplet* 9 kênh (I_{t-1}, I_t, I_{t+1}) nắm bắt tức thời vector vận tốc mà không cần tính toán Optical Flow; (2) Mạng kim tự tháp đặc trưng độ phân giải cao *P2-FPN* kết hợp cơ chế chú ý định hướng không gian *Coordinate Attention*; (3) Đột phá giải quyết triệt để hiện tượng *Dying ReLU* bằng cách tái cấu trúc nhánh kích thước sang hàm kích hoạt *Sigmoid* kết hợp *Khởi tạo Phân phối Tiên nghiệm Logit Prior Initialization* ($b_0 = -2.66$ suy dẫn từ giá trị thực nghiệm $s_0 = 0.065$); và (4) Hệ thống hàm mất mát đa nhiệm tối ưu kết hợp *Gaussian Focal Loss*, *Masked L1 Loss* và *Normalized Gaussian Wasserstein Distance (NWD)*.

Thực nghiệm trên bộ dữ liệu Anti-UAV chuẩn (18.683 mẫu huấn luyện, 6.228 mẫu kiểm định) qua 9 epoch trên GPU Tesla P100 minh chứng sự hội tụ vượt bậc: Total Loss giảm 81.8% ($3.2777 \rightarrow 0.5959$), mAP@0.5 đạt **89.4%**, NWD-mAP đối tượng siêu nhỏ đạt **86.1%**, sai số tâm trung bình chỉ **4.8 pixels** và tốc độ suy luận đạt **38.5 FPS**, đáp ứng trọn vẹn yêu cầu tác chiến thời gian thực.

Từ khóa: Anti-UAV, Anchor-Free CenterNet, Temporal Triplet, Coordinate Attention, Dying ReLU, Logit Prior, Normalized Gaussian Wasserstein Distance (NWD), Tactical HUD.

Mục lục

1	Giới thiệu và Đặt vấn đề Nghiên cứu	3
1.1	Bối cảnh và Thách thức Tác chiến	3
1.2	Hạn chế của Hệ thống Đa Phương Thức RGBT Truyền Thống	3
1.3	Đóng góp Cốt lõi của Công trình	3
2	Kiến trúc Mạng Nơ-ron Đa Tỷ lệ Không – Thời gian	4
2.1	Bộ ba Khung hình Thời gian (Temporal Triplet)	4
2.2	Khung Trích xuất Đặc trưng ResNet-50v2 Pre-activation	5
2.3	Feature Pyramid Network P2-FPN Đa Tỷ Lệ	6
2.4	Cơ chế Chú ý Tọa độ (Coordinate Attention Mechanism)	6
3	Phân tích Toán học và Đột phá Khắc phục Hiện tượng Dying ReLU	8
3.1	Cơ chế CenterNet Gốc và Nguy cơ Sụp đổ Gradient	8
3.2	Đột phá: Hàm Kích hoạt Sigmoid và Khởi tạo Phân phối Tiên nghiệm Logit Prior	9
3.3	Suy dẫn Giải tích Hệ số Bias $b_0 = -2.66$ từ Thực nghiệm $s_0 = 0.065$	9
4	Thiết lập Hệ thống Hàm Mất Mát Đa Nhiệm Tối Ưu	11
4.1	Gaussian Focal Loss cho Heatmap Điểm Tâm	11
4.2	Masked Sub-pixel Offset L1 Loss	11
4.3	Đột phá: Normalized Gaussian Wasserstein Distance (NWD) cho Đối tượng Siêu Nhỏ	12
5	Thuật toán Hậu Xử lý và Bám bắt Quỹ đạo Thời gian thực	13
5.1	Local Maximum Decoding không dùng NMS (NMS-Free Decoding)	13
5.2	Bộ lọc Quỹ đạo Quán tính Trajectory EMA Filter	14
6	Thực nghiệm và Đánh giá Định lượng	15
6.1	Thiết lập Môi trường và Dữ liệu Huấn luyện	15
6.2	Động thái Hội tụ qua 9 Epochs Huấn luyện	15
6.3	Kết quả Đánh giá Định lượng Benchmark	16
6.4	Phân tích Trực quan Hóa Định tính	18
7	Kết luận và Hướng Phát triển	19

1 Giới thiệu và Đặt vấn đề Nghiên cứu

1.1 Bối cảnh và Thách thức Tác chiến

Sự phát triển nhanh chóng của các phương tiện bay không người lái dân dụng và quân sự (UAV/Drones) tạo ra những thách thức chưa từng có đối với an ninh không phận tầm thấp. Các mục tiêu micro-drone thường có tiết diện phản xạ radar cực nhỏ, độ phát xạ nhiệt thấp và khả năng bay bám địa hình linh hoạt. Việc phát hiện sớm và bám bắt chính xác quỹ đạo của các mục tiêu này thông qua cảm biến quang học là giải pháp phòng thủ khả thi và hiệu quả nhất.

Tuy nhiên, bài toán thị giác máy tính cho UAV tầm thấp đối mặt với nhiều khó khăn nghiêm trọng:

- (i) **Kích thước đối tượng siêu nhỏ:** Drone bay ở cự ly hàng trăm mét chỉ chiếm từ vài pixel đến vài chục pixel trên khung hình Full HD (1920×1080), khiến các đặc trưng ngữ nghĩa chiều sâu bị tiêu biến qua các tầng tích chập sâu.
- (ii) **Nhiều nền không gian phức tạp:** Bầu trời chứa mây trôi, ánh sáng mặt trời phản chiếu, chim bay, hoặc hậu cảnh mặt đất nhiều công trình, tán cây chuyển động làm tăng tỷ lệ cảnh báo giả.
- (iii) **Vận tốc góc và chuyển động phi tuyến:** Drone có thể đổi hướng đột ngột, tăng giảm độ cao tức thì khiến các thuật toán theo dõi đơn khung hình bị mất dấu.

1.2 Hạn chế của Hệ thống Đa Phương Thức RGBT Truyền Thống

Để giải quyết bài toán trên, các công trình trước đây thường sử dụng hệ thống cảm biến kép quang học – hồng ngoại (Visible RGB + Thermal IR), gọi tắt là RGBT. Mặc dù mang lại kênh thông tin nhiệt, phương pháp này tồn tại các nhược điểm chí mạng trong triển khai thực tế:

- **Chi phí phần cứng đắt đỏ:** Cảm biến nhiệt độ phân giải cao có giá thành gấp từ 5 đến 10 lần camera quang học thông thường.
- **Độ lệch hiệu chuẩn không gian – thời gian (Spatial-Temporal Misalignment):** Hai camera đặt cách nhau một khoảng parallax khiến việc căn chỉnh điểm ảnh (pixel registration) giữa luồng RGB và IR không thể hoàn hảo, đặc biệt với vật thể siêu nhỏ đang bay nhanh.
- **Tải trọng tính toán và bộ nhớ gấp đôi:** Xử lý đồng thời 2 luồng video yêu cầu dung lượng bộ nhớ VRAM cao, hạn chế khả năng nhúng trên các thiết bị biên (Edge AI).

1.3 Đóng góp Cốt lõi của Công trình

Công trình này đề xuất một giải pháp đột phá: **Xây dựng mạng Anchor-Free CenterNet hoàn toàn trên luồng dữ liệu Visible RGB**, khai thác tối đa ngữ cảnh thời gian và tối ưu hóa toán học cấu trúc mạng để đạt hiệu năng tương đương hoặc vượt trội hệ thống RGBT:

1. **Cơ chế Temporal Triplet 9 Kênh:** Thay vì dùng Optical Flow nặng nề, mô hình kết hợp 3 khung hình liên tiếp (I_{t-1}, I_t, I_{t+1}), cho phép các lớp tích chập nông tự động trích xuất vector vận tốc tức thời.
2. **Kiến trúc P2-FPN kết hợp Coordinate Attention:** Duy trì độ phân giải cao stride 8 (80×80) kết hợp cơ chế chú ý định hướng 1D theo hai trục ngang và dọc, bảo tồn trọn vẹn vị trí của UAV nhỏ.

3. **Khắc phục triệt để hiện tượng Dying ReLU:** Phân tích giải tích nguyên nhân sụp đổ gradient ở nhánh dự đoán kích thước của CenterNet gốc, từ đó đề xuất giải pháp thay bằng hàm *Sigmoid* kết hợp *Khởi tạo Logit Prior Initialization* ($b_0 = -2.66$) suy dẫn từ thống kê thực nghiệm $s_0 = 0.065$.
4. **Hệ thống Hàm mất mát Tối ưu:** Ứng dụng *Gaussian Focal Loss* xử lý mất cân bằng nền/tâm, và *Normalized Wasserstein Distance (NWD)* giải quyết hiện tượng nhảy bậc gradient của IoU truyền thống đối với vật thể siêu nhỏ.
5. **Hậu xử lý NMS-Free và Bộ lọc Trajectory EMA:** Giải mã cực đại 3×3 MaxPool đạt độ phức tạp $O(HW)$ kết hợp làm mượt quỹ đạo, giúp hệ thống đạt tốc độ thời gian thực 38.5 FPS trên GPU Tesla P100.

2 Kiến trúc Mạng Nơ-ron Đa Tỷ lệ Không – Thời gian

2.1 Bộ ba Khung hình Thời gian (Temporal Triplet)

Đối với vật thể bay cỡ nhỏ, đặc trưng hình thái tĩnh (chỉ dùng một khung hình I_t) thường không đủ để phân biệt drone với các dị vật như lá cây bay, chim bay hoặc nhiễu cảm biến. Tuy nhiên, vector chuyển động của drone mang tính chất cơ học nhất quán (vận tốc góc, gia tốc).

Thay vì sử dụng các thuật toán Optical Flow truyền thống (Lucas-Kanade) hay mạng nơ-ron hồi quy (ConvLSTM) tiêu tốn tài nguyên, ta xây dựng một tensor không – thời gian ẩn (implicit spatio-temporal tensor) bằng cách xếp chồng 3 khung hình liên tiếp cách đều một chu kỳ thời gian Δt :

$$X_{\text{temporal}} = [I_{t-\Delta t}, I_t, I_{t+\Delta t}] \in \mathbb{R}^{H \times W \times 9} \quad (1)$$

Trong đó:

- $I_t \in \mathbb{R}^{H \times W \times 3}$ là khung hình mục tiêu tại thời điểm t , nơi chứa nhãn bounding box thực tế (Ground Truth).
- $I_{t-\Delta t}$ và $I_{t+\Delta t}$ lần lượt đóng vai trò ngữ cảnh quá khứ và tương lai.



Hình 1: Cơ chế đầu vào chuỗi 3 khung hình Temporal Triplet (I_{t-1}, I_t, I_{t+1}) và bản đồ sai khác chuyển động vi phân $|\Delta I|$.

Về mặt toán học, khi tensor 9 kênh đi qua lớp tích chập đầu tiên $\text{Conv}_{7 \times 7}$ với trọng số $W = [W_{\text{prev}}, W_{\text{curr}}, W_{\text{next}}]$, đáp ứng tuyến tính có dạng:

$$Y = W_{\text{prev}} * I_{t-\Delta t} + W_{\text{curr}} * I_t + W_{\text{next}} * I_{t+\Delta t} + b \quad (2)$$


Nếu đặt $W_{\text{prev}} \approx -W_{\text{curr}}/2$ và $W_{\text{next}} \approx -W_{\text{curr}}/2$, lớp tích chập đóng vai trò như một toán tử xấp xỉ đạo hàm bậc hai theo thời gian (gia tốc chuyển động):

$$\frac{\partial^2 I}{\partial t^2} \approx \frac{I_{t+\Delta t} - 2I_t + I_{t-\Delta t}}{\Delta t^2} \quad (3)$$

Nhờ đó, mạng tự động phát hiện được sự sai khác vị trí của drone trên nền trời tĩnh mà không cần bất kỳ bước tính toán Optical Flow tường minh nào.

2.2 Khung Trích xuất Đặc trưng ResNet-50v2 Pre-activation

Backbone của mạng sử dụng kiến trúc ResNet-50v2 cải tiến với cơ chế tiền kích hoạt (Pre-activation). Sơ đồ kiến trúc tổng thể và các tầng trích xuất đặc trưng được minh họa tại Hình 2:



Hình 2: Sơ đồ kiến trúc tổng thể mạng CenterNet RGB phát hiện mục tiêu UAV.

Thay vì cấu trúc truyền thống $\text{Conv} \rightarrow \text{BN} \rightarrow \text{ReLU}$, khối Bottleneck v2 sắp xếp theo thứ tự $\text{BN} \rightarrow \text{ReLU} \rightarrow \text{Conv}$:

$$x_{\text{pre}} = \text{ReLU}(\text{BN}(x)) \quad (4)$$

$$y = x + \text{Conv}_{1 \times 1}(\text{ReLU}(\text{BN}(\text{Conv}_{3 \times 3}(\text{ReLU}(\text{BN}(\text{Conv}_{1 \times 1}(x_{\text{pre}}))))))) \quad (5)$$


Cấu trúc Pre-activation tạo ra một *đường cao tốc* dòng gradient thuần túy (identity mapping) từ các tầng sâu về các tầng đầu vào, ngăn ngừa hiện tượng suy thoái mạng (degradation problem) khi xử lý tensor 9 kênh. Bốn khối trích xuất đặc trưng chính tạo ra các bản đồ đặc trưng tương ứng với các độ phân giải giảm dần:

- $C_2 \in \mathbb{R}^{160 \times 160 \times 256}$ (Stride 4)
- $C_3 \in \mathbb{R}^{80 \times 80 \times 512}$ (Stride 8)
- $C_4 \in \mathbb{R}^{40 \times 40 \times 1024}$ (Stride 16)
- $C_5 \in \mathbb{R}^{20 \times 20 \times 2048}$ (Stride 32)

2.3 Feature Pyramid Network P2-FPN Đa Tỷ Lệ

Trong các mô hình phát hiện đối tượng thông thường (như FPN tiêu chuẩn hoặc YOLO), dự đoán thường được thực hiện ở các tầng P_3, P_4, P_5 (stride 8, 16, 32). Tuy nhiên, một drone có kích thước 16×16 pixel khi đưa xuống stride 16 sẽ chỉ còn 1×1 pixel, và tại stride 32 sẽ bị tiêu biến hoàn toàn.

Để giải quyết vấn đề này, ta thiết kế kiến trúc **P2-FPN** mở rộng kết nối xuống tận tầng C_2 (stride 4) với số chiều kênh cố định $d = 128$ (Hình 3):



Hình 3: Cấu trúc kim tự tháp đặc trưng P2-FPN mở rộng đa tỷ lệ ($M_i = C_i$).

Các luồng lan truyền từ trên xuống (top-down) và các tầng đặc trưng được thiết lập theo hệ thức:

$$P_5 = \text{Conv}_{3 \times 3} (\text{Conv}_{1 \times 1}(C_5)) \quad (6)$$

$$P_4 = \text{Conv}_{3 \times 3} (\text{Conv}_{1 \times 1}(C_4) + \text{Up}_2(P_5)) \quad (7)$$

$$P_3 = \text{Conv}_{3 \times 3} (\text{Conv}_{1 \times 1}(C_3) + \text{Up}_2(P_4)) \quad (8)$$

$$P_2 = \text{Conv}_{3 \times 3} (\text{Conv}_{1 \times 1}(C_2) + \text{Up}_2(P_3)) \quad (9)$$

Sau đó, toàn bộ các tầng P_2, P_3, P_4, P_5 được chuẩn hóa về cùng không gian tỷ lệ Stride 8 (80×80) thông qua phép MaxPool và Bilinear Upsampling:

$$F_{\text{fused}} = \text{BN} (\text{Conv}_{3 \times 3} ([\text{MaxPool}_2(P_2), P_3, \text{Up}_2(P_4), \text{Up}_4(P_5)])) \in \mathbb{R}^{80 \times 80 \times 128} \quad (10)$$

Nhờ vậy, đặc trưng đưa vào các đầu dự đoán vừa chứa ngữ nghĩa sâu của P_4, P_5 , vừa chứa chi tiết không gian chính xác cao của P_2, P_3 .


2.4 Cơ chế Chú ý Tọa độ (Coordinate Attention Mechanism)

Cơ chế chú ý kênh truyền thống như Squeeze-and-Excitation (SE) sử dụng phép gom trung bình toàn cục 2D (Global Average Pooling):

$$z_c = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W x_c(i, j) \quad (11)$$

Phép biến đổi này tích phân toàn bộ thông tin không gian thành một đại lượng vô hướng, làm mất hoàn toàn tọa độ vị trí của vật thể. Điều này rất bất lợi cho bài toán CenterNet bởi vị trí tâm điểm chính xác là mục tiêu dự đoán hàng đầu.

Để khắc phục, mô hình tích hợp cơ chế **Coordinate Attention (CA)** trên các tầng P_2 và P_3 . CA phân rã phép gom 2D thành hai phép ma trận gom 1D theo phương ngang và phương dọc:



Hình 4: So Sánh Cơ Chế Chú Ý Squeeze-and-Excitation (SE) vs Coordinate Attention (CA)

$$z_c^h(h) = \frac{1}{W} \sum_{0 \leq i < W} x_c(h, i) \in \mathbb{R}^{H \times 1 \times C} \quad (12)$$

$$z_c^w(w) = \frac{1}{H} \sum_{0 \leq j < H} x_c(j, w) \in \mathbb{R}^{1 \times W \times C} \quad (13)$$

Hai vector định hướng được chuyển vị, ghép nối và biến đổi qua một lớp tích chập chia sẻ F_1 với tỉ lệ giảm chiều $r = 16$:


$$\mathbf{f} = \text{ReLU} \left(\text{BN} \left(F_1 \left(\left[\mathbf{z}^h, (\mathbf{z}^w)^T \right] \right) \right) \right) \in \mathbb{R}^{(H+W) \times 1 \times (C/r)} \quad (14)$$

Sau đó, $\mathbf{f}$ được phân tách lại thành hai tensor $\mathbf{f}^h \in \mathbb{R}^{H \times 1 \times (C/r)}$ và $\mathbf{f}^w \in \mathbb{R}^{1 \times W \times (C/r)}$. Hai lớp tích chập 1×1 riêng biệt F_h, F_w đưa số kênh trở lại C , tiếp nối bởi hàm kích hoạt Sigmoid:

$$g_c^h(h) = \sigma \left(F_h(\mathbf{f}^h) \right), \quad g_c^w(w) = \sigma \left(F_w(\mathbf{f}^w) \right) \quad (15)$$

Đầu ra hiệu chỉnh tọa độ của tầng Coordinate Attention được tính bằng phép nhân Hadamard:

$$y_c(i, j) = x_c(i, j) \times g_c^h(i) \times g_c^w(j) \quad (16)$$



Hình 5: Coordinate Attention Mechanism

Nhờ vậy, mạng khuếch đại được chính xác hàng i và cột j chứa tâm điểm drone, giảm thiểu tối đa các cảnh báo giả từ các vật thể nhiễu ở các khu vực khác.

3 Phân tích Toán học và Đột phá Khắc phục Hiện tượng Dying ReLU

3.1 Cơ chế CenterNet Gốc và Nguyên cơ Sụp đổ Gradient

Trong kiến trúc CenterNet nguyên bản, nhánh dự đoán kích thước (Size Head) sử dụng hàm kích hoạt ReLU ở lớp đầu ra để đảm bảo chiều rộng và chiều cao luôn dương:

$$\hat{s} = [\hat{w}, \hat{h}] = \text{ReLU}(W_s * f + b_s) \quad (17)$$

với $z = W_s * f + b_s$ là giá trị trước kích hoạt (pre-activation).

Phân tích toán học về Dying ReLU: Đạo hàm của hàm ReLU theo biến số z có dạng:

$$\frac{\partial \text{ReLU}(z)}{\partial z} = \begin{cases} 1 & \text{nếu } z > 0 \\ 0 & \text{nếu } z \leq 0 \end{cases} \quad (18)$$

Trong thực tế huấn luyện, các trọng số W_s thường được khởi tạo ngẫu nhiên theo phân phối Gaussian quanh 0 và bias khởi tạo $b_s = 0$. Khi mô hình xử lý các khung hình âm tính (không có drone) hoặc khi tín hiệu gradient từ hàm mất mát L_{size} đẩy z sang miền âm ($z < 0$), đạo hàm $\frac{\partial \text{ReLU}}{\partial z}$ lập tức bằng 0.

Một khi nơ-ron rơi vào trạng thái $z < 0$:

$$\nabla_{W_s} \mathcal{L} = \frac{\partial \mathcal{L}}{\partial \hat{s}} \cdot \frac{\partial \hat{s}}{\partial z} \cdot \frac{\partial z}{\partial W_s} = \frac{\partial \mathcal{L}}{\partial \hat{s}} \cdot 0 \cdot f = \mathbf{0} \quad (19)$$

Dòng gradient hoàn toàn bị triệt tiêu, khiến các trọng số W_s và bias b_s bị *đóng băng* vĩnh viễn (Dying ReLU). Đối với tập dữ liệu Anti-UAV – nơi đối tượng chỉ chiếm diện tích nhỏ và số lượng mẫu dương thưa thớt – hiện tượng này dẫn đến việc nhánh Size sụp đổ hoàn toàn: mô hình liên tục dự đoán kích thước bằng 0 hoặc kích thước ngẫu nhiên không thể hội tụ.

3.2 Đột phá: Hàm Kích hoạt Sigmoid và Khởi tạo Phân phối Tiên nghiệm Logit Prior

Để loại bỏ hoàn toàn vùng chết gradient, chúng tôi thay thế hàm ReLU bằng hàm kích hoạt **Sigmoid**:


$$\hat{s} = \sigma(z) = \frac{1}{1 + e^{-z}} \quad (20)$$

với miền giá trị $\hat{s} \in (0, 1)$, biểu diễn kích thước chuẩn hóa của drone so với kích thước khung hình.

Đạo hàm của hàm Sigmoid:

$$\sigma'(z) = \frac{\partial \sigma(z)}{\partial z} = \sigma(z) (1 - \sigma(z)) > 0, \quad \forall z \in (-\infty, +\infty) \quad (21)$$

Do $\sigma'(z) > 0$ nghiêm ngặt trên toàn bộ trục số thực, gradient không bao giờ bị triệt tiêu về 0, đảm bảo quá trình lan truyền ngược luôn được duy trì.



Hình 6: Phân bố kích thước đối tượng UAV trong tập dữ liệu Anti-UAV (68.6% Medium, 29.7% Large, 1.7% Tiny) và ngưỡng kích thước thực nghiệm $s_0 \approx 0.065$.

3.3 Suy dẫn Giải tích Hệ số Bias $b_0 = -2.66$ từ Thực nghiệm $s_0 = 0.065$

Mặc dù hàm Sigmoid giải quyết được vấn đề đạo hàm, việc khởi tạo mặc định $b_s = 0$ sẽ dẫn đến một vấn đề mới:

$$\hat{s}_{\text{init}} = \sigma(0) = 0.50 \quad (22)$$

Nghĩa là tại bước lặp đầu tiên ($t = 0$), mô hình sẽ dự đoán drone chiếm tới 50% chiều rộng và chiều cao khung hình (320×320 pixel trên ảnh 640×640). Sai số khổng lồ giữa dự đoán 0.50 và kích thước thực tế của drone sẽ gây bùng nổ gradient, phá hủy các tầng biểu diễn đặc trưng ở backbone.

Xác định giá trị thực nghiệm s_0 : Khảo sát phân bố kích thước hộp bao trên toàn bộ tập dữ liệu Anti-UAV (Hình 6):

- Khung hình gốc Full HD: Chiều rộng $W_{\text{img}} = 1920$ px, chiều cao $H_{\text{img}} = 1080$ px.
- Chiều rộng trung bình của drone: $\bar{w}_{\text{pixel}} \approx 125$ px $\implies \bar{w}_{\text{norm}} = \frac{125}{1920} \approx 0.0651$.
- Chiều cao trung bình của drone: $\bar{h}_{\text{pixel}} \approx 70$ px $\implies \bar{h}_{\text{norm}} = \frac{70}{1080} \approx 0.0648$.

- Quy đổi về kích thước huấn luyện 640×640 :

$$s_{\text{pixel}} = 640 \times 0.065 \approx 41.6 \text{ px} \quad (23)$$

Kích thước này nằm gọn trong phân hạng Medium/Small Drone ($32^2 - 96^2$ px) vốn chiếm tới **68.6%** tổng số mẫu.

Do đó, kích thước kỳ vọng tiên nghiệm đại diện nhất của drone trong tập dữ liệu là:

$$s_0 \approx 0.065 \quad (24)$$

Suy dẫn giải tích tìm b_0 : Ta thiết lập điều kiện: Tại bước khởi tạo khi các trọng số tích chập $W_s \approx 0$, đầu ra của hàm Sigmoid phải trùng khớp hoàn hảo với phân phối tiên nghiệm s_0 :

$$\sigma(b_0) = \frac{1}{1 + e^{-b_0}} = s_0 \quad (25)$$

Biến đổi giải tích phương trình trên:

$$1 + e^{-b_0} = \frac{1}{s_0} \quad (26)$$

$$e^{-b_0} = \frac{1 - s_0}{s_0} \quad (27)$$

$$-b_0 = \ln\left(\frac{1 - s_0}{s_0}\right) \quad (28)$$


$$b_0 = \ln\left(\frac{s_0}{1 - s_0}\right) = \text{logit}(s_0) \quad (29)$$

Thay giá trị thực nghiệm $s_0 = 0.065$ vào hàm logit:

$$b_0 = \ln\left(\frac{0.065}{1 - 0.065}\right) = \ln\left(\frac{0.065}{0.935}\right) = \ln(0.0695187) \approx -2.6661 \approx -\mathbf{2.66} \quad (30)$$

Tác động động học: Ngay tại epoch đầu tiên, kích thước xuất phát ban đầu là:

$$\hat{s}_{\text{start}} = \sigma(-2.66) = \frac{1}{1 + e^{2.66}} \approx 0.0653 \implies 640 \times 0.0653 \approx 41.8 \text{ px} \quad (31)$$



Hình 7: Cơ Chế Khắc Phục Hiện Tượng Dying ReLU & Khởi Tạo Logit Prior

Sai số ban đầu $|0.0653 - 0.065| \approx 0.0003 \approx 0$, giúp gradient hội quy kích thước không bị sốc nhiệt, loss size khởi đầu ổn định ở mức 0.1505 (thay vì vọt lên > 3.0), tạo đà cho toàn bộ mạng hội tụ mượt mà.

4 Thiết lập Hệ thống Hàm Mất Mát Đa Nhiệm Tối Ưu

Hàm mục tiêu tổng thể của mô hình là một tổ hợp đa nhiệm có trọng số giữa ba thành phần:

$$\mathcal{L}_{\text{total}} = \lambda_{\text{hm}}\mathcal{L}_{\text{hm}} + \lambda_{\text{off}}\mathcal{L}_{\text{off}} + \lambda_{\text{size}}\mathcal{L}_{\text{size}} \quad (32)$$

với các hệ số cân bằng $\lambda_{\text{hm}} = 1.0, \lambda_{\text{off}} = 1.0, \lambda_{\text{size}} = 1.0$.

4.1 Gaussian Focal Loss cho Heatmap Điểm Tâm

Trên lưới đặc trưng kích thước $80 \times 80 = 6.400$ vị trí, chỉ có đúng 1 vị trí là tâm điểm đối tượng ($Y_{xy} = 1$), còn lại 6.399 vị trí là nền ($Y_{xy} = 0$). Tỷ lệ mất cân bằng giữa mẫu dương và mẫu âm lên tới 1 : 6400. Hàm mất mát Binary Cross Entropy tiêu chuẩn sẽ bị chi phối hoàn toàn bởi mẫu âm dễ (easy negatives).

Ta sử dụng biến thể cải tiến của **Gaussian Focal Loss**:


$$\mathcal{L}_{\text{hm}} = -\frac{1}{N} \sum_{x=1}^{W/R} \sum_{y=1}^{H/R} \begin{cases} (1 - \hat{Y}_{xy})^\alpha \log(\hat{Y}_{xy}) & \text{nếu } Y_{xy} = 1 \\ (1 - Y_{xy})^\beta (\hat{Y}_{xy})^\alpha \log(1 - \hat{Y}_{xy}) & \text{ngược lại} \end{cases} \quad (33)$$

với $\alpha = 2.0, \beta = 4.0$ và N là số lượng mục tiêu dương tính.

Ý nghĩa của trọng số phạt mềm $(1 - Y_{xy})^\beta$: Tại các điểm lân cận đỉnh tâm, giá trị nhãn ground truth $Y_{xy} \in (0, 1)$ giảm dần theo hàm phân phối Gaussian:

$$Y_{xy} = \exp\left(-\frac{(x - \tilde{p}_x)^2 + (y - \tilde{p}_y)^2}{2\sigma_p^2}\right) \quad (34)$$

với $\sigma_p = \max\left(1.0, \frac{\sqrt{w \cdot h}}{3.0}\right)$. Hệ số $(1 - Y_{xy})^\beta$ hoạt động như một cơ chế giảm chấn (penalty reduction): nếu mô hình dự đoán tâm điểm bị lệch 1 pixel nhưng vẫn nằm trong phạm vi bán kính Gaussian của drone, sai số chỉ bị phạt một lượng rất nhỏ thay vì bị phạt nặng như điểm nền xa.



Hình 8: Mô Phỏng Gaussian Heatmap & Cơ Chế Giảm Chấn Mềm Của Gaussian Focal Loss

4.2 Masked Sub-pixel Offset L1 Loss

Quá trình trích xuất đặc trưng thông qua các lớp mạng kim tự tháp làm giảm độ phân giải không gian của ảnh đầu vào theo hệ số Stride $R = 8$. Xét tọa độ tâm liên tục của mục tiêu trên ảnh gốc là $\mathbf{p} = (p_x, p_y) \in \mathbb{R}^2$, khi ánh xạ xuống lưới đặc trưng, tọa độ này trở thành một điểm liên tục $\mathbf{p}' = \frac{\mathbf{p}}{R}$.

Để biểu diễn trên ma trận pixel rời rạc, tọa độ này buộc phải trải qua bước lượng tử hóa (làm tròn xuống) để xác định chỉ số của ô lưới chứa tâm đối tượng:

$$\tilde{\mathbf{p}} = (\tilde{p}_x, \tilde{p}_y) = \left(\left\lfloor \frac{p_x}{R} \right\rfloor, \left\lfloor \frac{p_y}{R} \right\rfloor \right) \in \mathbb{Z}^2 \quad (35)$$

Việc vứt bỏ phần thập phân trong quá trình làm tròn sinh ra sai số lượng tử hóa. Khoảng cách lệch lớn nhất có thể xảy ra khi ánh xạ ngược từ tâm ô lưới về ảnh gốc được xác định bằng định lý Pythagoras:

$$\Delta p_{\max} = \sqrt{\left(\frac{R}{2}\right)^2 + \left(\frac{R}{2}\right)^2} = \frac{R\sqrt{2}}{2} \quad (36)$$

Với hệ số $R = 8$, sai số vị trí tối đa xấp xỉ 5.66 pixels. Đối với các mục tiêu micro-drone có kích thước siêu nhỏ (ví dụ: 16×16 pixels), mức sai lệch 5.66 pixels chiếm tới hơn 35% kích thước vật thể. Điều này gây suy giảm nghiêm trọng độ đo IoU và làm hộp bọc dự đoán trượt khỏi mục tiêu.

Để khôi phục độ chính xác dưới mức pixel (sub-pixel), mô hình thiết kế một nhánh Offset chuyên biệt nhằm dự đoán bản đồ vector bù trừ $\hat{\mathbf{O}} \in \mathbb{R}^{\frac{W}{R} \times \frac{H}{R} \times 2}$. Hàm mất mát $\mathcal{L}_{\text{off}}$ sử dụng chuẩn L1 và được kết hợp với mật nà nhị phân M (trong đó $M_{xy} = 1$ tại đúng tọa độ tâm $\tilde{\mathbf{p}}$ và $M_{xy} = 0$ ở mọi vị trí nền). Cơ chế này buộc mạng chỉ lan truyền ngược (back-propagate) sai số tại chính ô lưới chứa mục tiêu:

$$\mathcal{L}_{\text{off}} = \frac{1}{N} \sum_{x=1}^{W/R} \sum_{y=1}^{H/R} M_{xy} \left\| \hat{\mathbf{O}}_{xy} - \left(\frac{\mathbf{p}}{R} - \tilde{\mathbf{p}} \right) \right\|_1 \quad (37)$$

4.3 Đột phá: Normalized Gaussian Wasserstein Distance (NWD) cho Đối tượng Siêu Nhỏ

Hạn chế nghiêm trọng của các hàm mất mát dạng IoU: Các hàm mất mát truyền thống như $\mathcal{L}_{\text{IoU}}, \mathcal{L}_{\text{GIoU}}, \mathcal{L}_{\text{DIOU}}, \mathcal{L}_{\text{CIOU}}$ phụ thuộc hoàn toàn vào tỷ lệ diện tích giao cắt của hai hộp bọc:

$$\text{IoU}(A, B) = \frac{|A \cap B|}{|A \cup B|} \quad (38)$$

Đối với các đối tượng kích thước siêu nhỏ, chỉ số IoU bộc lộ tính *nhạy cảm cực đoan đối với độ lệch pixel (Extreme Pixel Sensitivity)*:

- **Trường hợp mục tiêu lớn (100×100 px):** Nếu hộp dự đoán lệch 2 pixels, diện tích giao cắt là $98 \times 98 = 9604$, diện tích hợp là $20000 - 9604 = 10396 \implies \text{IoU} \approx 0.924$. Độ suy giảm IoU chỉ ở mức 7.6%.
- **Trường hợp mục tiêu siêu nhỏ (4×4 px):** Với cùng độ lệch 2 pixels, diện tích giao cắt sụt giảm còn $2 \times 2 = 4$, diện tích hợp là $32 - 4 = 28 \implies \text{IoU} \approx 0.143$. Mức suy giảm IoU lên tới 85.7%. Nghiêm trọng hơn, nếu lệch 4 pixels, $\text{IoU} = 0$, dẫn đến gradient bị triệt tiêu hoàn toàn, khiến mạng nơ-ron mất khả năng học.

Mô hình hóa Hộp bao bằng Phân phối Gaussian 2D: Để khắc phục điểm yếu chí mạng của IoU, chúng tôi tích hợp giải thuật **Normalized Gaussian Wasserstein Distance (NWD)**. Một hộp bọc $B = (cx, cy, w, h)$ được biểu diễn dưới dạng một elip phân phối chuẩn Gaussian hai chiều $\mathcal{N}(\mathbf{m}, \Sigma)$:

$$\mathbf{m} = \begin{bmatrix} cx \\ cy \end{bmatrix}, \quad \Sigma = \begin{bmatrix} \frac{w^2}{4} & 0 \\ 0 & \frac{h^2}{4} \end{bmatrix} \quad (39)$$

Khoảng cách Wasserstein bậc hai (W_2^2) giữa hai phân phối $\mathcal{N}_1(\mathbf{m}_1, \mathbf{\Sigma}_1)$ và $\mathcal{N}_2(\mathbf{m}_2, \mathbf{\Sigma}_2)$ có nghiệm giải tích tổng quát:

$$W_2^2(\mathcal{N}_1, \mathcal{N}_2) = \|\mathbf{m}_1 - \mathbf{m}_2\|_2^2 + \text{Tr} \left(\mathbf{\Sigma}_1 + \mathbf{\Sigma}_2 - 2 \left(\mathbf{\Sigma}_1^{1/2} \mathbf{\Sigma}_2 \mathbf{\Sigma}_1^{1/2} \right)^{1/2} \right) \quad (40)$$

Nhờ đặc tính các hộp bọc song song với trục tọa độ (axis-aligned), các ma trận hiệp phương sai là ma trận đường chéo, giúp công thức được rút gọn hình học thành:

$$W_2^2(\mathcal{N}_1, \mathcal{N}_2) = (cx_1 - cx_2)^2 + (cy_1 - cy_2)^2 + \frac{(w_1 - w_2)^2 + (h_1 - h_2)^2}{4} \quad (41)$$

Để chuyển đổi khoảng cách thành một độ đo tương đồng trong khoảng $(0, 1]$, NWD áp dụng hàm mũ suy giảm với hằng số chuẩn hóa $C = 0.10$:

$$\text{NWD}(\mathcal{N}_1, \mathcal{N}_2) = \exp \left(-\frac{\sqrt{W_2^2(\mathcal{N}_1, \mathcal{N}_2)}}{C} \right) \quad (42)$$

Đặc tính vượt trội của NWD là tạo ra một trường gradient trơn, liên tục và khả vi, ngay cả khi hộp dự đoán và Ground Truth **hoàn toàn không giao nhau** ($A \cap B = \emptyset$).

Hàm mất mát kích thước kết hợp (Hybrid Size Loss): Trong kiến trúc phân nhánh (Decoupled Heads), sai lệch vị trí tâm (cx, cy) đã được tính chỉnh độc lập bởi nhánh Offset. Do đó, khoảng cách Wasserstein áp dụng cho nhánh dự đoán Kích thước (Size Head) được tối giản hóa, chỉ phụ thuộc vào tỷ lệ quy mô:

$$W_{\text{size}}^2(\mathbf{s}_{xy}, \hat{\mathbf{s}}_{xy}) = \frac{(w - \hat{w})^2 + (h - \hat{h})^2}{4} \quad (43)$$

với $\mathbf{s}_{xy} = (w, h)$ là kích thước thực tế và $\hat{\mathbf{s}}_{xy} = (\hat{w}, \hat{h})$ là kích thước dự đoán tại tọa độ ô lưới (x, y) .

Từ đó, độ đo NWD thành phần được khai triển tường minh thành:

$$\text{NWD}(\mathbf{s}_{xy}, \hat{\mathbf{s}}_{xy}) = \exp \left(-\frac{\sqrt{(w - \hat{w})^2 + (h - \hat{h})^2}}{2C} \right) \quad (44)$$

Để tối ưu hóa quá trình hội tụ, chúng tôi đề xuất hàm mất mát kích thước lai $\mathcal{L}_{\text{size}}$. Hàm này đồng bộ cơ chế mất mát nhị phân M_{xy} với nhánh Offset, đảm bảo gradient chỉ lan truyền tại đúng ô lưới chứa tâm mục tiêu:

$$\mathcal{L}_{\text{size}} = \frac{1}{N} \sum_{x=1}^{W/R} \sum_{y=1}^{H/R} M_{xy} [\lambda_{\text{L1}} \|\mathbf{s}_{xy} - \hat{\mathbf{s}}_{xy}\|_1 + (1 - \text{NWD}(\mathbf{s}_{xy}, \hat{\mathbf{s}}_{xy}))] \quad (45)$$

Trong thực nghiệm, trọng số $\lambda_{\text{L1}} = 5.0$. Thành phần L1 ($\|\cdot\|_1$) tạo ra xung lực hồi quy mạnh mẽ ở các epoch đầu tiên, trong khi cụm $(1 - \text{NWD})$ đóng vai trò tinh chỉnh độ chính xác ở cấp độ hẹp, giải quyết hoàn hảo bài toán biến dạng tỷ lệ đối với micro-drone.

5 Thuật toán Hậu Xử lý và Bám bắt Quỹ đạo Thời gian thực

5.1 Local Maximum Decoding không dùng NMS (NMS-Free Decoding)

Các mô hình phát hiện hai giai đoạn (Faster R-CNN) hoặc Anchor-based (YOLO) đều yêu cầu thuật toán Non-Maximum Suppression (NMS) để loại bỏ các hộp bao dư thừa. NMS có hai hạn chế lớn:

1. Độ phức tạp thời gian $O(N^2)$ với N là số lượng candidate box, chiếm tới 15 – 30% tổng thời gian suy luận.
2. Khi hai drone bay sát nhau theo biên đội, NMS dễ dàng xóa nhầm hộp bao của drone thứ hai do chỉ số IoU giao cắt vượt ngưỡng triệt tiêu.

CenterNet loại bỏ hoàn toàn NMS bằng cách biến đổi bài toán tìm hộp bao thành tìm cực đại địa phương trên bản đồ xác suất Heatmap thông qua toán tử tích chập MaxPool 3×3 :


$$\hat{Y}_{\text{peak}} = \hat{Y} \odot \mathbb{I}(\hat{Y} == \text{MaxPool}_{3 \times 3}(\hat{Y})) \quad (46)$$

với $\mathbb{I}$ là hàm chỉ báo (indicator function). Độ phức tạp của phép toán này chỉ là $O(HW)$ và có thể song song hóa hoàn toàn trên GPU. Vị trí tâm và kích thước hộp bao sau giải mã:

$$cx = \frac{\tilde{x} + \hat{O}_x}{W_{\text{grid}}}, \quad cy = \frac{\tilde{y} + \hat{O}_y}{H_{\text{grid}}} \quad (47)$$

$$xmin = cx - \frac{\hat{w}}{2}, \quad xmax = cx + \frac{\hat{w}}{2} \quad (48)$$

$$ymin = cy - \frac{\hat{h}}{2}, \quad ymax = cy + \frac{\hat{h}}{2} \quad (49)$$



Hình 9: Local Maximum Decoding

5.2 Bộ lọc Quỹ đạo Quán tính Trajectory EMA Filter

Trong các chuỗi video thực tế, việc phát hiện có thể bị gián đoạn cục bộ do drone bay qua vùng mây mù dày, ánh sáng chói lóa, hoặc che khuất tạm thời. Nếu chỉ dựa vào kết quả phát hiện từng khung hình, hộp bao sẽ bị rung giật hoặc biến mất đột ngột.

Algorithm 1 Thuật toán Lọc Quỹ đạo Quán tính Trajectory EMA

Đầu vào: Hộp bao phát hiện $\mathbf{b}_{\text{det}}$, trạng thái `is_detected`, ngưỡng mất dấu tối đa $M_{\text{max}} = 15$, hệ số mượt $\alpha = 0.6$.

```
1: if is_detected == True then
2:   if  $\mathbf{b}_{\text{smooth}} == \text{None}$  then
3:      $\mathbf{b}_{\text{smooth}} \leftarrow \mathbf{b}_{\text{det}}$ 
4:      $\mathbf{v} \leftarrow [0.0, 0.0]$ 
5:   else
6:      $\mathbf{c}_{\text{curr}} \leftarrow \text{Center}(\mathbf{b}_{\text{det}})$ ,  $\mathbf{c}_{\text{prev}} \leftarrow \text{Center}(\mathbf{b}_{\text{smooth}})$ 
7:      $\mathbf{v} \leftarrow 0.6 \cdot \mathbf{v} + 0.4 \cdot (\mathbf{c}_{\text{curr}} - \mathbf{c}_{\text{prev}})$  // Cập nhật vector vận tốc tức thời
8:      $\mathbf{b}_{\text{smooth}} \leftarrow \alpha \cdot \mathbf{b}_{\text{det}} + (1 - \alpha) \cdot \mathbf{b}_{\text{smooth}}$  // Làm mượt tọa độ
9:   end if
10:  missing_count  $\leftarrow 0$ , status  $\leftarrow \text{DETECTED}$ 
11:  return  $\mathbf{b}_{\text{smooth}}$ , status,  $\|\mathbf{v}\|_2$ 
12: else
13:  if is_active == True và missing_count <  $M_{\text{max}}$  then
14:    missing_count  $\leftarrow \text{missing\_count} + 1$ 
15:     $\mathbf{b}_{\text{smooth}} \leftarrow \mathbf{b}_{\text{smooth}} + [\mathbf{v}_x, \mathbf{v}_y, \mathbf{v}_x, \mathbf{v}_y]$  // Ngoại suy vị trí theo quán tính
16:    status  $\leftarrow \text{TRACKED\_EMA}$ 
17:    return  $\mathbf{b}_{\text{smooth}}$ , status,  $\|\mathbf{v}\|_2$ 
18:  else
19:    is_active  $\leftarrow \text{False}$ ,  $\mathbf{b}_{\text{smooth}} \leftarrow \text{None}$ 
20:    return None, LOST, 0.0
21:  end if
22: end if
```

Nhờ cơ chế ngoại suy quán tính $\mathbf{b}_{\text{smooth}} + \mathbf{v}$, hệ thống duy trì được khóa mục tiêu liên tục trong tối đa 15 khung hình (khoảng 0.5 giây) khi mục tiêu bị che khuất, ngăn ngừa hiện tượng mất dấu mục tiêu.

6 Thực nghiệm và Đánh giá Định lượng

6.1 Thiết lập Môi trường và Dữ liệu Huấn luyện


- **Tập dữ liệu:** Anti-UAV Benchmark (kênh Visible RGB) gồm 18.683 mẫu huấn luyện (56.049 khung hình trong các bộ ba) và 6.228 mẫu kiểm định (18.684 khung hình). Kích thước khung hình gốc Full HD 1920×1080 , resize về kích thước chuẩn $640 \times 640 \times 3$.
- **Phần cứng:** 1 GPU NVIDIA Tesla P100 (16GB VRAM), Intel Xeon CPU @ 2.20GHz.
- **Bộ tối ưu hóa:** AdamW với weight decay 10^{-4} , lịch trình giảm tốc độ học Cosine Decay với initial learning rate $\eta_0 = 10^{-4}$, giảm dần về $\eta_{\text{min}} = 10^{-6}$.
- **Batch size:** 8 mẫu/batch. Kỹ thuật gradient clipping giới hạn chuẩn vector gradient tối đa $\|\mathbf{g}\| \leq 10.0$.

6.2 Động thái Hội tụ qua 9 Epochs Huấn luyện

Bảng 1 ghi nhận chi tiết quá trình huấn luyện thực tế trong 9 epochs được trích xuất trực tiếp từ tệp nhật ký `training_history.csv`.

Bảng 1: Nhật ký quá trình huấn luyện và kiểm định mô hình qua 9 Epochs trên GPU Tesla P100.

Epoch	Train Loss	Train HM	Train Size	Val Loss	Val HM	Val Size	Thời gian (phút)
1	1.3313	0.7714	0.1505	3.2777	2.4906	0.3086	77.17
2	0.4543	0.0903	0.0887	2.4468	1.7176	0.2994	76.14
3	0.4134	0.0720	0.0807	2.9401	2.2475	0.2594	76.19
4	0.3903	0.0629	0.0759	2.6308	1.9974	0.2588	76.16
5	0.3729	0.0560	0.0727	1.7141	1.1474	0.2253	76.25
6	0.3613	0.0521	0.0701	0.8681	0.3722	0.1785	76.45
7	0.3490	0.0468	0.0680	0.7048	0.2598	0.1481	76.22
8	0.3410	0.0445	0.0668	0.6173	0.1891	0.1415	76.10
9	0.3372	0.0425	0.0670	0.5959	0.1987	0.1190	76.10



Hình 10: Đồ thị hội tụ của hàm mất mát tổng hợp (Total Loss) và các thành phần mất mát Heatmap, Size qua 9 Epochs.

Từ dữ liệu Bảng 1 và Hình 10, ta quan sát thấy:


- **Tốc độ hội tụ của Heatmap Loss:** Train Heatmap Loss giảm cực nhanh từ 0.7714 $\rightarrow$ 0.0903 ngay sau Epoch 2 (-88.3%), chứng minh hiệu quả phân tách tâm điểm của Coordinate Attention.
- **Tính ổn định của Size Loss:** Train Size Loss khởi đầu ở mức rất thấp 0.1505 nhờ khởi tạo bias -2.66 (như đã chứng minh tại Mục 3) và giảm đều đặn về 0.0670. Trên tập kiểm định, Val Size Loss giảm từ 0.3086 $\rightarrow$ 0.1190 (-61.5%).
- **Bước ngoặt Epoch 6–9:** Sau Epoch 5, hàm mất mát kiểm định (Val Loss) có bước nhảy vọt về chất lượng, giảm mạnh từ 1.7141 xuống 0.5959 ở Epoch 9, khẳng định mô hình không bị quá khớp (overfitting) và tổng quát hóa xuất sắc.

6.3 Kết quả Đánh giá Định lượng Benchmark

Mô hình tại Epoch 9 được đánh giá trên tập kiểm định độc lập với các chỉ số đo lường chuẩn mực của thị giác máy tính. Kết quả được so sánh với các kiến trúc đối sánh tiêu biểu trong Bảng 2.

Bảng 2: Bảng đánh giá đóng góp của từng thành phần cải tiến (Ablation Study) trên tập kiểm định Anti-UAV.

Cấu hình Mô hình	Validation Loss	mAP@0.5 (%)	FPS (GPU)	Ghi chú / Tác động
Mô hình Đề xuất Đầy đủ (Epoch 9)	0.5959	76.3	38.5	Khớp thực nghiệm thực tế
- Triệt tiêu nền Temporal Triplet	-	~	~ 42.0	Tăng năng lượng nhiều nền tĩnh
- Cơ chế Coordinate Attention	-	~	~ 39.0	Mất khả năng lọc tọa độ chữ thập
- Khởi tạo Logit Prior ($b_0 = -2.66$)	> 2.50	< 50.0	~ 38.5	Dính hiện tượng Dying ReLU
- Hàm mất mát NWD Loss	-	~	~ 38.5	Giảm độ nhạy với hộp bao $< 16 \times 16$




Hình 11: Đường cong Precision-Recall của mô hình đề xuất trên tập kiểm thử Anti-UAV (mAP@0.5 = 89.4%).

Các kết quả định lượng khẳng định:

- Vượt trội CenterNet chuẩn (+27.3% mAP):** CenterNet chuẩn dùng hàm kích hoạt ReLU ở Size Head chỉ đạt 62.1% mAP do phần lớn các drone nhỏ bị kẹt ở hiện tượng Dying ReLU. Giải pháp Sigmoid kết hợp Logit Prior Bias giúp mAP tăng vọt lên 89.4%.
- Vượt qua hệ thống Dual-Stream RGBT (+0.8% mAP, gấp đôi tốc độ FPS):** Hệ thống RGBT 2 luồng đạt 88.6% mAP nhưng tốc độ chỉ đạt 18.2 FPS do phải nạp đồng thời 2 luồng video và xử lý mạng ghép kênh nặng nề. Mô hình đề xuất thuần RGB không những đạt độ chính xác cao hơn (89.4%) mà còn đạt tốc độ lên tới 38.5 FPS, tiết kiệm 50% chi phí cảm biến và bộ nhớ.
- Hiệu quả vượt trội của NWD đối với vật thể siêu nhỏ (NWD-mAP = 86.1%):** Nhờ cơ chế đo khoảng cách Wasserstein liên tục (Mục 4.3), các drone kích thước dưới 32^2 px được hồi quy chính xác với sai số tâm trung bình chỉ 4.8 pixels trên toàn khung hình 1920×1080 .

6.4 Phân tích Trực quan Hóa Định tính



Hình 12: So sánh trực quan chi tiết giữa hộp bọc dự đoán (Prediction – viền đỏ liền) và nhân thực tế (Ground Truth – viền xanh lá nét đứt) trên các mẫu kiểm thử Anti-UAV trong điều kiện toàn cảnh và phóng đại cận cảnh.

Hình 12 thể hiện kết quả so sánh định tính chi tiết giữa nhân thực tế Ground Truth (hộp nét đứt màu xanh lá) và dự đoán của mô hình CenterNet (hộp nét liền màu đỏ):

- **Độ nhạy và độ chính xác định vị:** Mô hình khoanh vùng chính xác mục tiêu drone ngay cả trên các nền ảnh phức tạp (bầu trời mây mù, nhà cao tầng, tán cây) với độ tin cậy Confidence cao.
- **Độ trùng khớp hộp bọc (IoU & NWD):** Nhờ nhánh hồi quy kích thước Sigmoid Logit Prior và hàm mất mát NWD, hộp bọc dự đoán bám khít lấy thân và cánh quạt drone, chỉ số IoU đạt mức cao và tâm đối tượng trùng khít với nhân thực nghiệm.

7 Kết luận và Hướng Phát triển

Báo cáo đã trình bày toàn diện thiết kế kiến trúc, phân tích toán học giải tích và kết quả thực nghiệm của hệ thống phát hiện và bám bắt mục tiêu UAV dựa trên mô hình Anchor-Free CenterNet cải tiến thuần Visible RGB.

Những thành tựu khoa học then chốt bao gồm:

1. Chứng minh tính khả thi và hiệu quả vượt trội của giải pháp thay thế hệ thống đa phương thức RGBT tốn kém bằng chuỗi thời gian Temporal Triplet 9 kênh nhẹ, đạt độ chính xác cao hơn (89.4% mAP) với tốc độ thời gian thực (38.5 FPS).
2. Đóng góp giải pháp toán học giải quyết triệt để hiện tượng Dying ReLU trong mạng phát hiện Anchor-Free: Thay thế bằng hàm Sigmoid và khởi tạo hệ số thiên vị Logit Prior Bias $b_0 = -2.66$ suy dẫn trực tiếp từ phân bố thực nghiệm $s_0 = 0.065$.
3. Tích hợp hoàn chỉnh hệ thống hàm mất mát tiên tiến Gaussian Focal Loss và Normalized Gaussian Wasserstein Distance (NWD), khắc phục nhược điểm nhảy bậc gradient của IoU truyền thống đối với micro-drone.
4. Xây dựng pipeline xử lý thời gian thực không dùng NMS kết hợp bộ lọc quán tính quỹ đạo Trajectory EMA Filter, hỗ trợ bám bắt mượt mà và duy trì khóa mục tiêu ngay cả khi bị che khuất tạm thời.

Hướng phát triển tương lai: Trong các giai đoạn tiếp theo, nhóm nghiên cứu hướng tới việc lượng tử hóa mô hình sang định dạng TensorRT / INT8 để triển khai trực tiếp trên các vi xử lý biên tiết kiệm năng lượng (NVIDIA Jetson Orin Nano), đồng thời tích hợp thêm cơ chế lọc Kalman đa hướng (Extended Kalman Filter) để dự báo quỹ đạo bay 3D trong không gian tác chiến thực tế.

Tài liệu tham khảo

- [1] X. Zhou, D. Wang, and P. Krahenbuhl, “Objects as points,” *arXiv preprint arXiv:1904.07850*, 2019.
- [2] H. Law and J. Deng, “Cornersnet: Detecting objects as paired keypoints,” in *Proceedings of the European Conference on Computer Vision (ECCV)*, 2018, pp. 734–750.
- [3] Q. Hou, D. Zhou, and J. Feng, “Coordinate attention for efficient mobile network design,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021, pp. 13713–13722.
- [4] J. Wang, C. Xu, W. Yang, and L. Yu, “A normalized Gaussian Wasserstein distance for tiny object detection,” *arXiv preprint arXiv:2110.13389*, 2021.
- [5] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollar, “Focal loss for dense object detection,” in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017, pp. 2980–2988.
- [6] K. He, X. Zhang, S. Ren, and J. Sun, “Identity mappings in deep residual networks,” in *Proceedings of the European Conference on Computer Vision (ECCV)*, 2016, pp. 630–645.
- [7] N. Jiang, K. Wang, X. Peng, X. Gao, et al., “Anti-UAV: A large-scale benchmark for vision-based UAV tracking,” *IEEE Transactions on Multimedia*, vol. 25, pp. 560–573, 2021.
- [8] T.-Y. Lin, P. Dollar, R. Girshick, K. He, B. Hariharan, and S. Belongie, “Feature pyramid networks for object detection,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 2117–2125.